

박사학위 논문
지도교수 문 일 영

강화 학습 환경에서 효율적인
에이전트 행동 최적화를 위한
대규모 언어 모델 기반 학습에
관한 연구

2025년 8월

한국기술교육대학교 대학원
컴퓨터공학과 컴퓨터공학전공
용 성 중

강화 학습 환경에서 효율적인 에이전트 행동 최적화를 위한
대규모 언어 모델 기반 학습에 관한 연구

2025. 8. 8
용성중

박사학위 논문
지도교수 문 일 영

강화 학습 환경에서 효율적인
에이전트 행동 최적화를 위한
대규모 언어 모델 기반 학습에
관한 연구

A Study on Large Language Model-Based
Learning for Efficient Agent Behavior
Optimization in a Reinforcement Learning
Environment

2025년 8월

한국기술교육대학교 대학원
컴퓨터공학과 컴퓨터공학전공
용 성 중

강화 학습 환경에서 효율적인
에이전트 행동 최적화를 위한
대규모 언어 모델 기반 학습에
관한 연구

A Study on Large Language Model-Based
Learning for Efficient Agent Behavior
Optimization in a Reinforcement Learning
Environment

이 논문을 공학 박사학위 논문으로 제출합니다

2025년 8월

한국기술교육대학교 대학원

컴퓨터공학과 컴퓨터공학전공

용 성 중

용성중의

공학 박사학위 논문을 인준함

심사위원장 _____ 권 오 영 (인)

심사위원 _____ 박 형 근 (인)

심사위원 _____ 문 일 영 (인)

심사위원 _____ 유 윤 섭 (인)

심사위원 _____ 김 유 두 (인)

2025년 8월

한국기술교육대학교 대학원

감 사 의 글

본 논문이 세상의 빛을 보기까지, 깊은 학문적 가르침과 따뜻한 격려로 이끌어주신 많은 분들이 계셨습니다. 이 지면을 빌려 그 소중한 인연과 도움에 진심 어린 감사의 마음을 전하고자 합니다.

무엇보다, 학문의 길을 처음부터 끝까지 세심하게 지도해주신 문일영 교수님께 가장 깊은 감사를 드립니다. 교수님의 끊임없는 격려와 예리한 통찰력이 없었다면 이 연구는 결코 완성에 이르지 못했을 것입니다. 바쁘신 와중에도 언제나 시간을 내어 연구의 방향을 바로잡아 주시고, 제자에게 학자로서의 올바른 자세를 몸소 보여주신 교수님의 은혜를 평생 잊지 않겠습니다.

또한, 귀한 시간을 내어 본 논문의 심사를 맡아주시고, 애정 어린 조언으로 연구의 완성도를 높여주신 권오영 교수님, 박형근 교수님, 유윤섭 교수님 그리고 김유두 교수님께도 진심으로 감사드립니다. 교수님들의 날카로운 지적과 따뜻한 격려 덕분에 부족했던 부분을 채우고 더 넓은 시각으로 연구를 바라볼 수 있었습니다.

지난 석사 과정부터 박사 졸업에 이르기까지, 변함없는 지지와 응원을 보내준 석광호 교수, 천재성 교사, 황현서 연구원에게도 감사의 마음을 표합니다. 더불어, NGN 연구실의 박병주, 유연휘를 비롯한 모든 구성원들과 함께했던 즐거운 시간들은 잊지 못할 소중한 추억으로 남을 것입니다. 여러분의 존재만으로도 큰 힘이 되었습니다.

마지막으로, 세상에서 가장 든든한 버팀목이 되어준 사랑하는 가족들에게 이 모든 영광을 돌립니다. 제가 학문의 길에 온전히 집중할 수 있었던 것은 언제나 한결같은 믿음과 무한한 사랑으로 곁을 지켜준 가족들이 있었기 때문입니다. 다시 한번, 모든 분들께 진심으로 머리 숙여 감사드립니다.

국문 요약

강화 학습 환경에서 효율적인 에이전트 행동 최적화를 위한 대규모 언어 모델 기반 학습에 관한 연구

지능형 에이전트의 자율적 의사결정 능력 구현을 목표로 하는 강화학습 분야의 근본적인 한계를 해결하기 위한 시도로 본 연구는 대규모 언어 모델(Large Language Model, LLM)이 내재한 고차원적인 자연어 처리 및 추론 역량을 활용하여 MiniGrid 환경에서 강화학습 에이전트의 행동을 최적화하는 새로운 패러다임의 접근법을 제안하고 그 타당성을 실제 실험을 통해 확인하였다. 본 연구의 핵심적인 기여는 환경 상태 정보를 정교하게 구조화된 자연어 텍스트로 변환하여 LLM(특히 한국어 특화 모델 활용)에 전달하고 LLM의 의미론적 이해 및 추론 메커니즘을 통해 최적 행동 정책을 도출한 후, 이를 다시 환경 내에서 실행 가능한 제어 신호로 변환하는 정보 처리 및 제어 루프를 설계하고 구현에 중점을 두었다.

MiniGrid-Empty-5x5-v0 환경에서 수행된 비교 실험 결과, 제안된 LLM 기반 에이전트는 대표적인 심층 강화학습 알고리즘 PPO (Proximal Policy Optimization), DQN (Deep Q-Networks) 및 무작위 탐색 방식과 비교하여 목표 달성 성공률(95.3%)과 학습 안정성(보상 표준편차 0.24) 측면에서 통계적으로 유의미하게 더 뛰어난 결과로 나타났다. 이는 LLM 통합이 단순한 성능 향상을 넘어, 학습 과정의 변동성을 효과적으로 줄일 수 있음을 확인하였다. 또한, 목표 달성까지 요구되는 평균 스텝 수 감소를 통해 향상된 탐색 효율성과 보다 복잡한 16x16 환경에서도 우수한 초기 성능 및 일반화 능력은 본 연구의 접근법이 실질적인 효용성과 가능성이 있음을 확인하였다.

이러한 실증적 결과는 LLM 기반 접근법이 환경 상태 정보 처리에서의 구조적 유연성, 방대한 사전 지식 활용을 통한 일반화 잠재력, 그리고 원리적으로 가능한 향상된 해석 가능성 등 중요한 이론적 강점을 내포하고 있음을 시사한다. 본 연구는 동시에 현존하는 기술적 한계점들이 몇 가지 존재한다. 복잡하거나 동적인 실제 환경으로의 확장성 문제, 생성된 행동의 수학적 최적성 보장의 부재, 확률적 모델 고유의 성능 재현성 및 안정성 이슈, 그리고 대규모 모델의 실시간 추론 성능 한계 등은 실용화를 위해 반드시 해결해야 할 도전 과제로 남아있다.

결론적으로, 본 연구는 LLM을 강화학습의 핵심 의사결정 메커니즘으로 통합하는 접근법이 상당한 유용성을 지닌 새로운 연구 접근법의 가능성을 확인하였다. 그러나 이 잠재력을 완전한 실용 기술로 전환하기 위해서는 앞서 논의된 확장성, 최적성, 안정성, 실시간성 등 다차원적인 기술적 한계점들을 넘어서야 한다. 따라서 향후 연구는 보다 정교한 하이브리드 아키텍처 설계, 강화학습 문제의 특수성을 고려한 LLM 미세조정 및 프롬프트 엔지니어링 고도화, 멀티모달 정보의 효과적 통합, 견고한 안전성 및 신뢰성 보장 메커니즘 개발, 그리고 설명 가능한 AI 기술의 접목 등에 전략적으로 집중될 필요가 있다. 이러한 다각적인 노력을 통해 현재의 한계를 극복하고, 궁극적으로 인간 수준의 지능과 적응력을 갖춘 자율 에이전트 시스템 구현이라는 비전에 한 걸음 더 다가갈 수 있을 것으로 전망된다.

주제어 : LLM, 강화학습, 자연어처리, 인공지능, 에이전트 행동 최적화, MiniGrid

목 차

국문요약	i
목 차	iii
표 목 차	iv
그림목차	vi

제1장 서론

제1절 연구의 필요성 및 목적	1
1. 연구의 필요성	1
2. 대규모 언어 모델 및 연구 목적	11

제2장 관련연구

제1절 강화학습의 기본 개념과 알고리즘	17
1. 강화학습 문제 정의	17
2. 가치 기반 방법	21
3. 정책 기반 방법	23
4. 액터-크리틱 방법	24
5. 심층 강화학습	26
제2절 MiniGrid	27
1. MiniGrid 환경과 그 특성	27
2. 개요 및 설계 철학	27
3. 주요 특징	28
4. 공통 태스크 및 벤치마크	30
5. MiniGrid 환경에서의 선행 연구	31
6. 대규모 언어 모델(LLM)의 개요 및 최근 발전	32

7. LLM 모델 종류 요약	39
-----------------------	----

제3장 에이전트(Agent) 행동 최적화 설계

제1절 실험 환경 설정	43
1. 강화학습 환경	44
제2절 언어 모델	47
1. 모델 선정 배경	47
2. LLaMA 아키텍처의 주요 특징	48
3. Blossom 변형 및 한국어 특화	49
4. LLM의 개념적 역할 및 활용 환경	50
5. LLM파라미터 조정을 통한 에이전트 행동 최적화	51

제4장 실험 및 결과

제1절 실험	53
1. LLM 기반 에이전트 설계	53
2. 실험 절차	57
제2절 결과	59
1. LLM 모델 선정을 위한 성능 검증	59
2. LLM 기반 에이전트 행동 최적화 성능 분석	62
3. 에이전트 행동 선택 패턴 분석	73
4. LLM 기반 에이전트의 일관성 및 효율성 분석	77
5. 환경 복잡도에 따른 일반화 분석	81

제5장 고찰 및 결론

제1절 연구의 주요 결과 및 의의	85
1. LLM 기반 에이전트의 성능 및 특성 분석	85

2. 연구 결과의 의의	87
제2절 연구 한계점 및 향후 연구 방향	89
1. 기술적 한계점 분석	89
2. 향후 연구 방향 및 결론	91
참고문헌	95
Abstract	104

표 목 차

<표 2-1> Key Tasks in MiniGrid	30
<표 2-2> LLM Architectures: Features and RL Integration	39
<표 4-1> Environmental State Description	53
<표 4-2> LLM Prompt Design	53
<표 4-3> Initial Success Rate Comparison of LLM Models in MiniGrid-5x5	58
<표 4-4> Results of 1,000 episodes in MiniGrid-5x5 environment by algorithm ...	66

그 립 목 차

[그림 3-1] 에이전트 행동 최적화를 위한 과정	51
[그림 3-2] 에이전트 행동 최적화를 위한 LLM 파라미터별 성공률	52
[그림 4-1] get_environment_state 함수 알고리즘	54
[그림 4-2] get_llm_action 함수 알고리즘	54
[그림 4-3] 전체 시스템 구조	57
[그림 4-4] LLM 강화학습 100개 에피소드의 총 보상 결과	63
[그림 4-5] LLM 강화학습 1,000 에피소드 총 보상 결과	64
[그림 4-6] 무작위 알고리즘 강화학습 100개 에피소드의 총 보상 결과	66
[그림 4-7] 무작위 알고리즘 강화학습 1,000개 에피소드의 총 보상	67
[그림 4-8] PPO 파라미터	71
[그림 4-9] DQN 파라미터	71
[그림 4-10] 제안한 LLM 파라미터	72
[그림 4-11] LLM 모델 적용 시 성공적인 단계 수	74
[그림 4-12] 무작위 알고리즘 적용 시 성공적인 단계 수	76
[그림 4-13] 알고리즘별 1,000 에피소드 성공률	78
[그림 4-14] 알고리즘별 평균 스텝 수	80
[그림 4-15] MiniGrid-16x16 환경 변화에 따른 보상 결과	82
[그림 4-16] 16x16 실험 횟수별 1,000 에피소드 성공 횟수	84

제1장 서론

제1절. 연구의 필요성 및 목적

1. 연구의 필요성

가. 강화학습의 중요성과 최근 연구 동향

인공지능의 핵심 분야 중 하나인 강화학습(Reinforcement Learning, RL)은 목표 지향적 학습의 강력한 패러다임으로 자리 잡았다[1, 2]. 강화학습의 기본 구조는 행동 주체인 에이전트가 주어진 환경 내에서 자신의 현재 상태를 인식하고, 가능한 행동 중 하나를 선택하여 실행하며, 그 결과로 환경으로부터 다음 상태와 함께 수치적 보상 신호를 받는 순환적 상호작용 과정에 기반한다. 에이전트의 궁극적인 목표는 단기적인 보상이 아닌, 장기적인 관점에서 누적되는 총 보상을 최대화하는 최적의 행동 전략, 즉 정책을 학습하는 것이다. 이러한 학습 방식은 지도학습(Supervised Learning)처럼 각 입력에 대한 ‘정답’ 레이블이 필요하지 않으며, 비지도 학습(Unsupervised Learning)처럼 데이터 내의 숨겨진 구조를 찾는 것과도 구별된다. 오직 시행착오를 통해 얻는 보상이라는 평가적 피드백만을 이용하여 스스로 최적의 행동을 ‘발견’해 나간다는 점에서, 명확한 정답을 알 수 없거나 동적으로 변화하는 환경에서의 순차적 의사결정 문제 해결에 독보적인 강점을 가진다.

초기 강화학습 연구는 주로 동적 프로그래밍, 몬테카를로 방법, 시간차 학습과 같은 알고리즘을 기반으로, 상태와 행동 공간이 유한하고 작은 문제들에 적용되어 이론적 토대를 마련했다. 예를 들어, Q-러닝(Q-learning)이나 SARSA(State-Action-Reward-State-Action)와 같은 알고리즘은 각 상태-행동 쌍의 가치를 테이블 형태로 저장하고 업데이트하며 최적 정책을 찾아 나갔다. 그러나 체스판의 상태 가짓수보다 훨씬

많은 상태를 가지는 현실의 문제들, 예를 들어 로봇이 연속적인 관절 각도를 제어하거나 자율주행차가 카메라 이미지로부터 도로 상황을 인식하는 문제 등은 상태 및 행동 공간의 차원이 매우 높고 연속적이기 때문에, 이러한 테이블 기반 방법으로는 표현력과 확장성 측면에서 명백한 한계에 부딪혔다.

이러한 ‘차원의 저주’ 문제를 극복하기 위한 돌파구는 심층 신경망(Deep Neural Network, DNN)과의 결합에서 마련되었다. 심층 강화학습(Deep Reinforcement Learning, DRL)은 DNN을 사용하여 고차원의 상태 입력으로부터 직접 가치 함수나 정책 함수를 근사하는 방식을 채택한다[3, 4].

DNN의 강력한 함수 근사 능력과 표현 학습 능력 덕분에 DRL 에이전트는 이전에는 다루기 힘들었던 복잡한 문제들에서 놀라운 성공을 거두기 시작했다. 대표적인 예로, DeepMind의 DQN은 별도의 게임 규칙 입력 없이 아타리 게임 화면의 픽셀 데이터만을 입력받아 인간 전문가 수준의 플레이 능력을 학습했으며, AlphaGo와 AlphaZero는 심층 신경망과 몬테카를로 트리 탐색을 결합하여 세계 최고 수준의 바둑 및 체스, 쇼기 기사를 능가하는 성과를 보였다[5]. 이 외에도 복잡한 실시간 전략 게임인 스타크래프트에서의 전문가 수준 플레이[6], 로봇 공학에서의 정교한 조작 및 보행 제어[7, 8], 자율주행 시스템에서의 주행 정책 학습[9], 데이터 센터 냉각 시스템 최적화와 같은 자원 관리[10], 사용자 맞춤형 추천 시스템 성능 향상, 금융 분야에서의 포트폴리오 관리 최적화[11] 등 광범위한 분야에서 DRL의 성공 사례가 보고되면서, 그 중요성과 잠재력에 대한 기대가 더욱 높아지고 있다.

강화학습은 다양한 분야에서 주목할 만한 성공을 거두었음에도 불구하고, 여전히 해결해야 할 다수의 도전 과제를 내포하고 있다. 이러한 과제를 극복하기 위한 연구가 다각적으로 수행되고 있으며, 현재 강화학습 연구의 주요 동향과 핵심 과제는 다음과 같이 논의될 수 있다.

첫째, 샘플 효율성 증대가 주요 과제로 부각된다. 현실 세계에서의 상호

작용은 시간, 비용, 안전상의 제약으로 인해 제한적이므로, 최소한의 환경 상호작용(샘플)만으로 효과적인 학습을 달성하는 것이 필수적이다. 이를 위해 환경의 동역학 모델을 학습하여 시뮬레이션에 활용하는 모델 기반 강화학습[12]과, 사전 수집된 대규모 데이터셋 만을 사용하는 오프라인 강화학습[13]이 활발히 연구되고 있다. 특히 오프라인 강화학습은 데이터셋과 학습된 정책 간의 분포 불일치 문제를 해결하는 것이 관건이다. 또한, 기존 태스크에서 축적된 지식을 새로운 태스크에 전이하는 전이 학습 및 다양한 태스크에 대한 빠른 적응 능력을 학습하는 메타 학습[14] 역시 샘플 효율성을 제고하는 유망한 접근법으로 간주된다.

둘째, 탐험과 활용 간의 균형 설정은 강화학습의 근본적인 트레이드오프 문제이다. 에이전트는 최적 정책을 찾기 위해 미지의 상태-행동 공간을 탐색하는 탐험과, 현재까지 학습된 최선의 정책을 이용해 보상을 극대화하는 활용 사이에서 적절한 균형을 유지해야 한다. 특히 보상이 희소하게 주어지는 환경에서는 효율적인 탐험 전략의 부재가 학습 실패로 이어질 수 있다. 기존의 ϵ -greedy나 낙관적 초기값 설정과 같은 전통적 방법을 넘어, 내재적 동기에 기반하여 에이전트의 호기심을 자극하는 탐험 기법(예: ICM[15], RND[16]) 및 정보 이론적 접근을 활용한 정교한 탐험 보너스 설계 등이 중요한 연구 방향으로 자리 잡고 있다.

셋째, 실제 물리 시스템이나 사회 시스템에 강화학습을 적용하기 위해서는 안전성 및 견고성 확보가 필수적이다. 예측 불가능하거나 위험한 행동을 방지하기 위해 학습 및 실행 과정에서 특정 제약 조건을 만족하도록 강제하는 제약 조건 만족 강화학습[17] 연구가 진행 중이다. 더불어, 환경의 미세한 변화, 예상치 못한 외란(Perturbation), 또는 적대적 공격에 대해서도 학습된 정책이 안정적으로 작동하도록 강인성을 확보하는 연구 역시 중요하게 다뤄지고 있다.

넷째, 학습된 특정 환경 외의 새로운 환경에 대한 일반화 성능 향상이 요구된다. 심층 강화학습(DRL) 에이전트는 종종 학습 환경에 과적합 되

어, 약간의 변형이 가해진 환경이나 미지의 환경에서는 성능이 급격히 저하되는 경향을 보인다. 이를 극복하기 위해 환경 파라미터를 무작위화하여 학습하는 절차적 콘텐츠 생성[18]과 도메인 무작위화[19]기술을 활용하여 다양한 학습 환경을 제공함으로써 일반화 능력을 향상 시키려는 연구가 활발하다.

다섯째, 다수의 에이전트가 상호작용하는 다중 에이전트 시스템으로의 확장이 중요한 연구 분야이다. 다중 에이전트 강화학습(Multi-Agent RL, MARL)[20]은 여러 에이전트가 협력 또는 경쟁하며 공동의 목표나 각자의 목표를 달성하기 위해 학습하는 문제를 다룬다. MARL 환경에서는 단일 에이전트 설정과 달리, 각 에이전트 관점에서 환경이 비정상적으로 변화하는 문제, 에이전트 간의 기여도 분배 문제, 효과적인 통신 및 협력 전략 학습 등 고유한 도전 과제들이 존재한다.

여섯째, 강화학습 에이전트와 인간 간의 상호작용 증진이 요구된다. 에이전트가 인간 사회에서 효과적으로 활용되기 위해서는 인간의 의도와 선호를 이해하고 반영하는 능력이 필수적이다. 인간의 시연으로부터 학습하는 모방 학습, 인간 행동을 통해 보상 함수를 추론하는 역강화학습(Inverse Reinforcement Learning, IRL), 그리고 학습 과정에서 인간의 피드백(선호도 비교, 평가 등)을 직접 활용하는 상호작용형 강화학습[21] 등은 보상 함수 설계의 어려움을 완화하고 인간의 가치에 부합하는 에이전트를 개발하는데 기여한다.

강화학습은 복잡하고 도전적인 문제 해결을 위한 핵심 인공지능 기술로서 이론, 방법론, 응용 측면에서 지속적으로 발전하고 있다. 상술한 도전 과제들을 해결하기 위한 연구 노력은 강화학습의 적용 범위를 확장하고 그 성능을 향상 시켜, 미래 사회에서의 중요성을 더욱 증대시킬 것으로 판단된다.

나. 대규모 언어 모델(LLM)의 발전과 그 응용 분야

최근 수년간 인공지능 분야의 혁신을 주도한 핵심 기술 중 하나로 대규모 언어 모델이 부상하였다[22, 23].

LLM은 그 명칭에서 알 수 있듯이, 초기 수백억 개에서 현재 수조 개에 이르는 방대한 수의 학습 가능한 파라미터를 가진 거대한 신경망 모델을 지칭한다. 이러한 모델들은 인터넷 규모의 방대한 텍스트 데이터(서적, 웹 페이지, 기사, 코드 등)를 활용한 사전 학습 과정을 거친다. 이 과정을 통해 모델은 인간 언어의 복잡한 통계적 패턴, 문법 구조, 의미론적 관계를 학습할 뿐만 아니라, 상당한 양의 사실적 지식과 상식을 내재화하게 된다.

LLM의 이러한 능력의 근간에는 2017년 제안된 트랜스포머 아키텍처가 자리 잡고 있다[24]. 기존의 순환 신경망(RNN)이나 장단기 메모리(LSTM) 모델은 순차적 정보 처리 방식의 한계로 인해 장거리 의존성 포착에 어려움을 겪었다. 반면, 트랜스포머는 셀프 어텐션 메커니즘을 도입하여 입력 시퀀스 내 모든 단어 쌍 간의 관련성을 직접 계산하고 가중치를 부여함으로써 문맥 정보를 보다 효과적으로 파악할 수 있게 하였다. 특히, 셀프 어텐션 메커니즘은 병렬 처리에 유리하여 이전 모델들보다 훨씬 큰 규모의 모델을 효율적으로 학습시키는 것을 가능하게 했다.

LLM의 괄목할 만한 발전은 몇 가지 주요 요인과 특징으로 설명될 수 있다. 첫째, 규모의 확장 법칙이다. 연구자들은 모델의 파라미터 수, 학습 데이터셋의 크기, 그리고 투입된 컴퓨팅 자원의 양을 증가시킬수록 LLM의 성능이 예측 가능한 로그-선형 관계로 향상된다는 경험적 법칙을 발견했다[25]. 이는 모델과 데이터 규모 확장이 성능 향상으로 이어진다는 강력한 증거를 제공하며, LLM 분야에서 ‘규모의 경쟁’을 촉발하는 중요한 동력이 되었다. 물론 이러한 대규모 확장은 막대한 계산 자원과 엔지니어링 노하우를 요구하는 도전적인 과제이다.

둘째, 사전학습-미세 조정 패러다임이다. LLM 학습은 일반적으로 두 단계로 진행된다. 첫 번째 단계는 대규모의 레이블 없는 텍스트 코퍼스를

사용하여 언어 자체에 대한 일반적인 이해 능력을 배양하는 사전 학습이다. 이 단계에서는 주로 마스크 된 단어 예측이나 다음 단어 예측과 같은 자기 지도 학습 방식이 활용된다[26]. 두 번째 단계는 사전 학습된 모델을 특정 목표 태스크에 맞게 추가 학습시키는 미세 조정(fine-tuning)이다. 여기서는 해당 태스크 관련 레이블된 데이터를 사용하여 모델 전체 파라미터를 업데이트하거나, LoRA와 같은 파라미터 효율적 미세 조정 기법을 통해 일부 파라미터만 효율적으로 조정한다. 이 패러다임 덕분에 각 태스크마다 모델을 새로 학습시킬 필요 없이, 강력한 범용 모델을 다양한 특정 문제에 효과적으로 적용할 수 있게 되었다.

셋째, 인컨텍스트 학습 및 제로샷/퓨샷 능력 이다. GPT-3와 같이 극도로 큰 규모의 LLM은 별도의 파라미터 업데이트 없이, 사용자 입력(프롬프트)에 작업 설명이나 소수의 예시를 자연어로 제공하는 것만으로도 새로운 태스크를 수행하는 능력을 보여주었다. 인컨텍스트 학습이라 불리는 이 능력은 모델이 사전학습을 통해 습득한 방대한 지식과 패턴 인식 능력을 바탕으로 프롬프트의 문맥 내에서 주어진 작업을 이해하고 해결하는 것으로 해석된다. 이는 LLM의 활용성을 크게 확장 시키고 모델과의 상호작용 방식을 변화시켰다.

넷째, 창발적 능력(Emergent Abilities)의 발현이다. 모델 규모가 특정 임계점을 초과하면서, 작은 모델에서는 관찰되지 않았던 복잡하고 추상적인 능력들이 나타나는 현상이 보고되었다[27]. 단계별 추론, 복잡한 수학 문제 해결, 비유 및 유머 이해, 창의적 글쓰기 등이 이러한 창발적 능력의 예시에 해당한다. 이러한 능력이 발생하는 정확한 기제에 대한 연구는 계속 진행 중이지만, 이는 LLM이 단순한 패턴 암기를 넘어 고차원적인 지능의 가능성을 내포하고 있음을 시사한다.

이러한 LLM의 발전은 자연어 처리(NLP) 분야에 혁신을 가져왔을 뿐만 아니라, 인공지능 기술의 응용 범위를 사회 전반으로 빠르게 확장 시키고 있다. 주요 응용 분야를 살펴보면, 첫째로 기계 번역 품질 향상, 텍스트

요약, 질의응답 시스템, 감성 분석 등 전통적인 NLP 태스크에서 인간 수준에 근접하거나 이를 넘어서는 성능을 보이고 있다[28].

첫째, ChatGPT와 같은 대화형 AI(챗봇) 및 가상 비서 개발에서 핵심 역할을 수행하며 사용자 경험을 혁신하고 있다[29].

둘째, 뉴스 기사, 블로그 포스트, 소셜, 시나리오 등 창의적인 글쓰기부터 광고 문구, 이메일 초안, 보고서 등 실용적인 텍스트 콘텐츠를 자동 생성하는 데 널리 활용된다.

셋째, 자연어 요구사항 명세를 바탕으로 프로그래밍 코드를 생성하거나, 기존 코드의 기능을 설명하고 버그를 수정 제안하는 등 소프트웨어 개발의 생산성과 효율성 향상에 기여하고 있다[30].

넷째, LLM은 방대한 내재적 지식을 바탕으로 단순 키워드 검색을 넘어선 심층적인 정보 탐색, 여러 출처 정보의 통합, 논리적 추론을 통한 새로운 결론 도출 등에 활용될 수 있다[31].

다섯째, 신약 개발, 신소재 설계, 유전자 분석 등 복잡한 과학 연구 과정에서 문헌 분석, 데이터 해석, 가설 생성을 보조하여 연구 개발 주기를 단축하고 새로운 발견을 촉진할 잠재력을 보여주고 있다[32].

여섯째, 학생 맞춤형 튜터링 시스템, 언어 학습 파트너, 교육 콘텐츠 제작 지원 등 교육 분야에서도 개인화된 학습 경험을 제공하며 혁신을 이끌 가능성이 있다[33].

결론적으로, 대규모 언어 모델은 그 자체로 강력한 지능형 도구로서 기능할 뿐만 아니라, 강화학습과 같은 다른 AI 기술 분야와의 융합을 통해 더욱 지능적이고 적응력이 뛰어난 시스템 구축의 새로운 가능성을 제시하고 있다. 이러한 융합은 차세대 인공지능 기술 발전의 중요한 축을 형성할 것으로 판단된다.

다. LLM을 강화학습에 적용하는 새로운 접근 방식의 필요성

강화학습은 지난 수십 년간 지속적인 발전을 통해 다양한 문제 해결 능

력을 입증해 왔다. 그러나 특히 복잡하고 불확실성이 높은 현실 세계 문제에 적용하는 과정에서 몇 가지 근본적인 한계와 도전에 직면하고 있다. 이러한 한계점들은 주로 강화학습 에이전트의 학습 효율성, 일반화 능력, 안전성, 그리고 인간과의 상호작용 측면에서 나타난다.

가장 근본적인 어려움 중 하나는 정교하고 효과적인 보상 설계에 있다. 강화학습은 보상 최대화 가설에 따라 모든 목표를 누적 보상 기댓값의 최대화로 표현할 수 있다는 가정에 기반하지만, 실제 문제에서 원하는 복잡한 목표나 행동 양식(예: 안전하고 신속한 물체 운반, 사용자 만족도 증진)을 단일 스칼라 값의 보상 함수로 정확히 정량화하는 것은 매우 어렵다[34]. 부적절하게 설계된 보상은 에이전트가 의도치 않은 방식으로 보상을 추구하는 ‘보상 해킹’ 현상을 유발하거나 목표 달성 실패로 이어질 수 있으며, 보상 함수 설계 및 수정 과정은 상당한 시간과 전문 지식을 요구하는 병목 현상을 초래한다.

또한, 심층 강화학습(Deep Reinforcement Learning, DRL) 에이전트는 학습 환경의 미묘한 통계적 특성까지 학습하여 과적합 되는 경향이 있으며, 이로 인해 학습 환경과 조금만 다르거나 새로운 상황에 직면했을 때 일반화 능력이 현저히 떨어지는 취약점을 보인다. 더불어, 인간에게는 당연한 세상에 대한 기본적인 상식이나 인과관계 이해가 부족하여 비현실적이거나 비효율적인 행동 계획을 수립하는 경우가 많다.

자연어 지시 사항을 이해하고 활용하는 능력의 부재 역시 중요한 한계이다. 인간은 자연어를 통해 목표, 제약 조건, 조언 등을 효율적으로 전달할 수 있지만, 전통적인 RL 에이전트는 이러한 고수준의 언어 정보를 직접 이해하고 학습에 활용하는 메커니즘이 부족하다. 목표는 보통 특정 상태 집합, 상태 변수의 목표값, 혹은 복잡하게 설계된 보상 함수 형태로 제공되어야 하므로, 인간 사용자와의 직관적인 소통을 저해하고 에이전트의 적용 범위를 제한한다.

탐험 과정의 비효율성과 안전 문제도 어려운 도전 과제이다. 에이전트

가 최적 정책을 학습하려면 충분한 환경 탐험이 필수적이지만, 상태 공간이 방대하거나 보상이 희소한 환경에서는 무작위 탐험이 극도로 비효율적일 수 있다. 더욱이 탐험 중 에이전트가 로봇의 물리적 손상이나 시스템 고장과 같은 위험한 상태에 도달할 가능성이 있어, 안전이 중요한 실제 시스템 적용을 어렵게 만든다.

마지막으로, 심층 신경망 기반 DRL 에이전트의 의사결정 과정은 ‘블랙박스’와 같아 행동의 해석 및 디버깅이 매우 어렵다[35]. 이러한 해석 가능성의 부족은 에이전트 행동의 신뢰성과 예측 가능성을 저해하며, 예상치 못한 실패 시 원인 분석 및 해결을 복잡하게 만든다.

이러한 전통적인 강화학습의 난제들을 해결하고 보다 지능적이고 유능한 에이전트를 개발하기 위한 혁신적인 접근 방식으로, 최근 비약적인 발전을 이룬 대규모 언어 모델(LLM)의 능력을 강화학습 프레임워크에 통합하려는 시도가 활발히 이루어지고 있다. LLM은 방대한 텍스트 데이터로부터 학습한 풍부한 언어 이해 능력, 폭넓은 세계 지식, 추론 능력, 상식 등을 갖추고 있어, 위에서 언급된 강화학습의 한계점들을 보완하고 극복하는 데 다음과 같이 기여할 잠재력을 지닌다.

첫째, LLM은 자연어를 통한 목표 설정 및 작업 분해를 가능하게 한다. 사용자가 자연어로 제시하는 복잡하거나 추상적인 목표(예: ‘부엌에서 사과를 찾아 식탁 위에 놓아라’)를 이해하고, 이를 에이전트가 수행 가능한 하위 목표나 구체적인 상태 조건으로 변환할 수 있다[36, 37]. 이는 에이전트에게 보다 직관적이고 유연하게 임무를 부여하고 장기 계획 수립을 용이하게 한다.

둘째, LLM의 지식을 활용하여 지식 기반의 보상 함수 설계 및 보상 셰이핑이 가능하다. LLM이 가진 상식이나 도메인 지식을 이용해, 희소한 외부 보상 환경에서 에이전트 학습을 효과적으로 안내할 조밀하고 의미론적으로 풍부한 보조 보상 또는 내재적 보상 신호를 생성할 수 있다[38, 39]. 예를 들어, 목표 달성에 근접하는 행동에 긍정적 보상을 제공하거나

위험한 행동에 패널티를 부여하는 방식으로 보상 함수 설계를 지원하거나 자동화할 수 있다.

셋째, LLM은 상식적 추론을 통해 고수준 계획 수립 및 행동 공간 제약에 기여한다. 주어진 목표와 현재 상태를 바탕으로 세상의 작동 방식에 대한 이해를 활용하여 합리적인 행동 계획이나 하위 목표 시퀀스를 생성할 수 있다[40, 41]. 이 계획은 에이전트의 탐험 방향을 유도하거나, 불필요하거나 위험한 행동을 제거하여 유효 행동 공간을 효과적으로 축소함으로써 학습 효율성을 크게 향상시킬 수 있다.

넷째, 언어 모델 기반의 세계 모델 구축 또는 향상에 LLM이 활용될 수 있다. LLM이 내재한 물리적, 사회적 상호작용 지식을 통해 환경의 동역학이나 객체 간 상호작용을 예측하는 세계 모델을 구축하거나 기존 모델 기반 RL의 세계 모델을 보강할 수 있다[42]. 이는 특히 데이터가 부족한 환경에서 모델 기반 학습의 정확도와 효율성을 높이는 데 기여할 수 있다.

다섯째, LLM의 언어 생성 능력을 활용하여 에이전트 행동에 대한 자연어 설명 생성이 가능하다[43]. 에이전트가 특정 결정을 내린 이유나 행동 계획을 인간이 이해하기 쉬운 자연어로 설명하도록 함으로써, 에이전트의 투명성과 해석 가능성을 높여 사용자 신뢰를 확보하고 시스템 디버깅 및 개선에 도움을 줄 수 있다.

이처럼 LLM과 강화학습의 결합은 각 기술의 강점을 활용하여 서로의 약점을 보완하는 강력한 시너지 효과를 창출할 잠재력을 가진다. LLM의 풍부한 지식과 언어 능력은 강화학습 에이전트가 보다 지능적으로 환경을 이해하고, 효율적으로 학습하며, 인간과 원활하게 소통하고 협력할 수 있도록 지원한다. 따라서 LLM 기반 강화학습이라는 새로운 연구 패러다임은 기존 강화학습의 적용 범위를 확장하고 성능을 한 단계 끌어올릴 수 있는 매우 중요하고 시의적절한 연구 방향이라 할 수 있다. 본 논문은 이러한 가능성을 탐구하기 위해, 특히 LLM의 능력을 활용하여 잘 알려진

강화학습 벤치마크 환경인 MiniGrid에서 에이전트의 행동 최적화를 달성하는 구체적인 방법론을 제안하고 검증하고자 한다.

2. 대규모 언어 모델 및 연구 목적

가. 대규모 언어 모델(LLM)의 종류

대규모 언어 모델(LLM)은 그 기반이 되는 아키텍처, 학습 목표, 그리고 주요 응용 분야에 따라 여러 주요 유형으로 분류될 수 있다. 이러한 분류는 주로 구글이 제안한 트랜스포머 아키텍처의 핵심 구성 요소인 인코더와 디코더 중 어떤 부분을 중점적으로 활용하는지에 따라 이루어진다.

각 유형의 모델은 고유한 강점과 특성을 지니므로, 특정 태스크나 LLM과 강화학습의 통합 방식에 더 적합할 수 있다. 첫 번째 유형은 인코더 전용 모델이다. BERT(Bidirectional Encoder Representations from Transformers)가 이 유형의 대표적인 예시이며, 이후 RoBERTa[44], ALBERT[45], ELECTRA[46] 등 다양한 개선 모델이 등장했다. 이 모델들은 트랜스포머 구조에서 인코더 부분만을 활용한다. 인코더는 입력 텍스트 전체를 동시에 처리하여 각 단어의 의미를 해당 단어의 앞뒤 문맥, 즉 양방향 문맥을 모두 고려하여 깊이 있게 이해하고 풍부한 문맥적 표현 벡터로 변환하는 데 특화되어 있다.

사전 학습 과정에서는 주로 입력 문장의 일부 단어를 마스킹하고 원 단어를 예측하는 마스킹된 언어 모델이나 두 문장의 연속성을 예측하는 다음 문장 예측과 같은 목표를 사용하여 학습된다. 이러한 특성으로 인해 인코더 전용 모델은 텍스트 분류, 개체명 인식, 질의응답 등 입력 텍스트의 의미를 정확하게 이해 하는 것이 중요한 자연어 이해(NLU) 태스크에서 강력한 성능을 발휘한다. 강화학습 환경에서는 에이전트가 관찰하는 상태(텍스트 기반 환경 설명, 센서 데이터 로그 등)를 의미론적으로 풍부한 벡터로 인코딩하여 정책 또는 가치 네트워크의 입력으로 사용하거나,

자연어 지시 사항을 이해하는 모듈로 활용될 수 있다.

두 번째 유형은 디코더 전용 모델이다. OpenAI의 GPT(Generative Pre-trained Transformer) 시리즈[47, 48]가 이 계열의 가장 잘 알려진 모델이며, 최근 LLM 분야의 발전을 주도하고 있다. 이 모델들은 트랜스포머 아키텍처의 디코더 부분만을 사용하며, 자동회귀방식으로 작동한다.

즉, 텍스트 생성 시 현재까지 생성된 토큰들만을 바탕으로(단방향 문맥) 다음에 올 확률이 가장 높은 토큰을 순차적으로 예측하며 생성해 나간다. 사전 학습 목표는 주로 주어진 텍스트 시퀀스에서 다음 단어를 예측하는 표준 언어 모델링이다. 이 구조는 문맥을 파악하여 일관성 있고 자연스러운 장문의 텍스트를 생성하는 데 매우 뛰어나, 대화형 AI, 창의적 글쓰기, 텍스트 요약, 코드 생성 등 다양한 생성 태스크에서 압도적인 성능을 보인다. 특히 모델 규모가 커짐에 따라 제로샷/퓨샷 학습 능력과 창발적 능력이 두드러지는 경향이 있다. 강화학습과의 통합에서는 LLM이 자연어 목표를 바탕으로 고수준 행동 계획을 생성하거나, 에이전트 행동에 대한 자연어 설명을 생성하고, 나아가 정책 자체를 언어 모델 형태로 표현하여 행동을 직접 생성하는 연구 등에 활발히 적용될 수 있다.

세 번째 유형은 인코더-디코더 모델, 또는 시퀀스-투-시퀀스 모델이다. 이 모델은 트랜스포머 아키텍처의 인코더와 디코더 부분을 모두 활용하는 고전적인 시퀀스-투-시퀀스 구조를 따른다. 인코더가 입력 시퀀스(예: 원본 언어 문장) 전체를 처리하여 문맥 정보를 압축된 벡터 표현으로 만들면, 디코더는 이 인코더 출력과 이전에 생성한 토큰들을 입력받아 목표 시퀀스(예: 번역된 문장)를 자동회귀 방식으로 생성한다. 이 구조는 입력 시퀀스를 다른 형태의 출력 시퀀스로 변환하는 기계 번역이나 텍스트 요약과 같은 태스크에 매우 효과적이다.

대표적인 모델로는 구글의 T5와 Meta AI의 BART(Bidirectional and Auto-Regressive Transformers)[49] 등이 있다. T5는 모든 NLP 태스크를 텍스트 입력과 텍스트 출력 형식으로 통일하여 처리하는 접근 방식을

채택했으며, BART는 BERT와 유사한 양방향 인코더와 GPT와 유사한 자동회귀 디코더를 결합하고 입력 텍스트에 노이즈를 추가 후 복원하는 방식으로 사전 학습하여 성능을 개선했다. 강화학습 환경에서는 자연어 지시를 구체적인 행동 시퀀스로 ‘번역’하거나, 복잡한 상태 관찰 정보를 간결한 텍스트 설명으로 ‘요약’하여 에이전트의 의사결정에 활용하는 방식으로 응용될 수 있다.

이 세 가지 주요 아키텍처 유형 외에도, LLM은 모델의 파라미터 규모(수백억 개에서 수조 개), 학습 데이터의 종류(텍스트, 코드, 이미지 등)와 규모, 구체적인 사전 학습 목표 및 미세 조정 기법, 그리고 접근성(오픈 소스 대 클로즈드 소스 API) 등에 따라 매우 다양하게 분류될 수 있다.

예를 들어, Meta AI의 LLaMA 시리즈[50]는 상대적으로 작은 크기에도 높은 성능을 보이며 오픈 소스로 공개되어 연구 커뮤니티에서 활발히 활용되고 있다. 반면 Google의 PaLM[51] 및 Gemini[52] 모델은 방대한 규모와 멀티모달 처리 능력을 특징으로 하며, Anthropic의 Claude[53] 모델은 AI 안전성과 윤리적 고려를 강조하며 개발되었다.

본 논문에서 LLM 기반 강화학습 에이전트를 설계하고 구현함에 있어서는, 목표하는 태스크(MiniGrid 환경에서의 행동 최적화)의 특성, 요구되는 능력(예: 계획 수립, 지시 이해), 가용한 컴퓨팅 자원, 그리고 선택된 강화학습 알고리즘과의 통합 용이성 등을 종합적으로 고려하여 가장 적합한 LLM 아키텍처와 특정 모델을 신중하게 선택하는 과정이 필수적이다.

나. 연구 목적 및 논문의 구성

본 논문은 최근 인공지능 분야의 핵심 동력으로 부상한 대규모 언어 모델(LLM)의 잠재력을 강화학습(RL) 프레임워크에 효과적으로 접목하여, 에이전트의 학습 효율성 및 행동 성능을 개선하는 새로운 방법론을 탐구하고 제안하는 것을 목표로 한다. 구체적으로, LLM이 보유한 풍부한 언어 이해 능력, 상식 기반 추론 능력, 그리고 계획 수립 능력을 활용하여,

절차적으로 생성되는 다양한 태스크를 포함하는 그리드 월드 환경인 MiniGrid[54]에서 작동하는 강화학습 에이전트의 행동 최적화 방안을 연구한다. 본 연구는 LLM을 통해 강화학습의 고질적인 문제점(예: 희소 보상, 샘플 비효율성, 자연어 지시 이해 부족)을 완화하고, 에이전트가 보다 복잡한 임무를 효과적으로 수행하며 새로운 상황에 더 잘 일반화될 수 있음을 실험적으로 입증하는 데 중점을 둔다.

이러한 연구 목표를 달성하기 위해, 본 논문은 다음과 같은 논리적 흐름에 따라 구성된다.

제1장 ‘서론’에서는 본 연구의 포괄적인 배경을 제시한다. 강화학습의 기본 개념과 중요성을 설명하고, 샘플 효율성, 탐험, 안전성, 일반화 등 현재 주요 연구 동향과 도전 과제들을 심도 있게 논의한다. 이어서 대규모 언어 모델(LLM)의 발전 과정, 핵심 기술(트랜스포머, 스케일링 법칙 등), 그리고 다양한 응용 분야를 상세히 소개한다. 다음으로, 전통적인 강화학습이 가진 근본적인 한계점들을 지적하고, 이러한 문제들을 해결하기 위해 LLM의 능력을 강화학습에 통합하는 접근 방식의 필요성과 유망성을 구체적인 예시와 함께 강조한다. 또한, 연구에 활용될 수 있는 다양한 유형의 LLM 모델(인코더 전용, 디코더 전용, 인코더-디코더)들의 특징과 장단점을 비교 설명한다. 마지막으로, 논문의 전체적인 구성을 소개하고 각 장에서 다룰 내용을 개괄적으로 소개한다.

제2장 ‘관련 연구’에서는 본 연구의 이론적, 방법론적 기반이 되는 선행 연구들을 체계적으로 검토하고 분석한다. 먼저, 강화학습 분야의 핵심 알고리즘(Q-러닝, SARSA, Actor-Critic 등)과 본 연구와 관련성이 높은 심층 강화학습 방법론(DQN, A3C, PPO 등)의 원리와 특징을 상세히 다룬다. 다음으로, 자연어 처리(NLP) 기술, 특히 LLM을 강화학습에 적용하려는 기존의 다양한 시도들을 집중적으로 조사한다. 여기에는 LLM을 이용한 자연어 지시 기반 강화학습, 보상 함수 설계 및 세이핑, 고수준 계획 수립, 상태 표현 학습, 세계 모델 구축, 행동 설명 생성 등 구체적인 통합

방식과 관련 연구 결과들을 포함한다. 마지막으로, 본 논문의 실험 환경으로 사용될 MiniGrid 환경의 특징, 이 환경에서의 기존 강화학습 연구 동향, 주요 벤치마크 결과, 그리고 언어 정보 활용 연구 사례 등을 살펴봄으로써 본 연구의 내용을 명확히 한다.

제3장 ‘에이전트 행동 최적화 설계’에서는 본 논문의 핵심 기여로서, LLM 기반 강화학습을 활용하여 MiniGrid 환경에서 에이전트 행동을 최적화하기 위한 구체적인 방법론을 상세하게 제안한다. 실험 대상인 MiniGrid 환경의 세부 설정(상태 공간, 행동 공간, 보상 구조)과 본 연구에서 해결하고자 하는 특정 태스크들(예: 목표 수행)을 명확하게 정의한다. 이어서, LLM과 강화학습 에이전트를 효과적으로 통합하기 위한 시스템 아키텍처를 설계하고, 두 구성 요소 간의 정보 흐름과 상호작용 메커니즘을 구체적으로 기술한다. 제안하는 방법론의 이론적 배경, 핵심 아이디어, 그리고 시스템 구조를 포함한 구현 세부 사항을 제시한다.

제4장 ‘실험 및 결과’에서는 제3장에서 제안된 방법론의 효과와 성능을 객관적으로 검증하기 위해 수행한 포괄적인 실험의 설계 과정과 그 결과를 상세히 보고한다. 먼저, 연구에 사용할 구체적인 LLM 모델과 기반 강화학습 알고리즘을 선정하고 그 이유를 설명한다. 실험에 사용된 MiniGrid 환경의 구체적인 구성, 학습 및 평가 데이터, 그리고 성능 평가를 위한 정량적 지표를 명확하게 명시한다. 제안된 LLM 기반 강화학습 모델의 성능을 전통적인 강화학습 베이스라인 및 관련 비교 모델들과 엄밀하게 비교 분석하고, 최종 성능 수치뿐만 아니라 학습 분석, 에이전트 행동 궤적 시각화 등 정성적인 분석 결과를 함께 제시하여 제안 방법론의 실제 작동 방식, 장단점, 그리고 LLM 통합의 구체적인 효과를 다각적으로 확인한다.

제5장 ‘고찰 및 결론’에서는 제4장의 실험 결과를 바탕으로, 본 연구에서 제안한 LLM 기반 강화학습 방법론의 학문적, 실용적 의미를 심층적으로 논의하고 해석한다. 실험 결과 분석을 통해 LLM 통합이 MiniGrid 환

경에서 에이전트 행동 최적화에 미친 긍정적인 영향을 명확히 밝히고, 이러한 결과의 잠재적 원인을 이론적 근거와 함께 추론한다. 동시에, 본 연구의 한계점을 서술하고, 결과 해석 시 고려해야 할 잠재적 편향이나 주의 사항 등을 객관적으로 고찰한다. 나아가, 본 연구 결과를 바탕으로 향후 개선하거나 확장할 수 있는 구체적인 미래 연구 방향을 제시한다.

제2장 관련연구

제1절. 강화학습의 기본 개념과 알고리즘

1. 강화학습 문제 정의

본 연구는 대규모 언어 모델을 활용하여 MiniGrid 환경에서 강화학습 에이전트의 행동을 최적화하는 것을 목표로 한다. 본 장에서는 연구의 관련된 선행 연구들을 포괄적으로 검토하고 분석한다. 첫째, 강화학습의 핵심 개념과 주요 알고리즘 분류(가치 기반, 정책 기반, 액터-크리틱) 및 심층 강화학습으로의 발전을 상세히 살펴본다. 둘째, 본 연구의 주요 실험 환경인 MiniGrid의 설계 철학, 핵심 특징(부분 관찰성, 희소 보상, 절차적 생성 등), 그리고 이 환경에서 수행된 기존 강화학습 연구들을 조사한다. 셋째, 최근 인공지능 분야의 혁신을 이끌고 있는 대규모 언어 모델의 기본 원리, 주요 아키텍처(트랜스포머), 발전 동향(스케일링 법칙, 창발적 능력 등) 및 다양한 모델 유형을 개괄한다. 마지막으로, LLM을 순차적 의사결정 문제, 특히 강화학습과 통합하려는 최근 연구 동향을 살펴보고 본 연구의 위치를 명확히 한다. 이러한 검토를 통해 본 연구의 독창성과 기여 지점을 명확히 하고, 제안하는 방법론의 이론적 근거를 확립하고자 한다.

강화학습은 에이전트가 환경과의 상호작용을 통해 누적 보상을 최대화하는 행동 정책을 학습하는 머신러닝의 한 분야이다. 이는 명시적인 감독 신호 없이 시행착오를 통해 학습이 이루어진다는 점에서 지도학습이나 비지도학습과 구별된다.

강화학습 문제는 일반적으로 마르코프 결정 과정이라는 수학적 프레임워크를 사용하여 형식화된다. 마르코프 결정 과정은 환경과 에이전트 간의 상호작용을 모델링하는 데 사용되며, 다음과 같은 요소들로 구성된 튜플 $(S,$

A, P, R, γ)로 정의된다.

첫째, 상태 공간 (S , State Space) 은 에이전트가 처할 수 있는 모든 가능한 상황의 집합이다. 각 상태 $s \in S$ 는 환경의 특정 구성을 나타내며, 상태 공간은 유한하거나 무한할 수 있고, 이산적이거나 연속적일 수 있다.

둘째, 행동 공간 (A , Action Space) 은 에이전트가 각 상태에서 취할 수 있는 모든 가능한 행동의 집합이다. 행동 $a \in A$ 는 에이전트의 선택을 나타내며, 행동 공간 역시 유한/무한, 이산적/연속적일 수 있다.

셋째, 상태 전이 확률 함수 (P , State Transition Probability Function) 는 $P(s' | s, a)$ 로 표기되며, 현재 상태 s 에서 행동 a 를 취했을 때 다음 상태가 s' 이 될 확률을 정의한다 ($P: S \times A \times S \rightarrow [0, 1]$). MDP(Markov Decision Process)의 핵심 가정인 마르코프 속성은 다음 상태의 확률 분포가 오직 현재 상태와 현재 행동에만 의존하며, 그 이전의 상태나 행동 이력과는 무관하다는 것을 의미한다. 넷째, 보상 함수 (R , Reward Function) 는 $R(s, a, s')$ 으로 표현되며, 상태 s 에서 행동 a 를 취하여 다음 상태 s' 으로 전이했을 때 에이전트가 즉시 받는 스칼라 보상을 나타낸다. 이 보상은 에이전트 행동의 즉각적인 좋고 나쁨을 평가하는 기준이 되며, 에이전트 학습 목표의 기반을 형성한다. 때로는 보상이 다음 상태 s' 에 의존하지 않고 $R(s, a)$ 형태로 주어지거나, 심지어 상태 s 에만 의존하는 $R(s)$ 형태로 정의되기도 한다.

마지막으로, 할인율 (γ , Discount Factor) 은 0과 1 사이의 값($\gamma \in [0, 1]$)을 가지는 하이퍼파라미터로, 미래 보상의 현재 가치를 결정한다.

γ 값이 0에 가까우면 에이전트는 즉각적인 보상에 더 집중하게 되고, 1에 가까우면 장기적인 미래 보상을 더 중요하게 고려하게 된다. 또한, 할인율은 무한한 시간 지평을 갖는 문제에서 누적 보상이 무한히 커지는 것을 방지하는 수학적 역할도 수행한다. 강화학습 에이전트의 목표는 주어진 MDP 환경 내에서 정책(policy) π 를 학습하는 것이다. 정책 π 는 특정 상태 s 에서 에이전트가 행동 a 를 선택할 확률 분포 $\pi(a|s)$ 로 정의된다. 결

정론적 정책의 경우에는 특정 상태 s 에 대해 특정 행동 a 를 매핑하는 함수 $\pi(s)$ 로 표현될 수 있다.

에이전트는 학습된 정책 π 에 따라 행동하며 시간 스텝 $t=0$ 부터 시작하여 상태-행동-보상 시퀀스($s_0, a_0, r_1, s_1, a_1, r_2, s_2, a_2, r_3, s_3, \dots$)를 경험하게 된다.

에이전트가 궁극적으로 추구하는 목표는 기대 누적 할인 보상(expected cumulative discounted reward), 즉 반환 값 G_t 의 기댓값을 최대화하는 것이다. 특정 시점 t 에서의 반환 값 G_t 는 해당 시점 이후부터 받을 보상들의 할인된 총합으로 식(1)과 같이 정의된다.

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}. \quad (1)$$

따라서 강화학습의 핵심 과제는 이러한 반환 값의 기댓값을 최대화하는 최적 정책(optimal policy) π 을 찾는 것이다. 최적 정책을 찾기 위해, 에이전트는 종종 가치 함수를 학습하거나 정책 자체를 직접 최적화하는 방법을 사용한다. 주요 가치 함수는 다음과 같다.

식(2)의 상태 가치 함수 $V^\pi(s)$ 는 정책 π 를 따를 때, 상태 s 에서 시작하여 미래에 받을 것으로 기대되는 누적 할인 보상이다.

$$V^\pi(S) = E_\pi[G_t | S_t = s] = E_\pi\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s\right]. \quad (2)$$

식(3)의 행동 가치 함수 $Q^\pi(s, a)$ 는 정책 π 를 따를 때, 상태 s 에서 행동 a 를 취한 후 미래에 받을 것으로 기대되는 누적 할인 보상이다.

$$Q^\pi(s, a) = E_\pi[G_t | S_t = s, A_t = a] = E_\pi\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s, A_t = a\right]. \quad (3)$$

최적 가치 함수 $V(s)$ 와 $Q(s,a)$ 는 모든 가능한 정책 중에서 가장 큰 가치 함수 값을 의미한다. 특히, 최적 행동 가치 함수 $Q^\pi(s,a)$ 를 알게 되면, 각 상태 s 에서 $Q^\pi(s,a)$ 값을 최대화하는 행동 a 를 선택함으로써 최적 정책 π 를 도출할 수 있다.

이러한 가치 함수들은 벨만 방정식이라는 중요한 재귀적 관계를 만족한다. 특정 정책 π 에 대한 벨만 기대 방정식은 현재 상태에서의 가치를 즉각적인 보상과 다음 상태에서의 기대 가치로 표현한다. 식(4)은 상태가치 함수와 식(5)는 행동가치 함수를 나타낸다.

$$V(s) = \sum_a \pi(a|s) \sum_{s'} P(s'|s,a) [R(s,a,s') + \gamma V(s')], \quad (4)$$

$$Q(s,a) = \sum_{s'} P(s'|s,a) [R(s,a,s') + \gamma \sum_{a'} \pi(a'|s') Q(s',a')]. \quad (5)$$

최적 정책에 대한 벨만 최적 방정식은 다음과 같이 주어진다. 식(6)은 최적상태가치함수와 식(7)는 최적행동가치함수를 나타낸다.

$$V^*(s) = \max_a \sum_{s'} P(s'|s,a) [R(s,a,s') + \gamma V^*(s')], \quad (6)$$

$$Q^*(s,a) = \sum_{s'} P(s'|s,a) [R(s,a,s') + \gamma \max_{a'} Q^*(s',a')]. \quad (7)$$

대부분의 강화학습 알고리즘들은 이러한 벨만 방정식을 기반으로 반복적으로 가치 함수를 추정하거나 정책을 개선해 나가는 방식으로 작동한다.

마지막으로, 강화학습 에이전트는 학습 과정에서 중요한 탐험과 활용의 딜레마(Exploration-Exploitation Dilemma)에 직면한다. 에이전트는 현재

까지의 경험을 바탕으로 가장 좋다고 알려진 행동을 선택하여 높은 보상을 얻으려는 활용과 아직 잘 알지 못하는 상태나 행동을 시도하여 더 나은 정책을 발견하려는 ‘탐험’ 사이에서 균형을 맞춰야 한다. 지나친 활용은 최적이지 아닌 정책에 머무르게 할 위험이 있고, 지나친 탐험은 학습 속도를 늦추고 불필요한 비용(예: 낮은 보상)을 발생시킬 수 있다. 이 딜레마를 해결하기 위해 ϵ -greedy, UCB(Upper Confidence Bound), Thompson sampling 등 다양한 탐험 전략들이 연구되었다.

2. 가치 기반 방법(Value-Based Methods)

가치 기반 방법은 최적 행동 가치 함수 $Q^*(s,a)$ 를 추정하고, 이를 이용하여 암묵적으로 최적 정책을 유도하는 방식이다. 즉, 학습된 Q 함수를 바탕으로 각 상태에서 Q 값이 가장 높은 행동을 선택하는 탐욕적 정책(greedy policy)을 사용한다.

가. Q-러닝 (Q-Learning)

대표적인 모델 프리(model-free), 오프 폴리시(off-policy) 시간차 학습(Temporal Difference, TD) 알고리즘이다[55]. 모델 프리는 환경의 전이 확률 P 나 보상 함수 R 를 알 필요 없이 경험(s, a, r, s')을 통해 학습한다는 의미이고, 오프 폴리시는 현재 데이터를 생성하는 데 사용된 행동 선택 정책(behavior policy, 예: ϵ -greedy)과 학습 대상이 되는 목표 정책(target policy, 예: greedy policy)이 다를 수 있음을 의미한다. Q-러닝은 다음 상태 s' 에서의 최대 Q 값을 이용하여 현재 상태-행동 쌍 (s, a) 의 Q 값을 업데이트한다. 업데이트 규칙은 식(8)과 같다.

$$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \max_{a'} Q(s',a') - Q(s,a)]. \quad (8)$$

여기서 α 는 학습률(learning rate)이다. Q-러닝은 적절한 조건 하에서 최적 행동 가치 함수 $Q^*(s,a)$ 로 수렴함이 증명되었다.

나. 심층 Q-네트워크 (Deep Q-Network, DQN)

Q-러닝을 심층 신경망과 결합하여 고차원 상태 공간(예: 이미지) 문제를 해결한 알고리즘이다. DQN은 다음과 같은 주요 기법들을 도입하여 학습 안정성을 높였다.

경험 리플레이 (Experience Replay): 에이전트의 경험 (s, a, r, s') 튜플을 리플레이 버퍼에 저장해두고, 학습 시 버퍼에서 무작위로 샘플링한 미니배치(mini-batch)를 사용하여 신경망을 업데이트한다. 이는 데이터 샘플 간의 시간적 상관관계를 깨뜨려 학습을 안정화하고 데이터 사용 효율을 높인다. 식(9)은 타겟 네트워크 분리(TD 타겟)를 나타낸다.

$$y = r + \gamma \max_{a'} Q(s', a'; \theta^-). \quad (9)$$

식(9)를 계산할 때 사용하는 Q-네트워크(타겟 네트워크, 파라미터 θ^-)를 현재 업데이트되는 Q-네트워크(파라미터 θ)와 분리한다. 타겟 네트워크의 파라미터는 일정 주기마다 현재 Q-네트워크의 파라미터로 복사되어 업데이트된다. 이는 TD 타겟 값의 변화를 줄여 학습 진동을 억제하고 안정성을 향상시킨다.

DQN은 아타리 2600 게임 환경에서 인간 수준의 성능을 달성하며 심층 강화학습의 가능성을 입증했다. 이후 DQN을 개선하기 위한 다양한 변형 알고리즘들이 제안되었다. 예를 들어, Double DQN은 Q 값 과대 추정 문제를 완화하기 위해 행동 선택과 가치 평가에 서로 다른 네트워크를 사용하며, Dueling DQN은 상태 가치 $V(s)$ 와 행동별 어드밴티지 $A(s, a)$ 를 분리하여 학습함으로써 Q값 추정의 효율성을 높인다.

Prioritized Experience Replay는 TD 오차가 큰 중요한 경험을 더 자주

샘플링하여 학습 효율을 개선한다.

가치 기반 방법은 개념적으로 비교적 간단하고 샘플 효율성이 좋은 경우가 많지만, 연속적인 행동 공간을 다루기 어렵고, 확률적 정책을 직접 학습하기 어렵다는 단점이 있다.

3. 정책 기반 방법(Policy-Based Methods)

정책 기반 방법은 가치 함수를 매개하지 않고 정책 $\pi(a|s; \theta)$ 자체를 직접 파라미터 θ 로 모델링하고 최적화하는 접근 방식이다. 정책 함수의 파라미터를 업데이트하여 성능 지표 $J(\theta)$ (예: 시작 상태에서의 기대 반환 값)를 개선하는 방향으로 학습을 진행한다.

가. 정책 경사 정리 (Policy Gradient Theorem)

정책 기반 방법의 핵심 이론으로, 성능 지표 $J(\theta)$ 의 파라미터 θ 에 대한 경사(gradient)가 식(10)과 같이 표현될 수 있음을 보인다[56].

$$\nabla_{\theta} J(\theta) = E_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s) Q^{\pi_{\theta}}(s, a)]. \quad (10)$$

이 정리는 $Q^{\pi_{\theta}}(s, a)$ 의 경사를 계산할 필요 없이, 정책 $\pi_{\theta}(a|s)$ 의 경사만을 이용하여 전체 성능 지표의 경사를 추정할 수 있게 해준다. 직관적으로, 이 경사는 Q 값이 높은 행동 a 의 선택 확률 $\log \pi_{\theta}(a|s)$ 의 경사를 증가시키고, Q 값이 낮은 행동의 선택 확률 경사는 감소시키는 방향으로 정책 파라미터를 업데이트하도록 유도한다.

나. 강화학습(Reinforce) 알고리즘

몬테카를로 정책 경사(Monte Carlo Policy Gradient) 방법의 가장 기본적인 형태이다[57]. 에피소드(episode) 전체를 실행하여 얻은 실제 반환 값 G_t 를 $Q^{\pi_\theta}(s_t, a_t)$ 의 추정치로 사용하여 정책 파라미터를 업데이트한다.

$$\theta \leftarrow \theta + \alpha \nabla_{\theta} \log_{\pi_{\theta}}(a_t | s_t) G_t. \quad (11)$$

몬테카를로 정책 경사는 구현이 간단하지만, 몬테카를로 추정치 G_t 의 분산이 매우 커서 학습이 불안정하고 수렴이 느릴 수 있다는 단점이 있다.

4. 액터-크리틱 방법(Actor-Critic Methods)

액터-크리틱 방법은 가치 기반 방법과 정책 기반 방법의 장점을 결합한 형태이다 [58]. 이 구조는 두 개의 구성 요소로 이루어진다.

액터(Actor)는 현재 정책 $\pi_{\theta}(a|s)$ 를 파라미터 θ 로 표현하고 업데이트하며, 어떤 행동을 취할지 결정한다. 정책 기반 방법과 유사하게 정책 경사를 따라 파라미터를 업데이트한다.

크리틱(Critic)은 액터가 따르는 현재 정책 π_{θ} 하에서의 가치 함수(주로 상태 가치 함수 $V(s)$ 또는 행동 가치 함수 $Q(s, a)$ 를 파라미터 w 로 추정하고 업데이트한다. 크리틱은 액터가 생성한 행동의 좋고 나쁨을 ‘비평’하는 역할을 한다.

크리틱이 추정한 가치 함수는 액터의 정책 경사를 계산하거나 분산을 줄이는 데 사용된다. 예를 들어, 어드밴티지 함수 $A(s, a) = Q(s, a) - V(s)$ 를 추정하여 정책 경사 업데이트에 사용할 수 있다. 시간차(TD) 오차는 식(12)와 같이 나타낸다.

$$\delta_t = r_{t+1} + \gamma V(s_{t+1}) - V(s_t). \quad (12)$$

어드밴티지 함수의 한 스텝 추정치로 사용될 수 있으며, 이를 이용하여 액터와 크리틱을 동시에 업데이트한다. 식(13)은 크리틱 업데이트(TD 학습)과 식(14)은 액터 업데이트(정책 경사)를 나타낸다.

$$w \leftarrow w + \alpha_w \delta_t \nabla_w V_w(s_t), \quad (13)$$

$$\theta \leftarrow \theta + \alpha_\theta \nabla_\theta \log_{\pi_\theta}(a_t | s_t) \delta_t. \quad (14)$$

어드밴티지 액터-크리틱(Advantage Actor-Critic, A2C)와 비동기적 어드밴티지 액터-크리틱 (Asynchronous Advantage Actor-Critic, A3C)는 여러 개의 에이전트가 각자 환경의 복사본과 상호작용하며 비동기적으로 파라미터를 업데이트하는 병렬 학습 구조를 제안하여 학습 속도와 안정성을 크게 향상 시켰다. A2C는 A3C의 동기적 버전으로 구현이 더 간단하면서도 유사한 성능을 보이는 경우가 많다. 이들은 TD 오차를 어드밴티지 추정치로 사용한다.

- ① 심층 결정론적 정책 경사 : 연속 행동 공간 문제를 위한 액터-크리틱 알고리즘이다[59]. DQN의 아이디어를 연속 행동 공간으로 확장하여, 액터(결정론적 정책 $\mu_\theta(s)$)와 크리틱(행동 가치 함수 $Q_w(s,a)$) 모두 심층 신경망으로 근사하고, 경험 리플레이와 타겟 네트워크 분리 기법을 사용한다.
- ② Twin Delayed DDPG (TD3) : DDPG의 성능을 개선하기 위해 Q값 과대 추정 문제와 학습 불안정성 문제를 해결하는 여러 기법(clipped double Q-learning, delayed policy updates, target policy smoothing)을 도입했다[60].
- ③ Soft Actor-Critic (SAC) : 최대 엔트로피 강화학습(Maximum

Entropy RL) 프레임워크를 기반으로 하는 최첨단 액터-크리틱 알고리즘이다[61]. 목표 함수에 정책의 엔트로피 항을 추가하여 탐험을 장려하고 견고성을 높인다. 즉, 누적 보상뿐만 아니라 정책의 무작위성(엔트로피)도 함께 최대화하려고 시도한다. SAC는 샘플 효율성이 높고 하이퍼파라미터 설정에 비교적 덜 민감하여 다양한 연속 제어 문제에서 뛰어난 성능을 보인다.

액터-크리틱 방법은 현재 많은 강화학습 문제에서 가장 강력하고 널리 사용되는 접근 방식 중 하나로, 가치 기반과 정책 기반 방법의 장점을 효과적으로 결합한다.

5. 심층 강화학습 (Deep Reinforcement Learning, DRL)

위에서 소개한 DQN, 정책 경사, 액터-크리틱 방법들에 DNN을 함수 근사기(function approximator)로 사용하는 것을 통칭하여 DRL이라고 부른다. DNN은 고차원의 원시 입력(raw input, 예: 이미지, 센서 데이터)으로부터 유용한 특징(feature)을 자동으로 추출하고, 복잡한 비선형 함수(가치 함수, 정책 함수)를 효과적으로 근사할 수 있게 해준다. 이로 인해 강화학습의 적용 범위가 이전에는 다루기 어려웠던 로봇 공학, 게임, 자율주행 등 복잡한 실제 문제들로 크게 확장되었다.

그러나 DRL은 여전히 높은 샘플 비효율성, 학습 불안정성, 하이퍼파라미터 민감성, 일반화 능력 부족 등 해결해야 할 과제들을 안고 있으며, 이를 개선하기 위한 연구가 지속적으로 이루어지고 있다.

제2절. MiniGrid 환경

1. MiniGrid 환경과 그 특성

본 연구의 실험 환경으로 사용될 MiniGrid는 OpenAI Gym 인터페이스를 따르는 간단하면서도 유연한 그리드 월드 환경 모음이다. 이는 강화학습, 특히 계층적 강화학습, 장기 기억, 희소 보상 및 일반화와 관련된 연구를 위해 설계되었다.

2. 개요 및 설계 철학

MiniGrid는 Farama Foundation (이전 OpenAI)의 Gymnasium (구 Gym) API 표준을 준수하는 환경으로, 파이썬으로 쉽게 설치하고 사용할 수 있다. 설계 철학은 다음과 같은 목표를 가진다.

- ① 최소주의 : 환경의 규칙과 시각적 표현이 매우 간단하여 이해하고 디버깅하기 쉽다.
- ② 속도 : 환경의 시뮬레이션 속도가 매우 빨라 대규모 실험과 빠른 프로토타이핑이 가능하다. CPU(Central Processing Unit) 기반으로 작동하며 GPU(Graphics Processing Unit)가 필요없다.
- ③ 유연성 및 확장성 : 새로운 그리드 객체, 환경, 태스크 목표를 쉽게 추가하고 커스터마이징할 수 있는 모듈식 구조를 가진다.
- ④ 절차적 생성 : 다양한 난이도와 구성을 가진 무한히 많은 레벨을 자동으로 생성할 수 있어, 에이전트의 일반화 능력을 평가하는 데 적합하다.

MiniGrid 환경은 기본적으로 2차원 그리드로 구성되며, 각 셀은 비어 있거나 벽, 문, 열쇠, 공, 상자 등 특정 객체를 포함할 수 있다. 에이전트는 이 그리드 내에서 특정 목표를 달성하기 위해 행동한다.

3. 주요 특징

MiniGrid 환경은 강화학습 연구에서 중요한 몇 가지 특징 및 도전 과제를 내포하고 있다.

- ① 그리드 기반 상태 표현 : 환경 상태는 기본적으로 그리드 형태로 표현된다. 각 셀의 타입과 상태(예: 문의 색상, 잠김 여부) 정보가 포함된다. 이는 이산적인 상태 공간을 가지지만, 그리드 크기가 커지거나 객체 종류가 다양해지면 상태 공간의 조합적 폭발이 발생할 수 있다.
- ② 부분 관찰성 : 에이전트는 일반적으로 전체 그리드 맵을 볼 수 없고, 자신이 향하는 방향으로 일정 범위(예: 7x7 크기)의 영역만을 볼 수 있는 자기 중심적 시점 만을 관찰로 받는다. 이는 실제 로봇이나 인간과 같이 제한된 시야를 가진 상황을 모방한다. 따라서 에이전트는 현재 관찰만으로는 완전한 환경 상태를 알 수 없으며 (관찰 $\neq$ 상태), 과거의 관찰 정보를 기억하고 통합하여 현재 상태를 추론해야 한다. 이는 순환 신경망(RNN)이나 LSTM(Long Short-Term Memory), GRU(Gated Recurrent Unit)와 같은 메모리 구조를 가진 정책/가치 네트워크 사용을 필요로 한다.
- ③ 희소 보상 : 많은 MiniGrid 태스크에서 에이전트는 최종 목표를 달성했을 때만 양(+)의 보상을 받고, 그 외의 모든 스텝에서는 0 또는 작은 음(-)의 보상을 받는다. 이러한 희소 보상 환경에서는 에이전트가 우연히 목표를 달성하기 전까지는 어떤 행동이 좋은지에 대한 피드백을 거의 받지 못하므로, 의미 있는 학습 신호를 얻기 어렵고 효율적인 탐험 전략이 매우 중요하다. 이는 내재적 동기 부여나 계층적 강화학습과 같은 접근법의 필요성을 부각 시킨다.
- ④ 절차적 콘텐츠 생성 : MiniGrid의 핵심 기능 중 하나는 각 에피소드가 시작될 때마다 환경의 레이아웃(방의 구조, 문의 위치), 객체의

종류와 위치, 에이전트의 시작 위치 등을 무작위로 생성하는 것이다. 사용자는 생성 파라미터(예: 그리드 크기, 방의 개수)를 조절하여 난이도를 제어할 수 있다. 절차적 콘텐츠 생성은 에이전트가 특정 레벨에 과적합 되는 것을 방지하고, 학습된 정책이 이전에 보지 못한 새로운 환경에서도 잘 작동하는지, 즉 일반화 성능을 평가하는 데 필수적이다. 이는 실제 세계의 다양성과 불확실성에 대처할 수 있는 강인한 에이전트를 개발하는 데 중요하다.

- ⑤ 이산적 행동 공간 : 에이전트가 취할 수 있는 행동은 일반적으로 7가지의 이산적인 행동으로 구성된다. turn_left (왼쪽으로 90도 회전), turn_right (오른쪽으로 90도 회전), move_forward (앞으로 한 칸 이동), pickup (앞에 있는 휴대 가능한 객체 줍기), drop (들고 있는 객체 내려놓기), toggle (앞에 있는 문이나 상자 열기/닫기/상호작용), done (태스크 완료 선언 - 일부 태스크에서 사용)

4. 공통 태스크 및 벤치마크

MiniGrid는 다양한 난이도와 목표를 가진 여러 내장 환경을 제공한다.

<표2-1> Key Tasks in MiniGrid

Tasks	Explanation
Empty	Moving to a specific location in an empty room.
DoorKey	In an environment with a locked door and its corresponding key, the agent's task is to pick up the key, unlock the door, and navigate to a goal location, which requires sequentially finding the key and the door under partial observability.
Workspace	The task requires an agent to navigate to a specific room, retrieve a ball of a particular color, and return it to its starting position, demanding capabilities in object identification, exploration, and memory.
GoToDoor	Navigate to a door of a specific color.
PutNear	Pick and place a specific object beside another one. This task demands object manipulation and spatial awareness.
MultiRoom	An environment where multiple rooms are connected by a corridor. The difficulty can be adjusted with factors like the number of rooms (N) and the number of door-key pairs (S).

이 외에도 KeyCorridor, ObstructedMaze, BlockedUnlockPickup 등 더 복잡하고 조합적인 목표를 가진 태스크들이 있다. 이러한 환경들은 부분 관찰성, 희소 보상, 절차적 생성 등 강화학습의 주요 난제들을 다양한 조합으로 제시하여 알고리즘의 성능을 체계적으로 평가하는 벤치마크로 활용된다.

5. MiniGrid 환경에서의 선행 연구

MiniGrid는 그 특성상 다양한 강화학습 연구 분야에서 널리 사용되어 왔다.

- ① 부분 관찰성 극복 : 에이전트의 제한된 시야 문제를 해결하기 위해 LSTM [62]이나 GRU [63]와 같은 RNN을 정책 네트워크에 통합하여 과거 정보를 기억하고 활용하는 연구가 일반적이다. 또한, 환경의 숨겨진 상태를 추론하는 Belief-based RL 접근법이나 Attention 메커니즘을 활용하는 연구도 시도되었다.
- ② 희소 보상 문제 해결 : 탐험 효율성을 높이기 위해 내재적 동기 부여 기반 방법들이 MiniGrid에서 활발히 연구되었다. 예를 들어, 새로운 상태 방문을 장려하는 카운트 기반 탐험, 예측 오류를 보상으로 사용하는 호기심 기반 탐험, 무작위 네트워크 증류(Random Network Distillation, RND) 등이 MiniGrid 환경에서 효과를 보였다. 계층적 강화학습(Hierarchical RL)을 통해 고수준의 목표(예: ‘열쇠 찾기’)와 저수준의 행동(예: ‘앞으로 가기’)을 분리하여 학습 효율을 높이려는 시도도 있었다[64].
- ③ 일반화 성능 향상 : MiniGrid의 절차적 생성 능력을 활용하여 학습 시 보지 못했던 새로운 레벨에서의 성능, 즉 일반화 능력을 측정하는 것이 중요한 평가 기준이 되었다. 이를 위해 데이터 증강, 도메인 무작위화와 유사한 기법들이 적용되거나, 환경의 구조적 정보를 활용

하는 Graph Neural Network (GNN) 기반 접근법 등이 연구되었다. Cobbe et al. (2019)은 대규모 절차적 생성 환경에서 DRL 알고리즘의 일반화 성능을 체계적으로 평가하는 벤치마크를 제안했으며, MiniGrid 역시 이러한 연구 흐름에 기여하고 있다.

- ④ 언어 지시 기반 학습 : MiniGrid 환경은 자연어 지시를 이해하고 그에 따라 행동하는 에이전트를 연구하기 위한 플랫폼으로도 확장되었다. 대표적인 예가 BabyAI[65] 플랫폼이다.

BabyAI는 MiniGrid를 기반으로 구축되었으며, 에이전트에게 “Go to the red ball”이나 “Pick up the key and open the door”와 같은 간단한 형식의 자연어 지시를 제공하고, 에이전트가 이 지시를 성공적으로 수행하도록 학습시키는 것을 목표로 한다. 이는 언어 이해와 시각적 그라운드링, 계획 수립 능력을 통합적으로 요구하는 도전적인 과제이다. BabyAI 연구에서는 모방 학습과 강화학습을 결합하거나, 주의 메커니즘을 활용하여 언어 지시와 시각적 관찰 사이의 연관성을 학습하는 모델들이 제안되었다.

이처럼 MiniGrid는 강화학습의 핵심적인 난제들을 연구하고 알고리즘을 평가하는 데 유용한 환경이며, 특히 본 연구의 목표인 LLM 기반 강화학습 에이전트의 행동 최적화, 특히 언어적 정보를 활용한 성능 향상 가능성을 탐구하기에 적합한 배경을 제공한다.

6. 대규모 언어 모델(LLM)의 개요 및 최근 발전

LLM은 최근 몇 년간 인공지능 분야에서 가장 큰 주목을 받으며 괄목할 만한 발전을 이룬 기술이다. LLM은 방대한 양의 텍스트 데이터로 사전 학습된 수십억 개 이상의 파라미터를 가진 심층 신경망 모델을 지칭하며, 인간 언어를 이해하고 생성하는 능력에서 전례 없는 성능을 보여주고 있다.

가. 기반 기술: 트랜스포머 아키텍처

현대 LLM의 성공은 2017년 Google 연구팀이 발표한 “Attention Is All You Need” 논문에서 제안된 트랜스포머(Transformer) 아키텍처에 크게 힘입고 있다. 트랜스포머는 기존의 순환 신경망(RNN)이나 합성곱 신경망(CNN)을 사용하지 않고, 셀프 어텐션 메커니즘만을 기반으로 시퀀스 데이터를 처리하는 혁신적인 구조를 제시했다.

- ① 셀프 어텐션 : 시퀀스 내의 각 단어(토큰)가 다른 모든 단어들과의 관련성을 계산하고, 이 관련성에 따라 다른 단어들의 정보를 가중 평균하여 해당 단어의 문맥적 표현을 생성하는 메커니즘이다. 이를 통해 문장 내 단어들 간의 장거리 의존성을 효과적으로 포착할 수 있다. 예를 들어, “그 동물은 길을 건너지 않았다. 왜냐하면 너무 피곤했기 때문이다.(The animal didn't cross the road because it was too tired.)” 라는 문장에서 ‘그것(it)’이 ‘동물(animal)’을 지칭한다는 것을 RNN보다 훨씬 쉽게 파악할 수 있다.
- ② 멀티 헤드 어텐션 : 셀프 어텐션을 여러 개의 ‘헤드’로 병렬적으로 수행하고 그 결과를 결합하는 방식이다. 각 헤드는 서로 다른 관점에서 단어 간의 관계를 학습하므로, 모델이 다양한 종류의 문맥적 정보를 동시에 포착할 수 있게 해준다.
- ③ 위치 인코딩 : 트랜스포머는 순환 구조가 없기 때문에 단어의 순서 정보를 별도로 주입해주어야 한다. 위치 인코딩은 각 단어의 절대적 또는 상대적 위치 정보를 벡터 형태로 표현하여 입력 임베딩에 더해준다.
- ④ 인코더-디코더 구조 : 원래 트랜스포머는 기계 번역과 같은 시퀀스-투-시퀀스 태스크를 위해 인코더와 디코더 스택으로 구성되었다. 인코더는 입력 시퀀스를 처리하여 문맥 정보를 담은 표현을 만들고, 디코더는 인코더의 출력과 이전에 생성된 출력 토큰을 기반으로 타겟 시퀀스를 생성한다. 이후 LLM들은 이 구조 전체를 사용하거나

(예: T5, BART), 인코더 부분만을 사용하거나(예: BERT), 디코더 부분만을 사용하여(예: GPT) 특정 목적에 맞게 발전해 왔다.

트랜스포머 아키텍처는 뛰어난 성능과 함께 병렬 처리 능력(GPU 활용 용이)이 우수하여, 이전 모델들보다 훨씬 더 큰 모델과 데이터셋으로 확장하는 것을 가능하게 했고, 이는 LLM의 폭발적인 발전을 촉발하는 핵심 동력이 되었다.

나. 사전 학습 패러다임

LLM의 핵심적인 학습 전략은 사전 학습(pre-training) 과 미세 조정(fine-tuning) 이라는 두 단계로 구성된다.

① 사전 학습 : 이 단계에서는 모델이 대규모의 레이블 없는 텍스트 코퍼스(예: 웹 페이지, 책, 위키피디아)를 이용하여 언어 자체의 통계적 패턴, 문법, 의미, 그리고 세상에 대한 지식을 학습한다. 이는 자기 지도 학습 방식으로 이루어지며, 별도의 레이블링 작업 없이 텍스트 데이터 자체로부터 학습 신호를 생성한다. 주요 사전 학습 목표는 다음과 같다.

(가) 마스크된 언어 모델링 : BERT 에서 사용된 방식으로, 입력 문장의 일부 토큰을 무작위로 마스킹하고, 주변 문맥을 이용하여 원래 토큰을 예측하도록 모델을 학습시킨다. 이는 모델이 양방향 문맥을 깊이 이해하는 능력을 길러준다.

(나) 인과적 언어 모델링 / 다음 토큰 예측 : GPT 계열 모델에서 주로 사용되는 방식으로, 주어진 텍스트 시퀀스에서 다음에 올 토큰을 예측하도록 모델을 학습시킨다. 이는 모델이 자연스러운 텍스트를 생성하는 능력을 길러준다.

(다) 텍스트-투-텍스트 : T5 모델은 모든 NLP 태스크를 입력 텍스트 시퀀스를 받아 출력 텍스트 시퀀스를 생성하는 통일된 형식으로 변환하여 학습한다. 예를 들어, 번역 태스크는 "translate

English to German: That is good.”이라는 입력을 받아 “Dasist gut.”이라는 출력을 생성하도록 학습한다.

- ② 미세 조정 : 사전 학습된 범용 언어 모델을 특정 다운스트림 태스크 (예: 감성 분석, 질의응답, 요약)에 맞게 추가로 학습시키는 단계이다. 이 단계에서는 해당 태스크에 특화된 비교적 작은 규모의 레이블된 데이터셋을 사용하여 모델 파라미터 전체 또는 일부를 업데이트한다. 이를 통해 모델은 사전학습으로 얻은 일반적인 언어 능력을 특정 태스크 수행에 필요한 지식 및 기술과 결합하여 높은 성능을 달성한다. 최근에는 파라미터 효율적 미세 조정 기법들(예: Adapter [66], LoRA [67])이 주목받고 있는데, 이는 사전 학습된 거대 모델의 파라미터 대부분은 고정된 채 소수의 추가 파라미터만을 학습시켜 계산 비용과 메모리 사용량을 크게 줄이면서도 준수한 성능을 얻는 방법이다.

다. 스케일링 법칙과 창발적 능력

LLM 연구에서 중요한 발견 중 하나는 모델의 성능이 세 가지 요소, 즉 모델 크기(파라미터 수), 데이터셋 크기, 그리고 학습에 사용된 컴퓨팅 양에 따라 예측 가능한 방식으로 향상된다는 스케일링 법칙이다. 구체적으로, 이 세 요소 중 병목이 되는 요소가 없을 때, 모델의 손실은 각 요소의 크기가 지수적으로 증가함에 따라 로그-선형적으로 감소하는 경향을 보인다. 이 발견은 단순히 모델과 데이터를 확장하는 것이 성능 향상의 핵심 전략임을 시사했으며, LLM의 규모를 수백억, 수천억, 심지어 수조 파라미터 수준까지 경쟁적으로 늘리는 추세를 이끌었다.

모델 규모가 특정 임계점을 넘어서면서, 작은 모델에서는 나타나지 않거나 예측하기 어려웠던 새로운 능력들이 갑자기 발현되는 창발적 능력 현상이 관찰되었다. 이러한 능력들은 모델 크기가 커짐에 따라 점진적으로 향상되는 것이 아니라, 특정 규모 이상에서 비선형적으로 급격히 나타나는 특징을 보인다. 대표적인 예는 다음과 같다.

- ① 인컨텍스트 학습 : 별도의 파라미터 업데이트 없이 프롬프트에 몇 개의 예시나 설명만 제공해도 새로운 작업을 수행하는 능력.
- ② 단계별 추론 : 복잡한 추론 문제(예: 수학 응용 문제, 상식 추론)를 풀 때, 중간 추론 과정을 단계별로 생성하도록 유도하면 최종 답변의 정확도가 크게 향상되는 능력[68].
- ③ 지시 따르기 : 자연어로 주어진 다양한 지시사항을 이해하고 그에 맞게 적절한 응답이나 행동을 생성하는 능력. 이는 지시 튜닝[69]과 같은 기법을 통해 더욱 강화될 수 있다.
- ④ 코드 생성 및 이해: 자연어 설명으로부터 복잡한 프로그래밍 코드를 생성하거나 코드의 버그를 찾는 능력.

이러한 창발적 능력의 정확한 메커니즘은 아직 완전히 규명되지 않았지만, LLM이 단순한 패턴 매칭을 넘어선 복잡한 인지 및 추론 능력을 학습할 수 있음을 시사하며 LLM의 활용 가능성을 크게 확장 시키고 있다.

라. 주요 LLM 모델군 및 최신 동향

지난 몇 년간 다양한 기관에서 각기 다른 특징과 강점을 가진 LLM들을 개발하여 발표했다.

- ① BERT (Bidirectional Encoder Representations from Transformers) : Google AI [26]. 인코더 전용 모델의 시대를 열었으며, NLU 벤치마크에서 큰 성능 향상을 가져왔다. RoBERTa, ALBERT, ELECTRA 등 다양한 변형 모델이 있다.
- ② GPT (Generative Pre-trained Transformer) : OpenAI. 디코더 전용 모델의 대표 주자. GPT-2, GPT-3, GPT-4로 발전하면서 모델 규모를 크게 확장하고 인컨텍스트 학습, 창발적 능력 등에서 놀라운 성능을 보여주었다[47, 48, 23, 29]. ChatGPT는 GPT 모델을 대화형으로 미세 조정한 것이다.
- ③ T5 (Text-to-Text Transfer Transformer) : Google AI . 인코더-디

코더 모델로, 모든 NLP 태스크를 텍스트-투-텍스트 형식으로 통일하여 처리하는 프레임워크를 제안했다.

- ④ LLaMA (Large Language Model Meta AI) : Meta AI . 비교적 작은 크기(7B~65B 파라미터)로도 뛰어난 성능을 보이며, 연구 커뮤니티에 모델 가중치를 공개(초기 버전)하여 오픈 소스 LLM 생태계 활성화에 크게 기여했다. Llama 2, Llama 3로 발전하고 있다.
- ⑤ PaLM (Pathways Language Model) / PaLM 2 / Gemini: Google Pathways 아키텍처를 기반으로 모델 규모를 540B 파라미터까지 확장했으며, 추론 및 코드 생성 능력이 뛰어나다[51, 52]. Gemini는 텍스트, 이미지, 오디오, 비디오 등 다양한 양식(modality)을 통합적으로 처리하는 멀티모달(multimodal) 모델로 개발되었다.
- ⑥ Claude : Anthropic. AI 안전성과 유용성, 정직성을 높이는 데 중점을 두고 개발되었다[53]. Constitutional AI라는 기법을 통해 유해한 응답을 피하도록 학습한다.

최근 LLM 연구는 단순히 모델 규모를 키우는 것을 넘어, 다음과 같은 방향으로 발전하고 있다.

- ① 효율성 증대 : 더 작은 모델로도 높은 성능을 내거나, 거대 모델의 학습 및 추론 비용을 줄이기 위한 연구 (예: Mixture-of-Experts (MoE), Quantization, Pruning).
- ② 멀티모달리티 (Multimodality) : 텍스트뿐만 아니라 이미지, 음성, 비디오 등 다양한 형태의 정보를 함께 이해하고 생성하는 능력 강화.
- ③ 정렬 (Alignment) : 모델의 행동을 인간의 의도나 가치에 부합하도록 조정하는 연구. 인간 피드백 기반 강화학습 (Reinforcement Learning from Human Feedback, RLHF)이 대표적인 정렬 기법으로, 인간이 선호하는 응답을 생성하도록 모델을 강화학습으로 미세 조정한다.

- ④ 에이전트화 (Agentic AI) : LLM을 도구 사용, 계획 수립, 환경과의 상호작용 능력을 갖춘 자율적인 에이전트로 발전시키려는 연구.

마. 순차적 의사결정 문제에서의 LLM 활용

LLM의 뛰어난 언어 이해, 지식 보유, 추론 능력은 순차적 의사결정 문제, 특히 강화학습과 결합될 때 새로운 가능성을 열어준다. 최근 LLM을 강화학습 에이전트의 ‘두뇌’ 또는 ‘조력자’로 활용하려는 연구가 활발히 진행되고 있다.

- ① 지시 이해 및 목표 설정 : LLM을 사용하여 자연어로 주어진 복잡한 지시를 이해하고 이를 강화학습 에이전트가 이해할 수 있는 형태(예: 보상 함수, 목표 상태, 하위 목표 시퀀스)로 변환하는 연구. 이는 에이전트의 유연성과 사용자 편의성을 높인다.
- ② 계획 수립 및 의사결정 보조 : LLM의 추론 능력을 활용하여 장기적인 목표 달성을 위한 고수준 행동 계획을 생성하고, 이를 강화학습 에이전트의 탐색을 안내하거나 정책을 제약하는 데 사용하는 연구. LLM이 생성한 계획은 에이전트가 더 효율적으로 학습하고 복잡한 문제를 해결하도록 돕는다.
- ③ 보상 설계 자동화/지원 : LLM의 상식 및 도메인 지식을 이용하여 희소한 환경 보상을 보완하는 조밀한 보상 신호를 생성하거나(reward shaping), 심지어 보상 함수 자체를 설계하도록 하는 연구. 이는 보상 설계의 어려움을 크게 완화할 수 있다.
- ④ 세계 모델로서의 활용 : LLM이 가진 세상에 대한 지식을 환경의 동역학을 예측하는 세계 모델의 일부로 사용하려는 시도, 이는 모델 기반 강화학습의 성능을 향상시킬 수 있다.
- ⑤ 정책 표현 및 생성 : 정책 자체를 LLM으로 표현하여, 상태 관찰 및 목표를 입력받아 행동을 직접 텍스트 형태로 생성하도록 하는 연구.
- ⑥ 탐색 전략 안내: LLM을 활용하여 에이전트가 아직 탐험하지 않은

유망한 영역이나 상태를 제안함으로써 탐색 효율성을 높이는 연구.

이러한 연구들은 LLM이 강화학습 에이전트에게 부족한 상식, 추론 능력, 언어 이해 능력을 제공함으로써, 에이전트가 더 복잡한 환경에서 더 지능적이고 효율적으로 행동하도록 만들 수 있음을 시사한다. 본 연구는 이러한 LLM과 RL의 시너지 효과를 MiniGrid라는 구체적인 환경에서 탐구하고 검증하는 것을 목표로 한다.

7. LLM 모델 종류 요약

앞서 논의된 내용을 바탕으로, 주요 LLM 아키텍처 유형별 특징과 강화학습(RL)을 요약하면 다음 표2-2와 같다.

이 표는 각 아키텍처 유형의 일반적인 특징을 나타내며, 실제 모델은 다양한 변형과 조합을 가질 수 있다. 본 논문에서 LLM을 MiniGrid 환경의 RL 에이전트와 통합할 때는, 수행하려는 특정 역할(예: 지시 이해, 계획 수립, 보상 제공 등)에 가장 적합한 아키텍처 유형과 모델을 선택하는 것이 중요하다. 예를 들어, 자연어 지시를 이해하여 하위 목표를 생성하는 역할에는 디코더 전용 모델이나 인코더-디코더 모델이 적합할 수 있으며, 환경 관찰(텍스트 설명)로부터 상태 특징을 추출하는 역할에는 인코더 전용 모델이 효과적일 수 있다.

<표2-2> LLM Architectures: Features and RL Integration

Feature Classification	Encoder Only	Decoder Only	Encoder-Decoder
Main architecture	Transformer encoder stack	Transformer Decoder Stack	Transformer encoder and decoder stack
Processing method	Simultaneous bi-directional context processing of all inputs	Sequential prediction of next token based on previous token (autoregressive)	After encoding input, decode output based on encoder output
Representative model example	Bert, RoBERTa, Albert, ELECTRA	GPT series (GPT-2, GPT-3, GPT-4), LLaMA, PaLM (some)	T5, BART, original Transformer
Main strengths	Understand the deep meaning of input text	Natural and consistent text generation (NLG)	Convert an input sequence to another output sequence
Example pre-learning objectives	Masked language modeling	Causal Language Modeling (CLM): Next-Token Prediction	Various Seq2Seq targets (e.g. Text-to-Text on T5)
Main application areas	Text classification, entity name recognition, question answering	Chatbot, content creation, code generation, summary (abstract)	Machine translation, text summarization (abstract/extractive), dialogue generation

본 장에서는 LLM 기반 강화학습을 활용한 MiniGrid 환경에서의 에이전트 행동 최적화 연구와 관련된 주요 선행 연구 분야들을 검토했다. 먼저 강화학습의 기본 원리인 MDP, 가치 함수, 정책 및 주요 알고리즘 패밀리를 (가치 기반, 정책 기반, 액터-크리틱)와 심층 강화학습으로의 발전을 살펴보았다. 다음으로 본 연구의 실험 환경인 MiniGrid의 특징(부분 관찰성, 희소 보상, 절차적 생성)과 이 환경에서 수행된 기존 연구들, 특히 언어 지시 따르기 관련 연구를 조사했다. 이어서, LLM의 기반 기술인 트랜스포머 아키텍처, 사전 학습 패러다임, 스케일링 법칙 및 창발적 능력, 주요 모델 유형 등 LLM의 핵심 개념과 최신 동향을 개괄했다. 마지막으로, LLM을 강화학습과 통합하여 순차적 의사결정 능력을 향상 시키려는 최근 연구 동향을 소개하고, LLM의 다양한 활용 가능성(지시 이해, 계획, 보상 설계 등)을 살펴보았다.

이러한 검토를 통해, MiniGrid 환경이 제시하는 강화학습의 난제들(부분 관찰성, 희소 보상, 일반화)을 해결하는 데 있어 LLM의 언어 이해, 지식, 추론 능력을 활용하는 것이 유망한 접근 방식이 될 수 있음을 확인하였다. 기존 연구[65]가 제시하는 지상화된 언어 학습의 샘플 효율성 연구를 위한 벤치마크 환경을 넘어, LLM을 직접적으로 활용하여 강화 학습 에이전트의 실시간 행동 최적화를 달성하려는 차별성을 가지게 된다. 특히 본 연구는 LLM의 언어 처리능력을 통해 에이전트가 복잡한 환경 상태를 해석하고 적절한 행동을 선택하도록 지원함으로써, 강화 학습 과정 자체의 효율성을 향상시키는 새로운 방식을 제시한다.

또한, MiniGrid 기반 환경에서 언어 정보를 활용하려는 시도가 있었음을 보여주지만, 최근 비약적으로 발전한 LLM의 능력을 본격적으로 활용하여 에이전트의 행동 자체를 최적화하려는 연구는 아직 초기 단계에 있다. 따라서 최신 LLM 기술을 MiniGrid 환경의 강화학습 에이전트에 접목하여 에이전트의 학습 효율성, 목표 달성 능력, 그리고 일반화 성능을 향상시키는 구체적인 방법론을 제안하고 그 효과를 검증함으로써 LLM을 강화

학습에서 에이전트 행동 최적화 분야의 발전에 기여하고자 한다. 다음 장에서는 본 연구에서 제안하는 구체적인 에이전트 행동 최적화 설계를 상세히 기술할 것이다.

제3장 에이전트(Agent) 행동 최적화 설계

제1절. 실험 환경 설정

본 연구에서는 MiniGrid-Empty-5x5-v0 환경에서 에이전트의 행동을 최적화하기 위해 LLM을 활용하는 새로운 접근 방식을 설계하고, 그 효과를 실증적으로 검증하는 것을 목표로 한다. 기존 강화 학습은 주로 환경과의 수많은 시행착오를 통해 최적의 정책을 학습하지만, 이는 높은 샘플 비효율성과 복잡한 환경에서의 확장성 문제에 직면한다. 이러한 한계를 극복하고자, 본 연구는 LLM의 강력한 자연어 처리 및 추론 능력을 강화 학습 프레임워크에 통합함으로써 에이전트의 의사 결정 과정을 향상시키고자 한다. 구체적으로, 에이전트가 환경으로부터 관측된 상태를 자연어 형태로 LLM에 전달하고, LLM은 이 정보를 바탕으로 다음 행동에 대한 전략적 조언 또는 직접적인 행동 명령을 생성한다. 이러한 LLM의 출력은 에이전트의 행동 선택을 유도하고, 강화 학습 알고리즘이 보다 효율적으로 최적의 행동 정책을 수립하도록 한다. 본 장에서는 MiniGrid-Empty-5x5-v0 환경의 특성을 상세히 분석하고, 이 환경에서 LLM 기반 에이전트가 어떻게 상태를 인지하고, LLM과 상호작용하며, 최종적으로 목표 달성을 위한 행동을 실행하는지 종합적인 프레임워크를 설명한다. 또한, 제안하는 LLM 기반 접근 방식이 전통적인 강화 학습 방법론과 어떻게 차별화되는지, 그리고 이를 통해 에이전트의 학습 효율성과 목표 달성 능력을 어떻게 향상시킬 수 있는지를 기술적으로 상세히 다룬다. 또한, 제안하는 LLM 기반 강화학습 에이전트의 성능을 평가하고 분석하기 위한 대규모 언어 모델로는 한국어 처리에 특화된 LLaMA 아키텍처 기반의 모델을 사용하였다. 이하 각 구성 요소에 대한 상세한 설정 내용을 기술한다.

1. 강화학습 환경 : MiniGrid-Empty-5x5-v0

본 연구의 초기 실험 단계 및 제안 방법론의 기본적인 검증을 위해 강화학습 환경으로 MiniGrid 환경 모음 중 MiniGrid-Empty-5x5-v0를 채택하였다. MiniGrid는 Farama Foundation (구 OpenAI)에서 개발하고 Gymnasium API 표준을 따르는 파이썬 기반 그리드 월드 시뮬레이션 환경이다. 이는 강화학습 알고리즘, 특히 부분 관찰성, 희소 보상, 그리고 절차적 생성하에서의 일반화 능력 연구를 위해 설계되었다.

MiniGrid 환경은 본 연구, 특히 LLM과 강화학습의 통합을 탐구하는 데 있어 여러 중요한 이점을 제공한다. 첫째, 계산적으로 가볍고 시뮬레이션 속도가 빨라 복잡한 모델 구조(특히 LLM 결합 시)를 사용하더라도 신속한 학습 반복과 대규모 실험 수행이 용이하며, 이는 알고리즘 개발 및 디버깅 과정의 효율성을 크게 향상 시킨다. 둘째, Empty와 같은 단순한 환경부터 MultiRoom, ObstructedMaze 등 점진적으로 복잡도가 증가하는 다양한 환경 구성을 제공하여, 에이전트의 기본 능력(탐색, 이동)부터 시작하여 점차 어려운 과제(기억, 계획, 지시 수행 등)로 확장하며 본 논문에서 제안한 에이전트(Agent) 행동 최적화 설계의 성능을 체계적으로 분석할 수 있는 기반을 마련한다. 셋째, 단순한 그리드 형태임에도 불구하고 부분 관찰성, 희소 보상, 절차적 생성과 같은 강화학습의 핵심 난제들을 포함하고 있어, 통제된 환경 내에서 알고리즘의 강인성을 실제 문제 상황과 유사한 조건 하에서 평가할 수 있다. 마지막으로, Gymnasium API 표준 준수 및 오픈 소스 공개는 연구 결과의 재현성 확보와 타 연구와의 비교를 용이하게 한다.

다양한 MiniGrid 환경 중 초기 연구 단계에서 가장 기본적인 MiniGrid-Empty-5x5-v0 환경을 선택한 주된 이유는 다음과 같다. 첫째, 복잡한 장애물이나 상호작용 요소가 없는 단순 환경에서 에이전트의 기본적인 탐색 및 이동 능력을 우선적으로 검증하고, LLM 통합이 이러한 기

초 능력 학습에 미치는 영향을 명확히 분리하여 파악하고자 하였다. 둘째, 환경 자체의 복잡성을 최소화함으로써 LLM과 강화학습 알고리즘 간의 상호작용 및 정보 전달 메커니즘 설계와 그 효과 분석에 집중할 수 있도록 하였다. 환경이 복잡할 경우 성능 변화의 원인이 LLM 통합인지 환경의 특정 요소인지 구분하기 어려울 수 있기 때문이다. 셋째, 가장 간단한 환경에서의 성능을 기준으로 삼아, 향후 더 복잡한 MiniGrid 환경(예: DoorKey, Workspace)으로 확장 시 성능 향상 정도를 비교 평가하기 위한 베이스라인을 설정하였다. 넷째, 학습 및 평가 주기가 짧아 LLM 통합 코드, 인터페이스, 하이퍼파라미터 등의 디버깅 및 개선 작업을 효율적으로 수행할 수 있었다.

MiniGrid-Empty-5x5-v0 환경의 구체적인 명세는 다음과 같다.

- ① 그리드 구조: 환경은 외벽을 포함한 5x5 크기의 그리드로 구성되며, 에이전트가 실제로 이동 가능한 내부 공간은 3x3 크기이다. 각 셀은 빈 공간, 벽, 또는 목표 지점 중 하나이다. Empty-5x5-v0 환경에는 내부 장애물(벽)이 없다.
- ② 상태 공간 : 환경의 완전한 상태는 그리드 크기, 각 셀의 객체 유형/색상/상태, 그리고 에이전트의 위치(x, y 좌표) 및 방향(0: 오른쪽, 1: 아래, 2: 왼쪽, 3: 위) 정보로 구성된 이산적 공간이다. 이 완전한 상태 정보는 에이전트에게 직접 제공되지 않는다.
- ③ 관찰 공간 : MiniGrid 표준 설정에 따라 에이전트는 부분 관찰 환경에서 작동한다. 전체 맵 대신, 현재 위치와 방향 기준 전방의 7x7 크기 자기 중심적 시야를 관찰한다. 관찰은 (높이=7, 너비=7, 채널=3) 형태의 3차원 배열로 제공되며, 채널은 객체 인덱스, 색상 인덱스, 상태 인덱스를 포함한다. 본 연구에서는 이 표준 부분 관찰 설정을 따라 신경망 기반 에이전트의 입력으로 사용하였다. 비록 환경은 단순하지만, 부분 관찰성 유지에 에이전트가 초기부터 POMDP(Partially Observable Markov Decision Process) 상황 대처

능력을 학습하도록 하여 복잡한 환경으로의 확장을 용이하게 한다.

- ④ 행동 공간 : 에이전트는 7가지 이산적 행동 중 하나를 선택할 수 있다. `turn_left` (좌회전), `turn_right` (우회전), `move_forward` (전진), `pickup` (줍기), `drop` (놓기), `toggle` (상호작용), `done` (종료 선언). `Empty-5x5-v0`에서는 주로 `turn_left`, `turn_right`, `move_forward` 세 행동이 유효하게 작용한다. `pickup`, `drop`, `toggle` 행동은 해당 객체가 없어 효과가 없으며, `done` 행동은 목표 도달 시 자동 종료되므로 일반적으로 사용되지 않는다.
- ⑤ 보상 함수 : 목표 지점 도달 시에만 양의 보상을 받는 희소 목표 기반 보상 구조를 따른다. `Gymnasium-MiniGrid` 라이브러리 기본 설정 기준, 목표 도달 시 보상은 $R = 1 - 0.9 * (\text{경과 스텝 수} / \text{최대 스텝 수})$ 로 계산되어, 빠르게 도달할수록 1에 가까운 높은 보상을 받는다. 그 외 스텝에서는 보상이 0이다. 최대 스텝 수 초과 시에도 보상은 0이다. 이 희소 보상 설정은 효율적인 탐색 전략 학습의 중요성을 강조한다.
- ⑥ 에피소드 종료 조건 : 에피소드는 에이전트가 목표 지점에 도달하거나, 사전에 설정된 최대 스텝 수([예: 100] 스텝)를 초과하면 종료된다. 본 연구에서는 충분한 탐색 시간을 보장하기 위해 최대 스텝 수를[예: 100]으로 설정하였다.
- ⑦ 절차적 생성 : 매 에피소드 시작 시, 에이전트의 시작 위치/방향 및 목표 지점 위치가 3x3 내부 공간 내에서 무작위로 재설정된다. 이는 특정 시작-목표 쌍에 대한 과적합을 방지하고 기본적인 일반화 능력을 요구한다.

본 연구에서 제안하는 LLM 기반 강화학습 에이전트의 기본적인 동작과 학습 가능성을 검증하기 위해, 먼저 단순화된 5x5 환경에서 기초 실험을 진행한다. 이후, 보다 복잡한 `MiniGrid-Empty-16x16-v0` 환경으로 확

장하여 실험을 수행한다. 이러한 단계적 접근을 통해, 제안된 에이전트 행동 최적화 설계가 단순한 환경뿐만 아니라 복잡성이 증가한 환경에서도 일관된 성능과 확장성을 보이는지 확인함으로써, LLM을 실시간 강화학습에 활용하는 접근법의 타당성을 입증하고자 한다. 16x16 환경에서의 성공적인 성능은 LLM이 사전 훈련된 지식을 활용하여 환경 구조를 신속하게 파악하고 목표에 효율적으로 도달하는 능력이 있음을 보여주며, 이는 제안된 모델의 일반화 가능성과 실효성을 뒷받침하는 핵심적인 근거가 된다.

MiniGrid-Empty-5x5-v0 환경 구현 및 상호작용을 위해 gymnasium-minigrid 라이브러리를 사용하였으며, 실험 코드는 Python 환경에서 Gymnasium 인터페이스를 기반으로 작성되었다.

제2절. 언어 모델

본 연구에서 강화학습 에이전트의 의사결정을 보조하고 환경 이해 능력을 향상 시키기 위해 활용할 핵심 대규모 언어 모델(LLM)로는 Blllossom/llama-3.2-Korean-Blllossom-3B 모델을 선정하였다.

1. 모델 선정 배경

LLM을 강화학습과 통합하는 연구에서 어떤 LLM을 사용할지 결정하는 것은 매우 중요하다. 본 연구에서 Blllossom/llama-3.2-Korean-Blllossom-3B 모델을 선택한 이유는 다음과 같다.

- ① LLaMA 아키텍처 기반: 이 모델은 Meta AI에서 개발한 LLaMA 아키텍처에 기반한다. LLaMA 모델들은 상대적으로 적은 파라미터 수로도 동급 또는 더 큰 규모의 다른 모델들과 필적하는 우수한 성능을

보여주는 것으로 알려져 있으며, 이는 모델의 효율성과 접근성을 높인다. LLaMA 아키텍처는 RMSNorm, SwiGLU 활성화 함수, Rotary Positional Embeddings 등 최신 기술들을 적용하여 성능과 안정성을 개선하였다.

- ② 한국어 특화 : 모델 이름에 명시된 바와 같이, 이 모델은 한국어 데이터 및 처리에 특화되어 개발된 모델을 사용하였다. 본 연구의 실험 환경 자체는 언어적 요소가 적지만, 향후 연구 확장(예: 한국어 자연어 지시 따르기)이나 LLM과의 인터페이스 설계(예: 상태 설명을 한국어로 생성하여 LLM에 입력) 시 한국어 처리 능력이 중요해질 수 있다. 또한, 한국어 기반 모델을 활용함으로써 국내 연구 환경에서의 접근성 및 활용 가능성을 고려하였다.
- ③ 적절한 모델 규모 : 30억(3 Billion)개의 파라미터를 가진 모델은 현재 LLM 스펙트럼에서 중간 규모에 해당한다. 이는 수백억~수천억 파라미터 모델보다는 작지만, 여전히 상당한 수준의 언어 이해 및 추론 능력을 보유할 것으로 기대된다. 동시에, 70억(7B) 이상의 더 큰 모델들에 비해 학습 및 추론에 필요한 계산 자원(GPU 메모리, 연산 시간) 요구량이 상대적으로 낮아, 본 연구와 같이 학술적 환경에서 강화학습과 통합하여 실험을 수행하기에 더 현실적인 선택지이다. 3B 모델은 강력한 성능과 계산 효율성 사이의 적절한 균형점을 제공한다.

2. LLaMA 아키텍처의 주요 특징

Blossom/llama-3.2-Korean-Blossom-3B 모델의 기반이 되는 LLaMA 아키텍처의 주요 기술적 특징은 다음과 같다. 이러한 특징들은 모델의 성능과 효율성에 기여한다.

- ① RMSNorm (Root Mean Square Layer Normalization): 기존의 Layer Normalization 을 단순화하고 계산 효율성을 높인 정규화 기법이다

[70]. Re-scaling invariant 속성을 유지하면서 re-centering 연산을 제거하여 계산 속도를 향상시킨다. LLaMA는 이를 트랜스포머 블록의 입력과 어텐션/MLP 레이어의 입력에 적용하여 학습 안정성을 높인다.

- ② SwiGLU 활성화 함수: 기존 트랜스포머에서 널리 사용되던 ReLU나 GELU 활성화 함수 대신, SwiGLU[71] 활성화 함수를 MLP(Feed-Forward Network) 레이어에 사용한다. SwiGLU는 입력의 일부를 사용하여 게이트(gate)를 계산하고 이를 다른 부분과 곱하는 방식으로 작동하며 ($\text{Swish}(xW) \odot xV$), 실험적으로 더 나은 성능을 보이는 것으로 알려져 있다. LLaMA는 MLP의 중간 차원을 표준 트랜스포머의 $4d$ 대신 $(2/3) * 4d$ 로 줄여 계산 효율성을 유지했다.
- ③ Rotary Positional Embeddings (RoPE): 기존의 절대 위치 인코딩이나 학습 가능한 상대 위치 인코딩 대신, RoPE [72]를 사용하여 토큰의 상대적인 위치 정보를 효과적으로 인코딩한다. RoPE는 토큰 임베딩 벡터를 복소 평면 상에서 위치 인덱스에 따라 회전시키는 방식으로 작동하며, 시퀀스 길이에 대한 외삽(extrapolation) 능력이 우수하고 구현이 비교적 간단하다는 장점이 있다. 이는 모델이 긴 문맥을 더 잘 이해하는 데 도움을 줄 수 있다.

3. Bllossom 변형 및 한국어 특화

Bllossom/llama-3.2-Korean-Bllossom-3B 모델은 특정 LLaMA 모델을 기반으로 한국어 데이터에 대한 추가 학습이나 미세 조정을 거친 모델이다. Bllossom/llama-3.2-Korean-Bllossom-3B 모델은 한국어 코퍼스 추가 학습을 통해 대규모의 고품질 한국어 텍스트 데이터(뉴스, 도서, 웹사이트 등)를 이용하여 기존 LLaMA 모델을 추가로 사전 학습시켜 한국어 어휘, 문법, 의미 및 문화적 맥락에 대한 이해도를 높였다.

또한 한국어 태스크 미세 조정으로 한국어로 된 특정 NLP 태스크(예: 번역, 요약, 질의응답) 데이터셋을 이용하여 모델을 미세 조정하여 해당 태스크 수행 능력을 강화하고, 한국어의 언어적 특성(교착어, 다양한 조사/어미 활용)을 더 잘 반영하는 토큰나이저를 사용하거나 기존 토큰나이저의 어휘 사전을 확장하여 한국어 텍스트 처리 효율성과 성능을 개선한 모델이다.

본 연구에서는 이 모델의 한국어 특화 능력이 MiniGrid 환경의 상태 정보를 더 정확하게 이해하거나, 향후 한국어 자연어 지시를 포함하는 태스크로 확장할 때 중요한 역할을 할 것으로 기대한다.

4. LLM의 개념적 역할 및 활용 환경

본 연구에서는 Hugging Face의 transformers 라이브러리를 사용하여 Bllossom/llama-3.2-Korean-Bllossom-3B 모델의 사전 학습된 가중치를 로드 하였다.

강화학습 루프 내에서 LLM을 사용할 때, LLM의 파라미터를 고정하고 추론 모드로만 사용할 수도 있고, 강화학습 과정에서 얻는 신호(예: 보상)를 이용하여 LLM 파라미터 일부 또는 전체를 미세조정 할 수도 있다.

본 연구의 초기 단계에서는 계산 효율성과 안정성을 위해 LLM 파라미터를 고정한 채 추론 모드로 활용하는 방식을 우선 고려하였다.


실험 환경의 하드웨어는 LLM 추론에는 상당한 계산 자원이 필요하므로, NVIDIA RTX A5000 GPU와 충분한 128GB RAM을 갖춘 시스템에서 실험을 수행하였다.

본 설계에서 Bllossom/llama-3.2-Korean-Bllossom-3B 모델은 강화학습 에이전트의 ‘지능’을 보장하는 역할을 수행 하도록 설계되었다. 구체적인 통합 방식은 다음 장에서 상세히 설명하겠지만, 개념적으로 LLM은 다음과 같은 역할을 수행할 수 있다.

MiniGrid 환경의 관찰 정보를 입력받아, 이를 보다 의미론적으로 풍부한 표현으로 변환하거나 자연어 텍스트로 요약하여 에이전트의 이해를 돕는다. 현재 상태와 목표를 고려하여 다음 행동에 대한 제안을 생성하거나, 유망한 행동의 확률 분포를 제공하여 강화학습 정책의 탐색 또는 의사결정을 안내한다. 장기적인 목표 달성을 위한 하위 목표 시퀀스를 생성하여, 이를 바탕으로 계층적 강화학습을 수행하거나 보상 함수를 설계하는 데 활용한다.

이러한 LLM의 통합은 MiniGrid 환경, 특히 Empty-5x5-v0와 같이 단순히 보이지만 효율적인 탐색이 중요한 환경에서도 에이전트가 더 빠르고 효과적으로 최적 정책을 학습하도록 도울 잠재력을 가진다.

5. LLM파라미터 조정을 통한 에이전트 행동 최적화



[그림 3-1] 에이전트 행동 최적화를 위한 과정


에이전트 행동의 일관성과 효율성을 높이기 위해, 본 연구에서는 LLM의 주요 생성 파라미터인 ‘Temperature’와 ‘Top-p’ 값을 조정하여 최적의 행동을 [그림 3-1]과 같이 실험을 진행하였다. LLM의 응답은 이 파라미터들에 따라 다양성과 결정성이 조절되므로, 에이전트의 목표 지향적 행동에 직접적인 영향을 준다.

Temperature는 이 파라미터는 LLM이 다음 단어를 선택할 때 확률 분포의 형태를 조절합니다. 낮은 값(예: 0.2)은 모델이 더 높은 확률을 가진 단어를 선택하게 만들어 일관되고 예측 가능한 응답을 생성한다. 반면, 높은 값(예: 1.0)은 더 많은 무작위성을 부여하여 창의적이고 다양한 응답을

유도한다. 본 실험에서는 에이전트가 특정 목표를 안정적으로 달성해야 하므로, 비교적 낮은 Temperature 값을 중심으로 최적점을 탐색하였다.

Top-p 파라미터는 누적 확률이 p 값에 도달할 때까지의 상위 단어들 중에서만 다음 단어를 선택하도록 제한한다. 이는 Temperature와 함께 사용되어 응답의 다양성을 제어한다. 예를 들어, Top-p를 0.9로 설정하면 모델은 확률 합이 90%가 되는 가장 가능성 있는 단어 집합 내에서만 다음 단어를 선택한다. 이를 통해 관련성이 떨어지는 단어들이 생성될 확률을 줄일 수 있다.

[그림 3-2]와 같이 다양한 Temperature와 Top-p 조합을 테스트한 결과, 에이전트가 가장 안정적으로 목표에 도달하고 일관된 행동 패턴을 보이는 최적의 파라미터 조합을 발견하였고, 이러한 파라미터 최적화 과정은 LLM 기반 에이전트가 특정 작업 환경에서 최고의 성능을 발휘하도록 미세 조정하는 핵심적인 단계이다.



[그림 3-2] 에이전트 행동 최적화를 위한 LLM 파라미터별 성공률

제4장 실험 및 결과

제1절. 실험

본 장에서는 제안된 대규모 언어 모델 기반 강화학습(LLM-RL) 방법론의 실증적 성능을 검증하고, 에이전트의 행동 패턴 및 학습 특성을 심층적으로 분석한 결과를 상세히 기술한다. 실험은 MiniGrid-Empty-5x5-v0 환경을 기반으로 진행되었으며, 성능 평가는 에피소드별 총 보상, 목표 달성 성공률, 목표 달성까지 소요된 스텝 수 등의 지표를 중심으로 이루어졌다. 또한, 제안 방법론의 우수성을 객관적으로 입증하기 위해 전통적인 강화학습 알고리즘(PPO, DQN) 및 무작위 행동 선택 방식과의 비교 분석을 수행하였다. 추가적으로, LLM의 일반화 능력을 확인하기 위해 보다 복잡한 16x16 크기의 환경에서도 실험을 진행하였다.

1. LLM 기반 에이전트 설계

환경 상태를 자연어로 표현하는 것은 LLM이 상황을 이해하고 적절한 행동을 결정하는데 중요하다.

본 연구에서는 `get_environment_state` 함수(그림 4-1 참조)를 사용하여 (1) 에이전트의 현재 위치와 방향, (2) 목표 위치, (3) 현재까지의 누적 보상, (4) 과거 학습 경험 요약에 포함하는 구조화된 문장으로 상태 문자열을 생성하여 LLM이 환경을 종합적으로 이해할 수 있도록 하였다. LLM에 대한 프롬프트는 표 4-1와 4-2에서 볼 수 있듯이 에이전트의 역할, 현재 상태, 예상 출력을 명확하게 정의하도록 설계되었다.

프롬프트의 구조는 다음과 같다. (1) 에이전트 역할 정의, (2) 현재 환경

상태 제시, (3) 목표 설명, (4) 가능한 행동 목록 제시, (5) 응답 형식 지정. 이 구조화된 프롬프트는 LLM이 일관된 형식으로 응답을 생성하도록 유도한다.

Algorithm 1 `get_environment_state`

```

1: procedure GET_ENVIRONMENT_STATE(env, cumulative_reward, memory)
2:   (agent_pos, goal_pos, agent_dir)  $\leftarrow$  GET_POSITIONS(env)
3:   lava_positions  $\leftarrow$  GET_LAVA_POSITIONS(env)
4:   dirs  $\leftarrow$  ['오른쪽', '아래', '왼쪽', '위']
5:   fw  $\leftarrow$  IS_OBSTACLE(env, agent_pos, agent_dir)
6:   lw  $\leftarrow$  IS_OBSTACLE(env, agent_pos, (agent_dir - 1) mod 4)
7:   rw  $\leftarrow$  IS_OBSTACLE(env, agent_pos, (agent_dir + 1) mod 4)
8:   summary  $\leftarrow$  SUMMARIZE_MEMORY(memory)
9:   return 상태 문자열: 위치, 방향, 벽 여부, 보상, 메모리 요약 포함
10: end procedure

```

[그림 4-1] `get_environment_state` 함수 알고리즘

Algorithm 2 `get_llm_action`

```

1: procedure GET_LLM_ACTION(environment_state)
2:   instruction  $\leftarrow$  환경 상태를 포함한 사용자 지침 생성
3:   messages  $\leftarrow$  사용자 역할로 instruction 포함한 대화 입력
4:   input_ids  $\leftarrow$  TOKENIZER.APPLY_CHAT_TEMPLATE(messages)
5:   terminators  $\leftarrow$  종료 토큰 ID 목록
6:   outputs  $\leftarrow$  MODEL.GENERATE(input_ids, 샘플링 파라미터 포함)
7:   response  $\leftarrow$  TOKENIZER.DECODE(outputs), 후처리하여 응답 문자열 생성
8:   Return response ('앞으로 이동' / '왼쪽으로 회전' / '오른쪽으로 회전')
9: end procedure

```

[그림 4-2] `get_llm_action` 함수 알고리즘

<표4-1> Environmental State Description

에이전트는 현재 위치 (2, 3)에 있으며 오른쪽을 향하고 있습니다.
목표는 위치 (4, 4)에 있습니다.
에이전트 앞에는 벽이 없고, 왼쪽에는 벽이 있으며, 오른쪽에는 벽이 없습니다.
현재 누적 보상은 5입니다.

<표4-2> LLM Prompt Design

당신은 5x5 그리드 환경에서 캐릭터를 제어하는 AI 에이전트입니다.
현재 상태와 과거 학습 기억을 기반으로 최적의 행동을 선택해야 합니다.
현재 상태: [환경 상태 설명]
에이전트는 목표 위치에 효율적으로 도달해야 합니다. 과거 경험에서 학습한 보상과 벌칙을 참조하여 다음 행동 중 하나를 응답으로 선택하세요: '앞으로 이동', '왼쪽으로 회전', '오른쪽으로 회전'. 추가 설명은 필요 없습니다.


LLM의 출력을 실제 에이전트 행동으로 변환하는 것은 `get_llm_action` (그림 4-2 참조) 함수에 의해 처리된다. 이 과정은 다음 단계로 구성된다. LLM 출력 텍스트 분석 및 이 텍스트를 미리 정의된 행동 매핑으로 변환한다. 이 행동 변환 과정은 식(15)와 같이 표현할 수 있다.

$$A(r) = \begin{cases} \text{Move Forward} \\ \text{Turn Left} \\ \text{Turn Right} \end{cases} \quad \text{if } r \text{ contains} \quad (15)$$

여기서 r 은 LLM의 응답 텍스트를 나타내고, $A(r)$ 은 최종 선택된 행동이다. 또한, 본 연구의 강화 학습 에피소드의 전체 실행은 식(16)과 같이 표현된다.

$$\begin{aligned} \text{Total Reward : } R_{total} &= \sum_{t=0}^T r_t \\ \text{Action Selection : } a_t &= \text{get_llm_action}(s_t) \\ \text{State Transition : } s_{t+1}, r_t &= \text{Move_agent}(s_t, a_t) \end{aligned} \quad (16)$$

여기서 R_{total} 은 각 에피소드 동안 얻은 총 보상을 나타내고, a_t 는 현재 상태 s_t 에서 LLM이 선택한 행동을 나타낸다. s_{t+1} , r_t 는 각각 행동 수행 후의 새로운 상태와 즉각적인 보상을 나타낸다. 이 변환 과정은 LLM의 자연어 출력을 MiniGrid 환경 내에서 실행 가능한 행동으로 매핑한다. 그림 4-3에서 볼 수 있듯이, 환경 상태는 자연어로 변환되어 LLM에 입력되고, LLM의 출력은 다시 환경에 적용되는 특정 에이전트 행동으로 변환되어 순환적인 과정을 진행한다.



[그림 4-3] 전체 시스템 구조

이 접근 방식을 통해 본 연구는 LLM의 언어 이해 및 생성 능력을 강화 학습 문제에 효과적으로 적용한다. 이는 복잡한 환경에서의 의사 결정 과정에 자연어 처리 기술을 통합하는 새로운 방안을 제시하고자 한다.

2. 실험 절차

본 연구에서는 거대 언어 모델(LLM) 기반의 MiniGrid 강화 학습 모델을 구현하고 분석했다. 실험은 MiniGrid-Empty-5x5-v0 환경에서 수행되었으며, 총 1,000개의 에피소드로 구성되었다. 각 에피소드는 최대 100단계로 제한되었다. 에피소드의 실행 과정은 다음과 같다. 먼저 환경이 초기화되고 에이전트의 위치, 방향, 목표 위치 및 주변 장애물에 대한 정보가 수집된다. 다음으로, LLM을 사용하여 현재 상황을 분석하고 최적의 행동을 선택한다. 선택된 행동이 실행되어 새로운 상태로 전환되고 해당 보상을 얻고, 이 과정은 에피소드가 끝날 때까지 반복된다.

에이전트는 최대 100단계 동안 행동을 수행할 수 있으며, 목표 위치에

도달하거나 단계 제한에 도달하면 에피소드가 종료된다. 각 단계에서 환경 상태가 분석되어 LLM에 입력으로 제공되며, LLM은 다음 행동 중 하나를 출력한다. ‘앞으로 이동’, ‘왼쪽으로 회전’, ‘오른쪽으로 회전’이다. 선택된 행동은 환경에 적용되어 새로운 상태와 보상을 생성한다.

보상 시스템은 에이전트가 효율적으로 목표에 도달하도록 장려하기 위해 설계하였다. 목표에 도달하면 +1.0의 양의 보상이 주어지며, 가능한 한 적은 단계로 목표에 도달하도록 장려하기 위해 각 단계마다 -0.01의 페널티가 적용된다.

또한 불필요한 행동을 최소화하기 위해 충돌이나 유효하지 않은 행동에 대해 0.1의 추가 페널티를 부과하였다.

데이터 수집 및 분석을 위해 각 에피소드별 총 보상, 단계 수, 에이전트 궤적과 같은 지표를 수집했다. 에이전트 행동은 Pygame 2.6.1을 사용하여 실시간으로 시각화되어 직관적인 성능 평가를 가능하게 했다.

수집된 데이터는 에피소드 당 총 보상을 나타내는 그래프로 시각화하여 학습 진행 상황을 분석했다.

제2절. 결 과

본 절에서는 제안하는 대규모 언어 모델 기반 강화학습(LLM-RL) 에이전트의 성능을 MiniGrid 환경에서 평가한 결과를 제시한다. 먼저, 다양한 LLM 중 본 연구에 사용될 모델을 선정하기 위한 초기 비교 실험 결과를 제시하고, 이후 선정된 모델을 활용한 에이전트의 학습 성과, 효율성, 그리고 비교 알고리즘 대비 우수성을 심층적으로 분석한다. 마지막으로, 환경 복잡도 증가에 따른 제안 모델의 일반화 성능을 검증하여 에이전트 잠재력과 실효성을 다각도로 확인한다.

1. LLM 모델 선정을 위한 성능 검증

강화학습 에이전트의 핵심 두뇌 역할을 수행할 LLM을 선정하는 과정은 연구의 성패를 좌우하는 중요한 첫 단계이다. 이에 본 연구에서는 공개적으로 접근 가능한 여러 LLM을 대상으로 MiniGrid-Empty-5x5-v0 환경에서의 초기 목표 달성 성공률을 비교 평가하여 최적의 모델을 선정하고자 하였다. 평가 대상 모델에는 한국어 처리에 특화된 Bllossom/llama-2.3-Korean-Bllossom-3B 모델과 함께, 보다 일반적인 LLM으로 알려진 GPT-2, GPT-2-large, 그리고 Facebook/OPT-250M 모델이 포함되었다. 각 모델의 파라미터 수는 Bllossom 모델이 30억 개(3B), OPT 모델이 2억 5천만 개(250M)이며, GPT-2 계열 모델들도 다양한 크기를 갖는다.

다음 표 4-3은 각 LLM을 활용하여 100회의 에피소드를 수행했을 때 관찰된 목표 달성 성공률을 요약한 결과이다.

<표4-3> Initial Success Rate Comparison of LLM Models in MiniGrid-5x5

LLM Model	Success rate when performing 100 episodes(%)
Blossom/llama-3.2-Korean-Blossom-3B	70%~80%
GPT-2	20% or less
GPT-2-large	20% or less
Racebook/OPT-250M	10% or less

표 4-3에서 명확히 드러나듯이, 한국어 특화 모델인 Blossom/llama-2.3-Korean-Blossom-3B는 70%에서 80% 사이의 가장 높은 초기 성공률을 기록하였다. 이는 동일 환경에서 다른 범용 LLM들 (GPT-2 및 GPT-2-large: 20% 이하, Facebook/OPT-250M: 10% 이하)이 보인 저조한 성능과 현저한 대조를 이룬다.

Blossom 모델의 상대적 우위는 여러 요인에 기인한 것으로 해석될 수 있다. 첫째, “언어 특수성”이 중요한 역할을 했을 가능성이 높다. 본 연구에서 환경의 상태 정보(표 4-1)와 에이전트에게 주어지는 프롬프트(표 4-2)는 모두 한국어로 구성되었다. 따라서 한국어에 미세 조정된 Blossom 모델은 이러한 자연어 기반의 작업 지시를 다른 영어 기반 모델들보다 더 정확하게 이해하고 해석하여 적절한 행동으로 연결했을 가능성이 크다. 이는 LLM이 환경 상태와 목표를 이해하는 데 있어 해당 언어에 대한 깊이 있는 이해도가 성능에 직접적인 영향을 미친다는 점을 뒷받

침한다.

둘째, “최적화되지 않은 프롬프트 사용”이 다른 모델들의 낮은 성능에 영향을 미쳤을 수 있다는 분석은 프롬프트 엔지니어링의 중요성을 강조한다. LLM의 행동은 제공되는 프롬프트의 구조와 내용에 매우 민감하게 반응할 수 있으므로, 각 모델의 특성에 맞는 최적화된 프롬프트를 설계하는 것이 성능 확보에 필수적일 수 있다. Bllossom 모델의 경우, 사용된 프롬프트가 상대적으로 더 효과적으로 작용했을 수 있다.

셋째, Bllossom 모델(30억 파라미터)은 GPT-3급 이상의 초거대 모델은 아니지만, 특정 작업(MiniGrid 목표 달성)에서 GPT-2 large (약 7.7억 파라미터) 보다 훨씬 우수한 성능을 보였다. 이는 LLM이 보유한 “사전 학습된 지식”을 활용하여 환경의 구조를 빠르게 이해하고, 목표 지점까지의 최적 경로를 신속하게 탐색하는 능력과 연관될 수 있다.

MiniGrid-Empty-5x5-v0 환경은 비교적 단순하지만, 에이전트는 현재 위치에서 목표 위치로 이동하기 위한 일련의 공간적 추론을 수행해야 한다. 한국어에 특화된 미세조정이 이러한 구조화된 정보(좌표, 방향)와 행동(이동, 회전) 간의 관계를 보다 효과적으로 학습하게 만들었을 수 있으며, 이는 단순한 텍스트 생성 능력을 넘어 특정 문제 해결을 위한 추론 과정이 LLM 내부에서 효율적으로 작동하고 있음을 시사한다. 즉, 모델의 크기뿐만 아니라 특정 도메인이나 작업 유형에 대한 미세조정이 LLM의 ‘추론 능력’을 특정 방향으로 강화시켜, 상대적으로 작은 모델로도 복잡한 작업을 효과적으로 수행할 수 있게 만들 수 있음을 보여준다.

이러한 초기 비교 실험 결과와 분석을 바탕으로, 본 연구에서는 후속 실험을 위한 주요 LLM으로 Bllossom/llama-3.2-Korean-Bllossom-3B 모델을 채택하였다. 이 결정은 단순한 임의 선택이 아니라, 초기 실험을 통한 객관적인 성능 검증에 기반한 합리적인 선택이며, 연구 결과의 신뢰도를 높이는 데 기여할 수 있다.

2. LLM 기반 에이전트 행동 최적화 성능 분석


가. 보상 기반 학습 성과

LLM 기반 강화학습 에이전트의 성능을 정량적으로 평가하기 위해, 총 1,000 에피소드에 걸쳐 학습을 진행하며 에피소드별로 획득한 총 보상을 기록 및 분석하였다.

에피소드별 총 보상에 대한 실험 결과는 그림 4-4와 그림 4-5의 두 그래프를 통해 시각적으로 제시되었다. 그림 4-4은 실험 초기 100 에피소드 동안의 총 보상 변화 추이를 상세히 보여주며, 이를 통해 단기적인 학습 안정성과 초기 목표 달성 능력을 집중적으로 평가할 수 있다. 반면, 그림 4-5은 총 1,000 에피소드 전체에 걸쳐 누적된 보상 데이터를 포괄적으로 나타내어, 장기적인 관점에서 에이전트 성능의 일관성, 수렴성 및 지속적인 학습 효과를 면밀히 관찰할 수 있도록 구성하였다.


그림 4-4에 나타난 초기 100 에피소드 동안의 보상 변화를 분석한 결과, 주목할 만한 점은 25번째와 80번째 에피소드에서 관찰된 보상 값 0이다. 이는 해당 에피소드에서 에이전트가 주어진 최대 스텝 수(100 스텝) 내에 목표 지점에 도달하지 못했음을 의미하는 명백한 실패 사례이다. 총 100 번의 시도 중 단 두 번의 실패만이 기록되었다는 사실은 98%라는 매우 높은 성공률을 시사하며, 이는 제안된 LLM 기반 강화학습 접근법이 별도의 복잡한 알고리즘 튜닝 없이도 기존의 잘 정립된 강화학습 알고리즘들과 비교하여 손색없는 안정적인 항해 및 목표 탐색 능력을 초기부터 보유하고 있음을 강력하게 뒷받침한다.

이러한 높은 초기 성공률은 LLM이 제공된 환경 상태 설명을 효과적으로 이해하고, 이를 바탕으로 목표 달성에 유리한 적절한 행동을 선택하는 능력이 초기 학습 단계에서도 충분히 발휘됨을 보여주는 중요한 실증적 지표이다.



[그림 4-4] LLM 강화학습 100개 에피소드의 총 보상 결과

더 나아가, 1,000 에피소드라는 보다 장기적인 관점에서 보상 분포를 면밀히 살펴보면(그림 4-5 참조), 전반적인 보상 값의 범위가 초기 100 에피소드에서 관찰된 수준과 매우 유사하게 유지되고 있음을 명확히 확인할 수 있다. 이는 학습이 진행됨에 따라 에이전트의 핵심적인 성능 지표, 즉 목표 달성 능력과 효율성이 크게 저하되거나 급격하게 변동하지 않으며, LLM이 일관된 수준의 의사결정 능력을 지속적으로 안정되게 발휘하고 있음을 반영한다.




[그림4-5] LLM 강화학습 1,000 에피소드 총 보상 결과

물론, 에피소드 간 보상 값에는 특정 범위 내에서의 어느 정도의 변동성이 필연적으로 관찰된다. 이는 각 에피소드가 시작될 때마다 에이전트의 시작 위치, 초기 방향, 그리고 목표 지점의 위치가 내부 3x3 공간 내에서 무작위로 새롭게 설정되는 MiniGrid 환경의 절차적 생성 특성에 기인한다. 따라서 이러한 보상의 변동성은 LLM 에이전트가 고정되지 않은 다양한 초기 조건 및 환경 구성에 효과적으로 적응하며 목표를 달성해 나가는 능력을 나타내는 긍정적인 지표로 해석될 수 있다. 즉, 모든 에피소드에서

완벽하게 동일한 최고 보상을 반복적으로 획득하지는 않지만, 다양한 시작-목표 쌍에 대해 일관되게 높은 수준의 보상을 얻으려는 경향성을 뚜렷하게 보였다. 이러한 ‘안정화’ 및 ‘낮은 학습 변동성’은 LLM 에이전트가 사전 학습된 방대한 지식을 효과적으로 활용하고 있다는 직접적인 증거로 볼 수 있다. 전통적인 강화학습 에이전트는 종종 많은 시행착오(낮은 보상을 받는 기간)를 거치며 점진적으로 정책을 개선해 나간다. 반면, LLM 에이전트가 초기부터 높은 성공률과 안정적인 보상 패턴을 보이는 것은, LLM이 이미 보유한 언어적, 개념적 지식을 바탕으로 MiniGrid 환경의 규칙(예: 이동 방식, 목표의 의미)을 빠르게 ‘이해’하고, 효과적인 전략을 즉각적으로 구사할 수 있기 때문으로 생각된다. 이는 ‘학습’ 과정이 전통적인 의미의 점진적 개선보다는 ‘지식 이전(knowledge transfer)’의 형태로 나타나고 있음을 시사한다. LLM은 사전 학습된 지식을 활용하여 환경을 해석하고 효율적으로 행동을 선택함으로써, 전통적으로 상당한 자원을 소모하는 무작위 탐색의 필요성을 최소화한다. 결과적으로 LLM 기반 강화학습은 탐색 비용이 크거나 초기 실패가 치명적인 환경에서 특히 유리할 수 있으며, ‘콜드 스타트(cold start)’ 문제를 완화하고 학습 초기 단계의 비효율성을 크게 줄여줄 잠재력을 기대해 볼 수 있다.


대부분의 에피소드에서 공통적으로 기록된 높은 보상 값은 단순히 에이전트가 목표 지점에 도달했다는 이진적인 성공 여부를 넘어, 목표 달성을 자체가 매우 높은 수준에서 안정적으로 유지되고 있음을 의미한다.

뿐만 아니라, 본 연구에서 채택한 보상 함수의 설계(목표 도달 시 보상 = $1 - 0.9 * (\text{현재 스텝 수} / \text{최대 스텝 수})$)를 고려할 때, 높은 보상 값은 목표 지점까지 도달하는 데 상대적으로 적은 스텝 수를 소요하며 효율적인 경로를 성공적으로 탐색하고 선택했음을 직접적으로 시사한다. 따라서, 실험 전반에 걸쳐 지속적으로 높은 보상이 빈번하게 관찰된다는 점은 LLM 기반 에이전트가 단순히 목표를 찾아내는 기본적인 능력을 넘어, 효율적인 방식으로 목표를 달성하는 실험적 결과이다.



[그림 4-6] 무작위 알고리즘 강화학습 100개 에피소드의 총 보상 결과

결과적으로 LLM 기반 접근법의 성능 우수성을 보다 명확하게 부각시키고 객관적인 비교 기준을 제시하기 위해, 동일한 환경 및 조건 하에서 무작위로 행동을 선택하는 알고리즘을 적용했을 때의 결과를 그림 4-6(초기 100 에피소드)와 그림 4-7(전체 1,000 에피소드)에 함께 제시하여 심층적인 비교 분석을 수행하였다. 그림 4-6에서 명확히 확인할 수 있듯이, 초기 100 에피소드 동안 무작위 알고리즘은 보상 값이 0(완전 실패)에서 최대 1에 가까운 값까지 매우 넓은 범위에 걸쳐 불규칙하게 분포하며 극심한 변동성을 나타낸다.



[그림 4-7] 무작위 알고리즘 강화학습 1,000개 에피소드의 총 보상

이는 에이전트가 목표 달성에 어떠한 일관성도 보이지 못하고, 성공과 실패가 전혀 예측 불가능하게 무작위적으로 반복됨을 명백히 의미한다. 이러한 극단적으로 높은 보상 변동성은 에이전트 성능에 대한 신뢰도를 현저히 저하시킬 뿐만 아니라, 목표 지향적인 과업 수행에 있어 방향성 없는 무작위 탐색 방식이 극도로 비효율적임을 명백하게 보여주는 결과이다. 장기적인 관찰 결과인 그림 4-7에서도 이러한 무작위적이고 불안정한 경향은 전혀 개선되지 않고 동일하게 지속되며, 어떠한 유의미한 학습이나 환경 적응의 패턴도 관찰되지 않는다. 평균적인 목표 달성률은 매우 낮은 수준에 머무르며, 설령 우연히 목표에 도달하더라도 요구되는 평균

스텝 수(그림 4-12 참조)는 LLM 기반 에이전트에 비해 현저히 높아, 무작위 행동 방식의 본질적인 비효율성이 재차 확인된다. 이러한 결과들은 복잡성이 조금이라도 존재하는 환경에서는 무작위 알고리즘이 효과적으로 기능하기 매우 어렵고 목표 달성에 심각한 어려움을 겪는다는 점을 강하게 뒷받침한다.

나. 전통 강화 알고리즘과 성능 비교

LLM 기반 에이전트의 성능을 보다 엄밀하게 평가하고 그 상대적 위치를 파악하기 위해, 강화학습 분야에서 대표적으로 사용되는 전통적인 알고리즘인 PPO 및 DQN과 MiniGrid-Empty-5x5-v0 환경에서 1,000 에피소드를 수행한 후의 주요 성능 지표를 비교 분석하였다. PPO는 정책 기반(policy-based) 방법론의 일종으로 안정적인 학습을 추구하며, DQN은 가치 기반(value-based) 방법론으로 Q-러닝을 심층 신경망과 결합한 형태이다. 이들 알고리즘은 다양한 강화학습 문제에서 좋은 성능을 입증해왔기에 적절한 비교 기준으로 활용될 수 있다.

<표4-4> Results of 1,000 episodes in MiniGrid-5x5 environment by algorithm

Experiment result indicator	PPO	DQN	LLM-RL (Proposal)
Success rate of reaching goal	461	494	953
Average reward	0.44	0.47	0.66
Standard deviation	0.48	0.48	0.24

표 4-4은 총 1,000 에피소드 수행 후, 본 연구에서 제안한 LLM-RL 기반 접근법과 대표적인 전통적 강화학습 알고리즘으로 알려진 PPO 및 DQN, 그리고 앞서 분석한 무작위 알고리즘 간의 주요 정량적 성능 지표를 비교하여 정리한 결과이다. PPO와 DQN 알고리즘은 각각 1,000 에피소드 중 461회와 494회의 성공 횟수를 기록하며 약 46~49% 수준의 중간 정도 성공률을 보였다. 그러나 주목할 점은 두 알고리즘 모두 보상의 표준편차가 각각 0.48로 상당히 높게 나타났다는 것이다. 이는 학습 과정 중 성능이 불안정하게 변동하거나, 다양한 초기 상태 및 환경 구성에 대한 일반화 능력이 상대적으로 부족하여 특정 상황에서는 좋은 성능을 보이다가도 다른 상황에서는 실패할 확률이 높다는 것을 시사한다. 이와 현저한 대조를 이루며, 본 연구의 LLM 기반 접근법은 1,000번의 에피소드 중 무려 953번의 성공을 기록하여 95.3%라는 월등히 높은 성공률을 달성했을 뿐만 아니라, 보상의 표준편차 역시 0.24로 PPO나 DQN의 절반 수준에 불과한 가장 낮은 값을 나타냈다. 이처럼 현저히 낮은 표준편차는 LLM 기반 에이전트가 단순히 목표를 더 자주 달성하는 것을 넘어서, 에피소드 간 성능 편차가 매우 적고 극히 안정적인 학습 과정을 보여준다는 매우 중요한 의미를 내포한다. 이는 LLM이 환경의 무작위적 변화에 강건하게 대처하며 일관성 있는 고성능을 안정적으로 유지하는 능력이 기존의 대표적인 강화학습 알고리즘들에 비해 뛰어나다는 점을 입증하는 정량적 증거라고 할 수 있다.

이와 같이 LLM 기반 강화학습에서 관찰된 전반적으로 우수한 성능과 주목할 만한 안정성은 LLM이 가진 고유한 능력과 특성에서 비롯된 것으로 해석된다. 그중 가장 핵심적인 요인은 환경의 상태 정보를 단순한 숫자나 기호의 배열이 아닌, 풍부한 의미를 내포한 자연어로 해석하고 이해하는 능력이다. LLM은 사전에 학습된 방대한 규모의 언어적 지식과 문맥적 이해 능력을 적극적으로 활용하여, 주어진 상태 설명을 다각도로 분석하고 현재 상황에서 목표 달성에 가장 효과적일 것으로 판단 되는 행동을

논리적으로 추론 해낼 수 있다. 이는 전통적인 강화학습 방법론에서 상태를 주로 저차원 또는 고차원의 수치 벡터로 표현하고, 복잡한 신경망으로 구성된 가치 함수나 정책 함수를 통해 간접적으로 최적 행동을 근사하거나 결정하는 방식과는 근본적인 차이를 보인다. LLM의 이러한 직접적인 상태 해석 및 행동 추론 능력은 최적 정책을 찾기 위해 환경과의 수많은 상호작용과 시행착오에 크게 의존하는 기존의 무작위 탐색의 필요성을 현저히 줄여주며, 이는 그림 4-4와 4-5에서 관찰된 매우 안정적인 보상 추세 변화로 명확하게 뒷받침된다. 즉, LLM은 최소한의 성능 변동성으로 높은 수준의 보상을 지속적으로 유지함으로써, 탐색과 활용의 균형 문제를 효과적으로 완화하며 전통적인 방법론이나 무작위 접근법을 능가하는 학습 효율성을 보여준다. 더 나아가, LLM은 환경 내 존재하는 객체들(예: 벽, 목표 지점) 간의 공간적 관계(예: 벽의 상대적 위치, 목표 지점과의 거리 및 방향)를 이해하고, 과거의 성공 및 실패 경험(본 연구에서는 프롬프트 내에 요약된 형태로 제공)을 현재의 의사결정에 누적적으로 반영하여, 매 에피소드마다 변화하는 다양한 환경 조건에도 불구하고 일관성 있고 합리적인 의사결정을 내릴 수 있다. 이러한 구조화되고 정보에 기반한 행동 선택 방식은 방향성 없이 무작위적인 행동을 반복하는 무작위 알고리즘에서 나타나는 예측 불가능하고 비효율적인 탐색 패턴과 현저한 대조를 이룬다.

다. 전통 강화 학습 알고리즘별 파라미터 분석

에이전트의 효율적인 학습을 위해서는 환경에 대한 적절한 탐색이 필수적이며, 그림 4-8의 PPO, 그림 4-9의 DQN, 그리고 본 논문에서 제시된 그림 4-10의 LLM 기반 강화학습 모델은 각기 다른 파라미터 설정과 탐색 기법을 통해 이 문제를 해결하고자 한다. 각 알고리즘의 탐색 전략과 성능을 파라미터 중심으로 비교하면 다음과 같다.

Algorithm 3 PPO Hyperparameter Configuration

- 1: **Initialize PPO Agent**
 - 2: Set Policy Network $\leftarrow$ "CnnPolicy" (Convolutional Neural Network)
 - 3: Set Environment $\leftarrow$ env
 - 4: **Hyperparameters:**
 - 5: Set Learning Rate, $\alpha \leftarrow 0.0003$
 - 6: Set Rollout Buffer Size (n_steps), $T \leftarrow 2048$
 - 7: Set Minibatch Size, $M \leftarrow 128$
 - 8: Set Number of Optimization Epochs, $K \leftarrow 10$
 - 9: **Logging:**
 - 10: Set Verbose Level $\leftarrow 1$
-

[그림 4-8] PPO 파라미터

Algorithm 4 DQN Hyperparameter Configuration

- 1: **Initialize DQN Agent**
 - 2: Set Policy Network $\leftarrow$ "CnnPolicy" (Convolutional Neural Network)
 - 3: Set Environment $\leftarrow$ env
 - 4: **Hyperparameters:**
 - 5: Set Learning Rate, $\alpha \leftarrow 0.0001$
 - 6: Set Minibatch Size $\leftarrow 64$
 - 7: Set Replay Buffer Size $\leftarrow 100\,000$
 - 8: **Exploration Schedule (ϵ -greedy):**
 - 9: Set Exploration Fraction $\leftarrow 0.1$
 - 10: Set Final Exploration Rate, $\epsilon_{final} \leftarrow 0.02$
 - 11: **Training Update Frequency:**
 - 12: Set Training Frequency $\leftarrow 4$ (every 4 steps)
 - 13: Set Target Network Update Interval $\leftarrow 10\,000$ (every 10,000 steps)
 - 14: **Logging:**
 - 15: Set Verbose Level $\leftarrow 1$
-

[그림 4-9] DQN 파라미터

Algorithm 5 LLM Generation Parameter Configuration

```
1: Input: input_ids

2: Generation Control Parameters:
3:   Set Maximum New Tokens  $\leftarrow 10$ 
4:   Set End-of-Sequence (EOS) Tokens  $\leftarrow \text{terminators}$ 
5:   Set Padding Token ID  $\leftarrow$  Tokenizer's EOS ID

6: Sampling Strategy Parameters:
7:   Enable Sampling (do_sample)  $\leftarrow$  True
8:   Set Temperature,  $T \leftarrow 0.4$ 
9:   Set Nucleus Sampling (top-p),  $p \leftarrow 0.9$ 
```

[그림 4-10] 제안한 LLM 파라미터

DQN은 ϵ -greedy (입실론-그리디) 전략을 사용하여 탐색과 활용의 균형을 맞춘다. 이는 exploration_fraction 파라미터로 지정된 학습 초반부 동안 무작위 행동을 수행할 확률(ϵ)을 점진적으로 줄여나가고, exploration_final_eps로 설정된 최소한의 탐색률을 유지하며 학습을 진행한다. 이 방식은 명시적인 파라미터를 통해 무작위 탐색의 강도를 직접 제어하는 것이 특징이다.

반면 PPO는 정책 자체에 확률적 요소를 내재하는 Stochastic Policy (확률적 정책)를 사용한다. 별도의 탐색 파라미터 대신, 정책 신경망이 각 행동의 확률 분포를 출력하고 에이전트는 이 분포에 따라 행동을 샘플링한다. 이 과정에서 발생하는 무작위성은 자연스러운 탐색으로 이어지며, n_steps 파라미터로 정의된 롤아웃 버퍼의 크기는 정책 업데이트의 안정성에 영향을 주어 간접적으로 탐색의 질을 결정한다.

본 논문에서 제안된 LLM 기반 에이전트는 앞선 두 방법과 근본적으로 다른 접근 방식을 채택했다. 이 에이전트는 전통적인 무작위 탐색을 최소화하고, LLM의 사전 학습된 지식과 언어 이해 능력을 활용한 Informed Action Selection (정보 기반 행동 선택)에 의존한다. 탐색의 다양성은

temperature와 top_p 같은 생성 파라미터를 통해 조절된다. temperature 값을 낮추면(예: 0.4) 모델이 더 확신하는 행동을 결정적으로 선택하게 되며, 이는 무분별한 행동을 줄이고 일관된 의사결정을 유도한다. LLM은 환경 상태를 자연어로 이해하고 과거 경험을 요약하여 최적의 행동을 추론하므로, 전통적인 알고리즘처럼 시행착오를 거치지 않도록 하였다.


논문의 실험 결과는 이러한 차이를 명확히 보여준다. DQN과 PPO가 각각 494회, 461회의 성공률을 보인 반면, LLM 기반 에이전트는 1,000회 중 953회라는 월등히 높은 성공률과 낮은 표준편차(0.24)를 기록했다. 이는 LLM이 사전 지식을 활용해 환경 구조를 빠르게 파악하고 비효율적인 탐색 단계를 대폭 줄임으로써, 기존 강화학습 알고리즘의 탐색 기법보다 더 안정적이고 높은 성능을 달성할 수 있음을 시사한다. LLM의 이러한 고유한 특성들은 특히 동적이고 불확실하며 적응성과 확장성이 중요하게 요구되는 복잡한 실제 환경 문제 해결에 있어 LLM 기반 접근법이 기존 강화학습의 한계를 보완하고 새로운 가능성을 제시하는 강력한 대안이 될 수 있을 것이다.

3. 에이전트 행동 선택 패턴 분석

LLM 기반 에이전트가 실제로 어떠한 행동 선택 패턴을 보이는지 보다 면밀히 분석하기 위해, 각 에피소드에서 목표 달성에 성공하기까지 소요된 총 스텝 수를 측정하고, 이를 앞서 비교 대상으로 삼았던 무작위 알고리즘의 결과와 상세히 비교하였다.

그림 4-11은 LLM 에이전트가 각 성공적인 에피소드에서 목표 지점에 도달하기까지 정확히 몇 스텝을 이동했는지를 보여주는 반면, 그림 4-12는 동일한 조건하에서 무작위 알고리즘이 목표 달성까지 소요한 스텝 수를 나타낸다. 이 두 그래프의 분포와 경향성을 비교함으로써, LLM이 환경을 얼마나 효율적으로 탐색하고 목표를 달성하는지를 에피소드별 효율

성 측면에서 보다 구체적이고 정량적으로 평가할 수 있다.




[그림 4-11] LLM 모델 적용 시 성공적인 단계 수

LLM 학습 에이전트와 무작위 알고리즘 간의 스텝 수 비교 분석 결과, LLM 기반 에이전트가 환경 상태에 대한 탁월한 이해력과 상황 적응력을 바탕으로 훨씬 효율적인 행동을 선택함을 명확히 확인할 수 있었다.

주어진 환경 상태 정보를 자연어로 변환하여 입력받은 LLM은 이를 효과적으로 해석하고, 현재 상태에서 목표 지점으로 향하는 데 가장 적합하다고 판단되는 행동(좌회전, 우회전, 전진)을 선택함으로써, 목표 지점 도

달에 필요한 총 스텝 수를 현저히 감소시키는 뚜렷한 경향을 보였다. 그림 4-11의 스텝 수 변화 그래프에서 명확히 나타나듯이, LLM 기반 에이전트는 실험 전반에 걸쳐 다수의 에피소드에서 일관되게 상대적으로 적은 스텝 수로 목표를 성공적으로 달성하고 있다. 이는 LLM이 다양한 환경 상태 변화, 즉 에이전트의 시작 위치나 목표 지점의 무작위적인 변경에도 불구하고 각 상황에 맞는 최적의 혹은 그에 준하는 효율적인 행동 순서를 효과적으로 찾아내고 있음을 시사한다. 특히 주목해야 할 점은, 그림 4-11에서 볼 수 있듯이 일부 에피소드에서는 극히 적은 스텝 수(예: 10 스텝 미만)만으로 신속하게 목표에 도달했다는 사실이다. 이는 단순히 최적의 시작 위치-목표 위치 조합이 우연히 주어진 결과라기보다는, LLM이 현재 상태와 목표 지점 간의 상대적 위치 및 방향 관계를 정확히 파악하고, 최단 경로 탐색과 유사한 형태의 공간적 추론을 수행하는 강력한 내재적 추론 능력과 환경 이해력을 보유하고 있음을 보여주는 구체적인 증거라고 해석할 수 있다.



[그림 4-12] 무작위 알고리즘 적용 시 성공적인 단계 수


반면에, 그림 4-12에 제시된 무작위 알고리즘이 목표 달성까지 소요한 스텝 수의 변화 그래프는 LLM의 결과와 극명한 대조를 이룬다. 성공한 에피소드들만 놓고 보더라도, 소요된 스텝 수가 에피소드마다 매우 큰 폭으로 변동하며, 어떤 일관된 패턴이나 효율적인 학습의 경향성을 전혀 찾아보기 어렵다. 이는 무작위 알고리즘의 경우 목표 달성 여부 자체가 매우 불안정할 뿐만 아니라, 설령 운 좋게 목표에 성공적으로 도달하더라도 그 과정이 매우 비효율적일 수 있음을 단적으로 보여준다. 무작위 알고리즘은 현재 환경 상태에 대한 어떠한 이해나 미래에 대한 계획 없이 단순히 가능한 행동들 중 하나를 확률적으로 동일하게 무작위 선택하기 때문에, 목표 방향과 무관한 불필요한 이동이나 제자리 회전을 반복하며 결과

적으로 목표 지점까지 도달하는 데 훨씬 많은 스텝을 소요하는 경우가 빈번하게 발생한다. 때로는 최대 스텝 수 제한(100 스텝)에 거의 근접해서야 겨우 목표에 도달하는 경우도 관찰된다. 이러한 결과는 목표 지향적 과업 수행에 있어 무작위 탐색 방식이 가지는 본질적인 비효율성과 명백한 한계를 다시 한번 극명하게 확인시켜 준다.

LLM 에이전트는 각 상황에 가장 적합하고 최적화된 행동을 결정하기 위해, 입력으로 주어진 환경 상태 정보를 자연어 형태로 변환하여 심도 있게 해석하고 추론한다. 이러한 LLM의 고유한 능력은 에이전트가 복잡하고 때로는 예측 불가능하게 변하는 동적인 상태 변화에도 신속하게 적응하여 지속적으로 높은 목표 달성률을 안정적으로 유지하도록 결정적인 역할을 한다. 특히, LLM 기반 에이전트는 프롬프트를 통해 명시적으로 제공된 벽이나 잠재적 장애물의 위치 정보를 효과적으로 고려하여, 비효율적인 충돌이나 막다른 길 진입을 회피하고 보다 효율적인 경로를 능동적으로 선택함으로써, 목표 달성에 요구되는 평균적인 스텝 수를 체계적으로 줄여나가는 모습을 보인다. 더욱이 강조할 점은, LLM이 보여주는 이러한 강력한 문제 해결 성능이 본 연구의 주된 실험 환경이었던 비교적 단순한 5x5 크기의 MiniGrid 환경에만 국한되지 않는다는 사실이다.

4. LLM 기반 에이전트의 일관성 및 효율성 분석

강화 학습 에이전트의 실제 적용 가능성을 평가하는 데 있어, 단순히 목표 달성 여부를 넘어 반복적인 실험 환경에서 성능의 일관성과 효율성을 입증하는 것은 필수이다. 제안하는 대규모 언어 모델 기반 강화 학습 에이전트의 성능을 무작위 알고리즘, PPO, 그리고 DQN과 비교하여, 에피소드를 통해 얻어진 성공률과 에피소드당 평균 스텝 수를 중심으로 분석한다.



[그림 4-13] 알고리즘별 1,000 에피소드 성공률

그림 4-13 그래프는 각 횟수별 1,000 에피소드를 반복적인 실험 환경에서 각 알고리즘의 성공률을 명확하게 보여주며, LLM-RL 에이전트의 탁월한 일관성을 확인할 수 있다. 그래프에서 노란색 별표로 표시된 LLM-RL은 실험 전반에 걸쳐 거의 100%에 가까운 성공률을 지속적으로 유지하고 있다. 이는 LLM-RL이 모든 시점에서 다른 알고리즘들을 압도하는 성능을 보여주며, 목표 달성 능력이 매우 안정적임을 의미한다.


반면, 파란색 다이아몬드로 표시된 무작위 알고리즘은 약 70% 중반대의 성공률을 보이고 주황색 사각형의 PPO와 회색 삼각형의 DQN은 더 큰 변동성을 보이며, 특히 DQN은 한 시점에서 성공률이 150 이하에 가깝게 떨어지는 극심한 불안정성을 드러낸다. PPO 역시 DQN보다는 나은 모습을 보이지만, 여전히 LLM-RL의 일관성과는 큰 차이를 보인다.

이러한 LLM-RL의 지속적으로 높은 성공률은 단순히 목표에 도달하는 능력을 넘어, 에이전트가 목표를 일관되게 달성할 수 있음을 의미한다.

이는 LLM이 가진 사전 학습된 방대한 지식과 자연어 이해 능력이 환경 상태를 정확하게 해석하고, 심지어 이전에 경험하지 못한 상황에서도 합리적인 의사 결정을 내릴 수 있도록 지원하는 것으로 생각된다. 결과적으로 LLM-RL은 최소한의 실패로 장기간에 걸쳐 안정적인 성능을 유지하며, 이는 그림 4-4와 4-5 에서 나타나는 보상 추이의 결과를 더욱 명확히 뒷받침 한다.

그림 4-14 그래프는 각 횟수별 1,000 에피소드를 진행하면서 목표에 도달하기까지 소요되는 스텝 수로 측정하였고, 제공된 그래프는 이 지표에서 LLM-RL의 우위를 확인할 수 있다. 그래프에서 노란색 별표로 표시된 LLM-RL은 모든 시점에서 가장 낮은 평균 스텝 수를 유지하고 있으며, 그 수치는 매우 안정적이고 일관적이다. 이는 LLM-RL 에이전트가 목표 달성을 위해 가장 효율적인 경로를 일관되게 찾아내고 있음을 의미한다. 반면, 다른 알고리즘들은 LLM-RL에 비해 훨씬 높은 평균 스텝 수를 보이며, 파란색 다이아몬드로 표시된 무작위 알고리즘은 LLM-RL보다는 높지만, PPO와 DQN에 비해서는 비교적 안정적인 중간 수준의 스텝 수를 나타낸다. 주황색 사각형의 PPO와 회색 삼각형의 DQN은 스텝 수에서 큰 변동성이 생겼다. 특히 DQN은 한 시점에서 평균 스텝 수가 크게 치솟는 불안정한 양상을 나타내며, 이는 DQN의 특성으로 리플레이 버퍼에 충분한 양의 경험 데이터가 수집되기 전까지 실제 학습, 즉 신경망 가중치 업데이트를 지연시키는 역할을 한다. 즉 실험에서 제시한 에피소드 및 스텝

의 값이 더 많이 설정되어야 한다. PPO 또한 DQN보다는 안정적이지만, LLM-RL의 일관된 낮은 스텝 수에는 훨씬 미치지 못한다.



[그림 4-14] 알고리즘별 평균 스텝 수


이러한 LLM-RL의 지속적으로 낮은 평균 스텝 수는 LLM이 환경의 공간적 관계와 LLM 모델의 방대한 지식을 효과적으로 활용하여 최적 또는 거의 최적의 경로를 추론하고, 불필요한 탐색을 최소화함으로써 가능해진 결과이다. LLM은 사전 학습된 지식을 통해 환경의 구조를 빠르게 이해하

고, 이를 바탕으로 목표 지점까지의 최적 경로를 효율적으로 탐색한다. 이는 특히 초기 성공률을 높이고 학습 안정성을 강화하는 데 기여하며, 복잡한 환경에서도 적용할 수 있다. 반면, 무작위 알고리즘은 행동 선택에 체계적인 패턴이 없으므로, 목표 도달에 많은 스텝이 소요되거나 심지어 스텝 제한 내에 목표에 도달하지 못하는 경우가 빈번하다. PPO와 DQN 또한 학습을 통해 스텝 수를 줄이는 경향을 보이지만, 제한된 학습 횟수 및 스텝에서는 LLM-RL만큼 일관적으로 효율적인 경로를 찾는 데는 한계가 있다.

5. 환경 복잡도에 따른 일반화 분석

본 연구의 핵심적인 동기, 즉 LLM이 가진 사전 지식과 추론 능력이 강화학습 에이전트의 성능 향상에 기여할 수 있다는 가설을 더욱 공고히 하기 위해, 환경의 복잡도를 높여 16x16 크기의 더욱 넓고 복잡한 그리드 환경(MiniGrid-Empty-16x16-v0)에서도 추가적인 검증 실험을 수행하였다. 그 결과는 그림 4-15에 제시된 것처럼 LLM은 훨씬 넓어지고 탐색 공간이 방대해진 복잡한 환경에서도 별도의 추가 학습이나 미세조정 없이 초기 학습 단계부터 매우 높은 성공률과 안정적인 보상 수준을 기록하였다. 이는 LLM이 특정 환경에 과적합 된 것이 아니라, 사전에 학습된 방대한 양의 일반적인 지식을 바탕으로 처음 접하는 새로운 환경의 내재적 구조(예: 그리드의 크기, 가능한 이동 경로의 형태, 목표 도달을 위한 일반적 전략 등)를 빠르게 파악하고, 주어진 목표 지점까지의 최적 또는 준 최적 경로를 효율적으로 탐색해 나가는 뛰어난 일반화 능력을 갖추고 있기 때문으로 분석된다. 그림 4-15은 16x16 환경에서의 1,000 에피소드 동안의 에피소드별 총 보상 변화를 보여주는데, 5x5 환경과 마찬가지로 실험 초기부터 전반적으로 일관되게 높은 보상 값이 안정적으로 유지되는 것을 명확하게 확인할 수 있다.

이러한 LLM의 고유한 특성은 환경의 규모나 복잡성이 증가하더라도 초기 학습 성능의 저하를 최소화하고 초기 성공률을 높이며, 전체적인 학습 안정성을 강화하는 데 크게 기여한다.




[그림 4-15] MiniGrid-16x16 환경 변화에 따른 보상 결과

이는 기존의 강화학습 알고리즘들이 환경 복잡도 증가에 따라 학습 속도가 급격히 느려지거나 성능 저하를 겪는 경향과 비교할 때, LLM 기반 강화학습이 가지는 매우 중요한 실질적인 장점 중 하나라고 평가할 수 있다. 무작위 알고리즘과의 비교를 종합해 볼 때, LLM의 행동 반응은 훨씬 더 체계적이고 명확하게 목표 지향적인 특성을 보인다. 이는 앞서 제시된 보상 그래프(그림 4-4, 4-5)와 목표 달성 스텝 수 그래프(그림 4-11) 모두

에서 명확하게 드러나는 결과이다. LLM 기반 학습 방식은 높고 안정적인 보상 수준을 지속적으로 유지하는 반면, 무작위 알고리즘은 예측 불가능한 상당한 성능 변동성을 보이며 전반적으로 낮은 보상 수준에 머무른다.

결론적으로, 본 연구의 실험 결과들은 LLM이 환경 상태에 대한 깊이 있는 이해와 효과적인 추론 능력을 바탕으로 각 상황에 적절한 행동을 능동적으로 선택함으로써, MiniGrid 환경에서의 강화학습 문제 해결에 있어 단순한 무작위 알고리즘보다 월등히 우수한 성능과 학습 효율성을 보여주었음을 입증한다. 이러한 결과들은 LLM이 가진 내재적인 강력한 문제 해결 능력과 새로운 상황에 대한 뛰어난 일반화 가능성을 강조하며, 향후 LLM과 강화학습의 접목 방식에 대한 추가적인 연구 및 방법론 개선을 통해 더욱 복잡하고 도전적인 문제에서도 훨씬 큰 성능 향상을 달성할 수 있는 상당한 잠재력을 가지고 있음을 시사한다.



[그림 4-16] 16x16 실험 횟수별 1,000 에피소드 성공 횟수

그림 4-16과 같이 전통적인 강화학습 에이전트의 경우, 학습 환경(100 에피소드, 50 스텝 제한)이 크게 변경되면(예: 상태 공간의 급격한 확장 및 학습 조건) 처음부터 다시 학습해야 하거나 상당한 규모의 재학습 과정과 미세조정이 필요한 경우가 일반적이다. 그러나 LLM 기반 에이전트는 환경 변화에 훨씬 더 강인한 적응력을 보여주며, 이는 초기 성공률을 향상시키고 중간 정도의 복잡한 환경에서도 학습 안정성을 강화하는 데 기여한다.

제5장 고찰 및 결론

제1절. 연구의 주요 결과 및 의의

본 연구는 LLM을 강화학습 에이전트의 핵심 의사결정 메커니즘으로 통합하여, 표준 벤치마크 환경인 MiniGrid에서 그 성능과 특성을 심층적으로 분석하고 평가하는 것을 목표로 하였다. 연구의 핵심은 환경 상태 정보를 구조화된 자연어 텍스트로 변환하여 LLM에 입력하고, LLM의 추론 능력을 통해 행동을 도출한 후, 이를 다시 환경 내 실행 가능한 행동으로 변환하는 독창적인 상호작용 프레임워크를 구축하고 그 유효성을 검증하는 데 있었다. 특히, 한국어 특화 언어 모델을 활용하여 언어적 특성이 강화학습 성능에 미치는 잠재적 영향까지 확인하고자 하였다.

1. LLM 기반 에이전트의 성능 및 특성 분석

본 연구는 LLM을 강화학습 에이전트의 핵심 의사결정 메커니즘으로 통합하여, 표준 벤치마크 환경인 MiniGrid에서 그 성능과 특성을 심층적으로 분석하고 평가하는 것을 목표로 하였다. 연구의 핵심은 환경 상태 정보를 구조화된 자연어 텍스트로 변환하여 LLM에 입력하고, LLM의 추론 능력을 통해 행동을 도출한 후, 이를 다시 환경내 실행 가능한 행동으로 변환하는 독창적인 상호작용 프레임워크를 구축하고 그 유효성을 검증하는 데 있었다. 특히, 한국어 특화 언어 모델을 활용하여 언어적 특성이 강화학습 성능에 미치는 잠재적 영향까지 확인하고자 하였다.

실험 결과, 제안된 LLM 기반 강화학습 에이전트는 MiniGrid-Empty-5x5-v0 환경에서 전통적인 강화학습 알고리즘인 PPO 및 DQN 그리고 무작위 행동 정책과 비교하였을 때 현저히 우수한 성능

을 나타내었다. 구체적으로, LLM 기반 에이전트는 95.3% 이상 높은 목표 달성 성공률을 기록하였으며, 이는 LLM이 환경 상태에 대한 자연어 기술을 이해하고, 이를 바탕으로 적절한 행동을 추론하여 강화학습의 목표를 효과적으로 달성할 수 있음을 실증적으로 입증하는 결과이다. 평균 누적 보상 측면에서도 LLM 에이전트는 가장 높은 값을 기록하여, 단순히 목표를 달성하는 것을 넘어 보상 최대화라는 강화학습의 근본적인 목표에도 부합하는 행동 전략을 학습할 수 있음을 보여주었다.

목표 달성까지 소요된 평균 스텝 수 분석에서는 LLM 기반 에이전트가 다른 비교 대상들보다 더 적은 스텝으로 목표 지점에 도달하는 경향을 나타내었다. 이는 LLM이 현재 위치와 목표 지점 간의 공간적 관계를 이해하고, 불필요한 탐색을 줄이며 보다 효율적인 경로를 계획할 수 있는 잠재력을 가지고 있음을 시사한다. 이러한 효율적인 경로 탐색 능력은 LLM의 사전 지식과 추론 능력이 단순한 상태-행동 매핑을 넘어, 문제 해결을 위한 일종의 계획 능력을 발휘할 수 있음을 생각해 볼 수 있는 중요한 결과이다.

본 연구의 또 다른 중요한 발견은 LLM 기반 에이전트의 일반화 능력과 학습 안정성이다. 환경의 복잡도를 높인 MiniGrid-Empty-16x16-v0 환경에서, 5x5 환경에서 사용된 것과 동일한 프롬프트 및 LLM 설정을 별도의 재학습이나 미세 조정 없이 적용했음에도 불구하고, LLM 기반 에이전트는 합리적인 수준의 초기 목표 달성 성공률(약 60~70%)을 나타내었다. 이는 특정 환경에 과적합 되지 않고, 사전 학습을 통해 습득한 일반적인 공간 추론 능력이나 문제 해결 전략을 새로운, 더 복잡한 상황에도 어느 정도 적용할 수 있는 LLM의 강력한 일반화 잠재력을 명확히 보여준다. 전통적인 강화학습 알고리즘들이 새로운 환경에 적응하기 위해 상당량의 추가 학습을 필요로 하는 것과 비교할 때, 이는 LLM 활용의 중요한 이점을 부각 시킨다. 학습 안정성 측면에서도 LLM 기반 에이전트는 보상 표준편차 0.24로 매우 안정적인 학습 곡선을 나타내었다. 이는 학습

초기 단계에서 상당한 성능 변동성을 보이는 PPO나 DQN과 대조적으로, LLM의 내재된 지식과 추론 능력이 초기 탐색의 불안정성을 줄이고 일관된 성능 유지에 기여했음을 시사한다. 이러한 안정성은 실제 응용 환경에서 예측 가능하고 신뢰할 수 있는 에이전트 개발에 중요한 요소로 작용할 수 있다.

종합적으로, 본 연구의 실험 결과는 다음과 같은 핵심적인 발견을 제시한다. 첫째, 대규모 언어 모델은 적절한 프롬프트 엔지니어링을 통해 표준적인 강화학습 문제 환경에서 효과적으로 기능하며, 목표 달성, 보상 최대화, 효율적 경로 탐색 측면에서 기존 강화학습 방법론 대비 우수한 성능을 나타낼 수 있다. 둘째, LLM은 별도의 재학습 없이도 새로운, 더 복잡한 환경에 대해 일정 수준 이상의 일반화 성능을 보이며, 이는 데이터 효율성 및 환경 적응력 향상의 가능성을 시사한다. 셋째, LLM 기반 에이전트는 상대적으로 높은 학습 안정성을 보여, 예측 가능하고 신뢰성 있는 행동 패턴을 학습할 수 있는 잠재력을 지닌다. 이러한 발견들은 LLM의 사전 지식과 추론 능력이 순차적 의사결정 문제 해결에 새로운 패러다임을 제공할 수 있음을 강조하며, 자연어 처리와 강화학습 분야의 성공적인 융합 가능성을 확인하였다.

2. 연구 결과의 의미

본 연구에서 도출된 LLM 기반 강화학습 접근법의 성공적인 성능 검증과 그 과정에서 관찰된 독특한 특징들은 단순한 기술적 성과를 넘어, 인공지능 연구 분야 전반에 걸쳐 중요한 학문적, 기술적 의미와 기여를 내포하고 있다.

전통적인 강화학습에서 상태 표현은 종종 수치 벡터나 이미지 픽셀 데이터와 같이 정형화된 형태로 이루어지며, 이는 환경의 복잡한 의미론적 정보나 객체 간의 관계를 명시적으로 표현하는 데 한계를 가질 수 있다.

반면, 본 연구에서 LLM은 환경 상태를 자연어 텍스트로 이해하고 처리함으로써, 상태 표현의 패러다임을 근본적으로 전환할 가능성을 제시한다. 자연어는 객체 간의 공간적, 의미론적 관계, 환경의 동적인 변화, 심지어 추상적인 목표나 복잡한 지시 사항까지도 풍부하고 유연하게 표현할 수 있는 강력한 매체이다. LLM이 이러한 자연어 기반 상태 표현을 효과적으로 처리할 수 있다는 것은, 특정 환경이나 작업에 맞춰 특정 공학(feature engineering)에 많은 노력을 기울여야 했던 기존 방식의 한계를 극복하고, 보다 다양한 강화학습 문제에 용이하게 적용될 수 있는 높은 수준의 적응성과 확장성을 의미한다. 또한, LLM이 사전 학습을 통해 습득한 방대한 양의 일반 지식과 상식적 추론 능력은 강화학습 에이전트의 일반화 성능 향상에 결정적인 기여를 할 수 있다.

심층 강화학습 모델은 종종 ‘블랙박스’로 간주되어 그 의사결정 과정을 이해하기 어렵다는 한계가 지적 되어왔다. 반면, LLM 기반 접근법은 에이전트의 의사결정 과정을 LLM의 자연어 추론 과정을 통해 설명하거나 이해할 수 있는 잠재력을 제공함으로써, 해석 가능성 측면에서 중요한 진전을 이룰 수 있다. 에이전트가 특정 행동을 선택한 이유를 자연어로 설명할 수 있다면, 이는 시스템 개발 과정에서의 디버깅을 용이하게 하고, 최종 사용자가 AI의 결정을 신뢰하고 수용하는 데 크게 기여할 수 있다.

더 나아가, 본 연구에서 시도된 과거 경험 요약 정보의 프롬프트 통합은 LLM의 뛰어난 문맥 이해 능력을 강화학습의 ‘학습’ 과정 자체에 효과적으로 적용할 수 있는 새로운 가능성을 제시한다.

본 연구는 자연어 처리와 강화학습이라는, 과거에는 비교적 독립적으로 발전해 온 두 인공지능 핵심 분야를 성공적으로 통합할 수 있는 구체적인 방법론과 그 실증적 증거를 제시했다는 점에서 중요한 학문적 의의를 갖는다. LLM이 환경 상태를 이해하고 적절한 행동을 추론하여 강화학습 목표를 달성할 수 있음을 입증한 것은, LLM을 단순한 언어 처리 도구를 넘어 순차적 의사결정 문제 해결을 위한 강력한 인지 엔진으로 인식하는 패

러다임 전환을 의미한다.

기술적 측면에서, LLM 기반 강화학습은 기존 강화학습 방법론이 직면했던 여러 현실적인 문제들을 해결하는 데 중요한 기여를 할 수 있다. LLM의 사전 지식과 일반화 능력은 강화학습 에이전트의 데이터 효율성을 크게 향상시켜, 많은 양의 시행착오 없이도 새로운 환경이나 작업에 빠르게 적응할 수 있도록 돕는다. 또한, LLM 기반 에이전트는 자연어를 통해 인간과 소통하고 지시를 받을 수 있으므로, 인간-AI 상호작용(Human-AI Interaction)의 질을 획기적으로 개선할 능력을 예상해 볼 수 있다. 이는 복잡한 작업을 인간과 AI가 협력하여 수행하는 공동 작업 시나리오에서 매우 중요한 역할을 할 수 있으며, AI를 단순한 도구가 아닌 능동적이고 이해심 있는 협력 파트너로 발전시키는 데 기여할 것이다.

제2절. 연구 한계점 및 향후 연구 방향

본 연구를 통해 LLM 기반 강화학습 접근법의 상당한 잠재력이 확인되었음에도 불구하고, 이 기술이 실제 세계의 복잡한 문제에 광범위하게 적용되기까지는 해결해야 할 여러 본질적인 한계점과 도전 과제들이 존재한다. 이러한 문제점들에 대한 명확한 인식은 향후 연구 방향을 설정하고 기술적 난관을 극복하는 데 필수적이다.

1. 기술적 한계점 분석

본 연구를 통해 LLM 기반 강화학습 접근법의 상당한 잠재력이 확인되었음에도 불구하고, 이 기술이 실제 세계의 복잡한 문제에 광범위하게 적용되기까지는 해결해야 할 여러 한계점과 도전 과제들이 존재한다. 본 연구에서 사용된 MiniGrid 환경은 규칙이 명확하고 상태 공간이 비교적 잘

정의된 제어된 환경이다. 그러나 실제 세계의 많은 문제들은 사전 정보가 부족하거나 규칙이 지속적으로 변하는 미지의 환경, 또는 매우 높은 차원의 연속적인 상태 및 행동 공간을 가진 동적인 환경의 특성을 지닌다.

현재의 LLM 기반 에이전트가 이러한 복잡하고 예측 불가능한 실제 환경에서 강건하게 작동하고 효과적으로 목표를 달성하기 위해서는 상당한 개선이 필요하다. 효과적인 온라인 학습 메커니즘, 지속적인 환경 모델링 능력, 그리고 변화에 대한 빠른 적응 전략의 부재는 실제 환경 적용의 주요 제약 요인으로 작용한다.

현재의 LLM 기반 방법론을 훨씬 더 복잡하고 상태/행동 공간이 방대한 대규모 환경이나 실제 물리 세계 문제에 직접 적용하는 데에는 확장성의 한계가 존재한다. 방대한 양의 센서 데이터나 복잡한 상황 정보를 LLM이 처리 가능한 길이와 형태의 효과적인 자연어 프롬프트로 변환하는 것 자체가 매우 도전적인 과제이다. 또한, LLM 기반 에이전트는 LLM 모델에 따라 에피소드 간 성능 변동성을 보일 수 있으며, LLM의 행동이 입력 프롬프트의 미세한 변화에도 매우 민감하게 반응하는 경향이 있다. 이로 인해 최적의 성능을 내는 프롬프트를 설계하고 유지하는 것이 고도의 전문성과 많은 시행착오를 요구하는 ‘프롬프트 엔지니어링’ 작업이 되며, 이는 연구의 재현성과 일반화를 저해하는 요인이 될 수 있다.

LLM은 주어진 문맥에서 통계적으로 그럴듯한 응답을 생성하는 데 탁월한 능력을 보이지만, 이것이 강화학습의 궁극적인 목표인 장기적인 누적 보상 최대화라는 측면에서 항상 최적임을 보장하지는 못한다. LLM의 결정은 때때로 근시안적이거나, 논리적 일관성이 부족하거나, 사전 학습 데이터에 존재하는 편향이나 부정확한 정보를 무비판적으로 반영할 수 있다. 특히 안전이 매우 중요하게 요구되는 응용 분야에서는 LLM의 예측 불가능하거나 잠재적으로 위험한 행동이 치명적인 결과를 초래할 수 있다. 따라서 LLM 기반 에이전트의 행동이 사전에 정의된 안전 제약 조건을 반드시 준수하도록 보장하는 메커니즘 연구가 필수적이다.

파라미터 수가 수십억에서 수조 개에 이르는 대규모 LLM의 단일 추론 과정은 상당한 계산 시간과 메모리 자원을 요구한다. 이는 많은 강화학습 응용 분야에서 요구하는 밀리초(ms) 단위의 빠른 의사결정과 실시간 반응 속도를 지원하는 데 구조적인 어려움을 야기한다. 현재 LLM의 추론 속도는 이러한 요구사항을 충족시키기에 부족한 경우가 많다. 이 문제를 완화하기 위한 노력들이 진행되고 있지만, 종종 성능 저하를 수반하거나 추가적인 비용을 발생시킬 수 있다. 따라서 성능, 속도, 비용 간의 균형을 맞추는 실용적인 솔루션 개발이 중요한 과제로 남아있다.

2. 향후 연구 방향 및 결론

앞서 논의된 LLM 기반 강화학습의 한계점과 도전 과제들을 극복하고, 이 분야의 잠재력을 최대한 발휘시키기 위해서는 다각적이고 심도 있는 향후 연구가 필수적이다.

정교한 하이브리드 접근법 및 메타/연속 학습 연구 심화가 필요하다. LLM의 고수준 계획 능력과 전통적인 강화학습 알고리즘의 저수준 제어 정밀성을 효과적으로 결합하는 다양한 형태의 정교한 하이브리드 아키텍처 연구가 핵심적인 돌파구가 될 수 있다. 예를 들어, LLM이 장기적인 목표나 하위 목표열을 생성하고, 다른 RL 알고리즘이 각 하위 목표를 달성하는 저수준 정책을 학습하는 계층적 강화학습 구조를 보다 심도 있게 탐구해야 한다. 더 나아가, LLM을 활용하여 소량의 경험 데이터로부터 새로운 작업이나 환경 변화에 빠르게 적응하는 효과적인 학습 전략 자체를 학습하는 메타 학습 연구와, 이전에 학습된 지식을 잊지 않고 새로운 지식을 점진적으로 통합해 나가는 연속 학습 능력 개발 연구는 데이터 효율성과 에이전트의 적응력을 획기적으로 향상 시킬 잠재력이 있다.

강화학습 특화 프롬프트 엔지니어링 고도화 및 자동화가 요구된다. 강화학습 문제의 고유한 특성을 LLM이 효과적으로 이해하고 최적 행동 추

론에 반영하도록 유도하는 프롬프트 설계 원리 및 최적화 기법에 대한 체계적인 연구가 필요하다. 또한, 강화학습 과정에서 얻어지는 피드백을 활용하여 프롬프트를 동적으로 수정하거나 개선하는 적응형 프롬프팅(adaptive prompting) 기법 개발도 중요하다. 궁극적으로는 프롬프트 자체를 데이터로부터 학습하거나 자동으로 생성하고 개선하는 연구가 이 분야의 발전에 크게 기여할 것이다.

멀티모달 정보 통합 및 샘플 효율성 극대화 방안을 모색해야 한다. 로봇 센서로부터 얻어지는 이미지, 비디오 스트림, 음향 정보 등 다양한 형태의 데이터를 LLM이 통합적으로 이해하고 이를 바탕으로 보다 풍부한 현실 세계의 물리적 맥락 속에서 의사결정을 내리도록 하는 멀티모달 LLM(Multimodal LLM) 기반 강화학습 연구가 매우 중요하다. 또한, LLM의 강력한 사전 지식, 제로샷/퓨샷 추론 능력을 활용하여 환경과의 상호작용 횟수를 획기적으로 줄이는 방안을 모색해야 한다. LLM을 이용해 가상 환경을 시뮬레이션하고 합성 데이터를 생성함으로써, 에이전트가 실제 환경과의 값비싼 상호작용 없이도 풍부한 경험을 쌓도록 도울 수 있다.

설명 가능한 AI 기술 개발 및 신뢰성/안전성 강화가 필수적이다. LLM 기반 에이전트가 왜 특정 행동을 선택했는지 그 의사결정 과정을 사용자가 이해하고 신뢰할 수 있도록, LLM의 내부 추론 과정을 설명하는 설명 가능한 AI 기술 개발 역시 이 분야의 책임감 있는 발전을 위해 필수적으로 병행되어야 할 중요한 연구 과제이다. 마지막으로, 앞서 언급한 실시간 추론 성능 개선을 위한 지속적인 노력과 더불어, LLM 기반 에이전트가 예측 불가능하거나 잠재적으로 위험한 행동을 하지 않도록 안전성과 신뢰성을 보장하기 위한 체계적인 메커니즘 연구가 필요하다.

결론적으로, 본 연구는 LLM을 강화 학습 에이전트의 핵심 구성 요소로 통합하는 혁신적인 접근법을 제안하고, 표준 벤치마크 환경에서의 실험을 통해 그 유효성과 잠재력을 실증적으로 검증하였다. 연구 결과, LLM 기

반 에이전트는 전통적인 강화학습 방법론 대비 우수한 목표 달성 능력, 효율적인 경로 탐색, 뛰어난 일반화 성능 및 학습 안정성을 나타내었으며, 이는 LLM이 가진 방대한 사전 지식, 뛰어난 언어 이해 및 추론 능력이 순차적 의사결정 문제 해결에 효과적으로 기여할 수 있음을 명확히 보여 준다. 본 연구의 가장 중요한 학문적 의의는 자연어 처리와 강화학습이라는 인공지능의 두 핵심 분야를 성공적으로 융합할 수 있는 구체적인 방법론과 실증적 증거를 제시함으로써, LLM을 순차적 의사결정 문제 해결을 위한 강력한 인지 엔진으로 활용할 수 있는 새로운 연구 패러다임의 가능성을 열었다는 데 있다. 기술적으로는 상태 표현의 유연성 증대, 일반화 능력 및 데이터 효율성 향상, 해석 가능성 증진, 그리고 경험 기반 학습 및 인간-AI 상호작용의 새로운 가능성 탐색 등, 기존 강화학습의 여러 한계를 극복하고 실용성을 높이는 데 기여할 수 있는 중요한 기초를 제공하였다. 특히 한국어 특화 모델을 활용한 실험은 다양한 언어 환경에서의 LLM 기반 강화학습 연구 확장의 필요성을 시사한다. 대규모 언어 모델 기반 강화학습은 지능형 에이전트 개발에 있어 혁신적인 변화를 가져올 잠재력을 지닌 매우 유망한 연구 분야이다. 그러나 미지의 동적 환경 대처 능력, 확장성, 학습 안정성, 최적성 및 안전성 보장, 실시간 처리 및 계산 비용 문제 등 해결해야 할 중요한 도전 과제들 또한 산적해 있다. 향후 연구는 본 논문에서 제안한 바와 같이, 정교한 하이브리드 아키텍처 개발, 강화학습 특화 프롬프트 엔지니어링 고도화, 멀티모달 정보 통합, 샘플 효율성 극대화, 설명 가능한 AI 기술 개발, 그리고 신뢰성 및 안전성 강화에 집중해야 할 것이다. 이러한 기술적 난제들을 창의적이고 엄밀한 연구를 통해 성공적으로 극복해 나간다면, 우리는 보다 고도의 지능과 자율성을 갖추고, 예측 불가능한 환경 변화에 강건하게 적응하며, 인간과 자연스럽고 효과적으로 소통하고 협력할 수 있는 차세대 자율 에이전트를 개발하는 목표에 한 걸음 더 다가설 수 있을 것이다. 이는 궁극적으로 교육, 의료, 환경, 산업, 과학 연구 등 인류가 직면한 다양한 영역의 복잡하

고 도전적인 현실 세계의 문제들을 해결하는 데 중요한 기술적 진보를 이룰 수 있음을 의미한다.

참 고 문 헌

- [1] Sutton, R. S. & Barto, A. G.(2018). Reinforcement learning: An introduction. MIT press.
- [2] Arulkumaran, K., Deisenroth, M. P., Brundage, M., & Bharath, A. A. (2017). Deep reinforcement learning: A brief survey. IEEE Signal Processing Magazine, 34(6), 26-38.
- [3] Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., & Hassabis, D. (2015). Human-level control through deep reinforcement learning. Nature, 518(7540), 529-5332.
- [4] Li, Y. (2017). Deep reinforcement learning: An overview. arXiv preprint arXiv:1701.07274.
- [5] Silver, D., Hubert, T., Schrittwieser, J., Antonoglou, I., Lai, M., Guez, A., & Hassabis, D. (2017). Mastering Chess and Shogi by Self-Play with a General Reinforcement Learning Algorithm. arXiv preprint arXiv:1712.014815.
- [6] Vinyals, O., Babuschkin, I., Czarnecki, W. M., Mathieu, M., Dudzik, A., Chung, J., & Silver, D. (2019). Grandmaster level in StarCraft II using multi-agent reinforcement learning. Nature, 575(7782), 350-3545.
- [7] Levine, S., Finn, C., Darrell, T., & Abbeel, P. (2016). End-to-end training of deep visuomotor policies. Journal of Machine Learning Research, 17(39), 1-40.
- [8] Kober, J., Bagnell, J. A., & Peters, J. (2013). Reinforcement learning in robotics: A survey. The International Journal of Robotics Research, 32(11), 1238-12747.
- [9] Kiran, B. R., Sobh, I., Talpaert, V., Mannion, P., Al Sallab, A. A., Yogamani, S., & Pérez, P. (2021). Deep reinforcement learning for

- autonomous driving: A survey. *IEEE Transactions on Intelligent Transportation Systems*, 23(6), 4909–4926.
- [10] Lazic, N., Lu, T., Chen, X., Boutilier, C., & Roy, B. V. (2018). Data center cooling using model-predictive control. *Advances in Neural Information Processing Systems*, 31.
- [11] Afsar, M. M., Crump, T., & Far, B. (2021). Reinforcement learning based recommender systems: A survey. *ACM Computing Surveys (CSUR)*, 54(5), 1–38.
- [12] Moerland, T. M., Broekens, J., & Jonker, C. M. (2023). Model-based reinforcement learning: A survey. *Foundations and Trends in Machine Learning*, 16(1), 1–118.
- [13] Levine, S., Kumar, A., Tucker, G., & Fu, J. (2020). Offline reinforcement learning: Tutorial, review, and perspectives on open problems. *arXiv preprint arXiv:2005.091643*.
- [14] Finn, C., Abbeel, P., & Levine, S. (2017). Model-agnostic meta-learning for fast adaptation of deep networks. In *International conference on machine learning* (pp. 1126–113511). PMLR.
- [15] Pathak, D., Agrawal, P., Efros, A. A., & Darrell, T. (2017). Curiosity-driven exploration by self-supervised prediction. In *Proceedings of the IEEE conference on computer vision and pattern recognition workshops13* (pp. 16–17).
- [16] Burda, Y., Edwards, H., Storkey, A., & Klimov, O. (2018). Exploration by random network distillation. *arXiv preprint arXiv:1810.12894*.
- [17] Garcia, J., & Fernandez, F. (2015). A comprehensive survey on safe reinforcement learning. *Journal of Machine Learning Research*, 16(1), 1437–1480.

- [18] Cobbe, K., Hesse, C., Hilton, J., & Schulman, J. (2019). Leveraging procedural generation to benchmark reinforcement learning. arXiv preprint arXiv:1912.1501588.
- [19] Tobin, J., Fong, R., Ray, A., Schneider, J., Zaremba, W., & Abbeel, P. (2017). Domain randomization for transferring deep neural networks from simulation to the real world. In 2017 IEEE/RSJ international conference on intelligent robots and systems (pp. 23–30). IEEE.
- [20] Zhang, K., Yang, Z., & Başar, T. (2021). Multi-agent reinforcement learning: A selective overview of theories and algorithms. In *Handbook of Reinforcement Learning and Control* (pp. 321–384). Springer, Cham.
- [21] Christiano, P. F., Leike, J., Brown, T., Martic, M., Legg, S., & Amodei, D. (2017). Deep reinforcement learning from human preferences. *Advances in neural information processing systems*, 30.
- [22] Zhao, W. X., Zhou, K., Li, J., Tang, T., Wang, X., Hou, Y., & Wen, J. R. (2023). A survey of large language models. arXiv preprint arXiv:2303.18223.
- [23] Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., & Amodei, D. (2020). Language models are few-shot learners. *Advances in neural information processing systems*, 33, 1877–1901.
- [24] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, 30.
- [25] Kaplan, J., McCandlish, S., Henighan, T., Brown, T. B., Chess, B., Child, R., & Amodei, D. (2020). Scaling laws for neural language

- models. arXiv preprint arXiv:2001.0832361.
- [26] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805.
- [27] Wei, J., Tay, Y., Bommasani, R., Raffel, C., Zoph, B., Borgeaud, S., ... & Fedus, W. (2022). Emergent abilities of large language models. Transactions on Machine Learning Research.
- [28] Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., & Liu, P. J. (2020). Exploring the limits of transfer learning with a unified text-to-text transformer. Journal of Machine Learning Research, 21(140), 1-67.
- [29] OpenAI. (2023). GPT-4 Technical Report. arXiv preprint arXiv:2303.08774.
- [30] Chen, M., Tworek, J., Jun, H., Yuan, Q., Ponde de Oliveira Pinto, H., Kaplan, J., & Zaremba, W. (2021). Evaluating large language models trained on code. arXiv preprint arXiv:2107.03374.
- [31] Petroni, F., Rocktäschel, T., Lewis, P., Bakhtin, A., Wu, Y., Miller, A. H., & Riedel, S. (2019). Language models as knowledge bases?. arXiv preprint arXiv:1909.0102966.
- [32] Boiko, D. A., MacKnight, R., & Gomes, G. (2023). Emergent autonomous scientific research capabilities of large language models. arXiv preprint arXiv:2304.0533032.
- [33] Kasneci, E., Sessler, K., Küchemann, S., Bannert, M., Dementieva, D., Fischer, F., & Kasneci, G. (2023). ChatGPT for good? On opportunities and challenges of large language models for education. Learning and Individual Differences, 103, 32102274.
- [34] Amodei, D., Olah, C., Steinhardt, J., Christiano, P., Schulman, J., &

- Mane, D. (2016). Concrete problems in AI safety. arXiv preprint arXiv:1606.06565.
- [35] Puiutta, E., & Veith, E. (2020). Explainable reinforcement learning: A survey. In IFIP International Conference on Artificial Intelligence Applications and Innovations (pp. 77–88). Springer, Cham.
- [36] Jiang, Y., Gu, S. S., Murphy, K., & Finn, C. (2019). Language as an abstraction for hierarchical deep reinforcement learning. *Advances in Neural Information Processing Systems*, 32.
- [37] Lynch, C., Khansari, M., Xiao, T., Kumar, V., Tompson, J., Levine, S., & Sermanet, P. (2019). Learning latent plans from play. In *Conference on Robot Learning* (pp. 851–863). PMLR.
- [38] Goyal, T., Niekum, S., & Mooney, R. J. (2019). Using natural language for reward shaping in reinforcement learning. arXiv preprint arXiv:1903.02020.
- [39] Kwon, M., Kim, D., & Lee, S. (2023). Reward Design with Language Models. arXiv preprint arXiv:2303.00007.
- [40] Ahn, M., Brohan, A., Brown, N., Chowdhery, A., Cortes, E., David, A., & Zitkovich, M. (2022). Do as i can, not as i say: Grounding language in robotic affordances. arXiv preprint arXiv:2204.01691.
- [41] Huang, W., Abbeel, P., Pathak, D., & Mordatch, I. (2022). Language models as zero-shot planners: Extracting actionable knowledge for embodied agents. In *International Conference on Machine Learning* (p36p. 9118–9147). PMLR.
- [42] Du, Y., Watkins, O., Wang, Z., Colas, C., Darrell, T., Abbeel, P., & Andreas, J. (2023). Guiding Pretraining in Reinforcement Learning with Large Language Models. arXiv preprint arXiv:2302.06692.
- [43] Carta, T., Romac, C., Lamprier, S., Sigaud, O., & Oudeyer, P. Y.

- (2023). Grounding large language models in interactive environments with online reinforcement learning. arXiv preprint arXiv:2302.39026.
- [44] Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., & Stoyanov, V. (2019). Roberta: A robustly optimized bert pretraining approach. arXiv preprint arXiv:1907.11692.
- [45] Lan, Z., Chen, M., Goodman, S., Gimpel, K., Sharma, P., & Soricut, R. (2019). Albert: A lite bert for self-supervised learning of language representations. arXiv preprint arXiv:1909.11941.
- [46] Clark, K., Luong, M. T., Le, Q. V., & Manning, C. D. (2020). Electra: Pre-training text encoders as discriminators rather than generators. arXiv preprint arXiv:2003.10555.
- [47] Radford, A., Narasimhan, K., Salimans, T., & Sutskever, I. (2018). Improving language understanding by generative pre-training.
- [48] Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., & Sutskever, I. (2019). Language models are unsupervised multitask learners. OpenAI blog, 431(8), 9.
- [49] Lewis, M., Liu, Y., Goyal, N., Ghazvininejad, M., Mohamed, A., Levy, O., & Zettlemoyer, L. (2019). Bart: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension. arXiv preprint arXiv:1910.13461.
- [50] Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M. A., Lacroix, T., & Lample, G. (2023). Llama: Open and efficient foundation language models. arXiv preprint arXiv:2302.13971.
- [51] Chowdhery, A., Narang, S., Devlin, J., Bosma, M., Mishra, G., Roberts, A., & Fiedel, N. (2022). Palm: Scaling language modeling with pathways. arXiv preprint arXiv:2204.02311.
- [52] Gemini Team, Google. (2023). Gemini: A Family of Highly

Capable Multimodal Models. arXiv preprint arXiv:2312.11805.

[53] Bai, Y., Kadavath, S., Kundu, S., Askill, A., Kernion, J., Jones, A., & Kaplan, J. (2022). Constitutional ai: Harmlessness from ai feedback. arXiv preprint arXiv:2212.0807347.

[54] Chevalier-Boisvert, M., Willems, L., & Pal, S. (2018). Minimalistic gridworld environment for openai gym.

[55] Watkins, C.J.C.H., Dayan, P. (1992). Q-learning. Mach Learn 8, 279 - 292. <https://doi.org/10.1007/BF00992698>

[56] Richard S. Sutton, (2000). Policy Gradient Methods for Reinforcement Learning with Function Approximation. NeurIPS

[57] Williams, R.J. (1992). Simple statistical gradient-following algorithms for connectionist reinforcement learning. Mach Learn 8, 229 - 256 . <https://doi.org/10.1007/BF00992696>

[58] Vijay R. Konda, John N. Tsitsiklis. (2000). Actor-Critic Algorithms.

[59] Lillicrap, T.P., Hunt, J.J., Pritzel, A., Heess, N.M., Erez, T., Tassa, Y., Silver, D., & Wierstra, D. (2015). Continuous control with deep reinforcement learning. CoRR, abs/1509.02971.

[60] Fujimoto, S., Hoof, H.V., & Meger, D. (2018). Addressing Function Approximation Error in Actor-Critic Methods. International Conference on Machine Learning.

[61] Haarnoja, T., Zhou, A., Abbeel, P., & Levine, S. (2018). Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor. ArXiv, abs/1801.01290.

[62] Sepp Hochreiter, Jürgen Schmidhuber, (1997). Long Short-Term Memory. Neural Computation, 9 (8): 1735 - 1780. doi: <https://doi.org/10.1162/neco.1997.9.8.1735>

- [63] Cho, K., Merrienboer, B.V., Gülçehre, Ç., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning Phrase Representations using RNN Encoder - Decoder for Statistical Machine Translation. Conference on Empirical Methods in Natural Language Processing.
- [64] Nachum, O., Gu, S.S., Lee, H., & Levine, S. (2018). Data-Efficient Hierarchical Reinforcement Learning. Neural Information Processing Systems.
- [65] Chevalier-Boisvert, M., Bahdanau, D., Lahlou, S., Willems, L., Saharia, C., Nguyen, T.H., & Bengio, Y. (2019). BabyAI: A Platform to Study the Sample Efficiency of Grounded Language Learning. International Conference on Learning Representations.
- [66] Houlsby, N., Giurghi, A., Jastrzebski, S., Morrone, B., Laroussilhe, Q.D., Gesmundo, A., Attariyan, M., & Gelly, S. (2019). Parameter-Efficient Transfer Learning for NLP. ArXiv, abs/1902.00751.
- [67] Hu, J.E., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., & Chen, W. (2021). LoRA: Low-Rank Adaptation of Large Language Models. ArXiv, abs/2106.09685.
- [68] Wei, J., Tay, Y., Bommasani, R., Raffel, C., Zoph, B., Borgeaud, S., Yogatama, D., Bosma, M., Zhou, D., Metzler, D., Chi, E.H., Hashimoto, T., Vinyals, O., Liang, P., Dean, J., & Fedus, W. (2022). Emergent Abilities of Large Language Models. ArXiv, abs/2206.07682.
- [69] Wei, J., Bosma, M., Zhao, V., Guu, K., Yu, A.W., Lester, B., Du, N., Dai, A.M., & Le, Q.V. (2021). Finetuned Language Models Are Zero-Shot Learners. ArXiv, abs/2109.01652.
- [70] Ba, J., Kiros, J.R., & Hinton, G.E. (2016). Layer Normalization. ArXiv, abs/1607.06450.
- [71] Shazeer, N.M. (2020). GLU Variants Improve Transformer. ArXiv,

abs/2002.05202.

[72] Su, J., Lu, Y., Pan, S., Wen, B., & Liu, Y. (2021). RoFormer: Enhanced Transformer with Rotary Position Embedding. ArXiv, abs/2104.09864.

ABSTRACT

A Study on Large Language Model-Based Learning for Efficient Agent Behavior Optimization in a Reinforcement Learning Environment

Yong, Sung Jung

Department of Computer Science & Engineering

Major of Computer Science & Engineering

The Graduate School

Korea University of Technology and Education

As an endeavor to overcome fundamental limitations in Reinforcement Learning concerning the implementation of autonomous decision-making capabilities in intelligent agents, this research proposes and empirically validates a novel paradigmatic approach. This approach leverages the inherent high-dimensional natural language processing and reasoning capacities of Large Language Models to optimize the behavior of RL agents within the MiniGrid environment. The core contribution of this methodology lies in the design and implementation of an original information processing and control loop. This loop transforms environmental state information into sophisticatedly structured natural language text, conveys it to an LLM (particularly utilizing a Korean-specialized model), derives an optimal

action policy through the LLM’s semantic understanding and reasoning mechanisms, and subsequently translates this policy back into executable control signals within the environment.

Rigorous comparative experiments conducted in the MiniGrid-Empty-5x5-v0 environment demonstrated that the proposed LLM-based agent exhibited statistically significant and marked superiority over representative deep reinforcement learning algorithms, such as PPO and DQN, as well as a random exploration baseline. This superiority was evident in both goal achievement success rate (95.3%) and learning stability (reward standard deviation of 0.24). This suggests that LLM integration not only enhances performance but also effectively suppresses volatility during the learning process. Furthermore, the enhanced exploration efficiency, confirmed by a reduction in the average number of steps required to reach the goal, coupled with superior initial performance and generalization ability observed even in a more complex 16x16 environment, strongly substantiates the practical utility and potential of this approach.

These empirical findings strongly suggest that the LLM-based approach embodies significant theoretical strengths, including structural flexibility in processing environmental state information, superior generalization potential through leveraging vast pre-trained knowledge, and potentially enhanced interpretability. Nevertheless, this study also clearly highlights existing technological constraints. Key among these are scalability issues when extending to extremely complex or dynamic real-world environments, the absence of mathematical optimality guarantees for generated actions, performance reproducibility and stability challenges inherent in stochastic models, and the real-time

inference performance limitations of large-scale models. These remain critical challenges that must be addressed for practical application.

In conclusion, this research confirms that integrating LLMs as the core decision-making mechanism within RL presents a new research paradigm with considerable potential. However, translating this potential into fully practical technology necessitates overcoming the aforementioned multidimensional technical hurdles, including scalability, optimality, stability, and real-time performance. Therefore, future research must strategically focus on designing more sophisticated hybrid architectures, advancing LLM fine-tuning and prompt engineering tailored to the specific characteristics of RL problems, effectively integrating multimodal information, developing robust safety and reliability assurance mechanisms, and incorporating Explainable AI techniques. Through such multifaceted efforts, it is anticipated that current limitations can be surmounted, ultimately advancing towards the vision of realizing autonomous agent systems endowed with human-level intelligence and adaptability.

Keyword : LLM, Reinforcement Learning, Natural Language Processing, MiniGrid, Agent Behavior Optimization, Artificial Intelligence